

NOTE D'INFORMATION POUR STATISTICIENS, INFORMATIENS ET DIRECTION

Infrastructure IA pour les instituts de statistique

Ce qu'il faut réellement pour exploiter l'IA dans un institut national de statistique — avec un accent sur le contexte africain

Calcul

Données & MLOps

Déploiement

Gouvernance

Coûts

Équipes & feuille de route

Data Innovation For Africa (DI4A) - African Development Bank

Pourquoi cette présentation, et ce que vous apprendrez

Objectif : une base commune et pratique pour décider comment bâtir une capacité IA dans un INS

LE MESSAGE CENTRAL

Dans un INS, une capacité IA est une plateforme de production soumise à des obligations légales — ni un modèle, ni un projet ponctuel.

PUBLIC VISÉ



Statisticiens et méthodologues



Équipes informatiques et sécurité



Direction et organes de contrôle

À LA FIN, VOUS SAUREZ

1

Expliquer les cinq couches d'un système d'IA et pourquoi le modèle en est la plus petite

2

Associer matériel, hébergement et modèles à chaque charge et à sa classification

3

Identifier les nouveaux risques de divulgation liés à l'IA et les contrôles adaptés

4

Estimer le coût complet sur cinq ans et les décisions qui le font vraiment varier

5

Planifier l'équipe, les niveaux de maturité et une feuille de route de 24 mois

Sommaire

Six parties, environ 95 minutes avec les échanges

01



Cadrage & architecture

Pourquoi le modèle est la partie facile, cas d'usage, contexte africain, architecture en cinq couches

02



Calcul, données & MLOps

Matériel IA et dimensionnement, énergie, plateformes de données, données annotées, RAG

03



Choix de déploiement

Quatre modèles d'hébergement, grille de décision, faire ou acheter, modèles ouverts ou propriétaires

04



Gouvernance & confidentialité

Nouveaux risques de divulgation, cadre juridique, niveaux de classification, contrôles

05



Coûts & budget

Structure complète des coûts, scénarios à cinq ans, seuils de rentabilité, argumentaire budgétaire

06



Équipes & feuille de route

Rôles, compétences, maturité, plan sur 24 mois et liste de vérification

Dix notions clés en langage simple

Gardez cette page en tête : toutes les diapositives suivantes utilisent ces termes



Modèle

Programme dont le comportement est appris à partir d'exemples plutôt qu'écrit sous forme de règles.



Entraînement

Montrer au modèle de nombreux exemples annotés pour qu'il apprenne. Calcul lourd et ponctuel.



Inférence

Utiliser un modèle entraîné pour produire une réponse. Léger par requête, mais continu.



GPU

Processeur effectuant de nombreux calculs en parallèle. Vital pour les grands modèles.



LLM

Grand modèle de langage : modèle génératif qui rédige, extrait et classe du texte.



Modèle ouvert

Modèle à poids ouverts : on peut télécharger les paramètres et l'exécuter sur ses propres serveurs.



Affinage

Entraînement complémentaire d'un modèle existant sur vos propres données.



RAG

Génération augmentée par récupération : le modèle répond à partir de vos documents.



MLOps

Pratiques et outils qui font passer un modèle de l'expérimentation à la production.



Jeu de référence

Données figées, codées par des experts, qui servent à mesurer la performance d'un modèle.

SECTION 01

01

Cadrage & architecture

Pourquoi le modèle est-il la partie la plus simple d'un système d'IA ?

DANS CETTE SECTION

- › Le modèle, partie facile
- › Où l'IA est utile
- › Un exemple détaillé
- › INS ou entreprise tech
- › Le contexte africain
- › Les cinq couches



Le modèle est la partie facile

Dans un système d'IA en production, le code du modèle est une petite boîte entourée de bien plus grandes

~5 %

d'un système réel d'apprentissage automatique est du code de modèle ; le reste : données, service, suivi

6–18

mois : délai d'acquisition typique de GPU sur site dans l'administration (ordre de grandeur)

20–40 %

de l'effort va à la préparation des données, à l'annotation et à l'évaluation (ordre de grandeur)

CE QUE CONTIENT UN SYSTÈME D'IA EN PRODUCTION

Collecte des données

Vérification des données

Configuration

Extraction de variables

Code du modèle

Infrastructure de service

Gestion des ressources

Outils d'analyse et d'évaluation

Suivi et surveillance



À RETENIR Une capacité IA est une plateforme, pas un projet : il lui faut un financement récurrent, un responsable et une équipe d'exploitation — et on la juge par rapport au processus manuel actuel, pas à la perfection.

Source : Sculley et al., « Hidden Technical Debt in Machine Learning Systems », NeurIPS 2015 (schéma adapté). Délais et parts d'effort : ordres de grandeur.

Où l'IA trouve sa place en statistique officielle

Huit familles de cas d'usage, classées approximativement par maturité dans les instituts



Codification automatique

Réponses en clair codées en CITP, CITI, COICOP, CPC ou CIM.

Éprouvé



Données web et de caisse

Prix en ligne pour l'IPC, offres d'emploi en ligne.

Éprouvé



Appariement

Recensement, répertoires et fichiers administratifs.

Éprouvé



Contrôle et imputation

Contrôle sélectif, valeurs aberrantes, imputation.

Éprouvé



Textes et documents

Questions ouvertes, répertoires, métadonnées.

Émergent



Imagerie et géospatial

Bâti pour la cartographie censitaire, sols, cultures.

Émergent



Outils d'assistance

Aide au code, rédaction, traduction, recherche.

Émergent



Appui à la confidentialité

Risque de divulgation, données synthétiques.

Validation requise



À RETENIR Commencez là où vous disposez déjà d'années de réponses codées manuellement — en général la codification. On peut l'évaluer honnêtement dès le premier jour.

Exemple : coder les professions avec l'IA

Suivre une réponse du recensement, du questionnaire au tableau publié



ILLUSTRATION : 100 000 RÉPONSES DU RECENSEMENT

70 000 codées automatiquement

30 000 aux codeurs

Les codeurs traitent les 30 % difficiles et contrôlent la qualité du reste.

TROIS LEÇONS

- ✓ Le score de confiance compte autant que le code
- ✓ Fixer le seuil sur un jeu de référence figé
- ✓ On redéploie les agents, on ne les supprime pas

Chiffres pédagogiques. Les taux réels dépendent des données, de la nomenclature et du seuil. CITP-08 2341 = enseignants du primaire.

Un institut de statistique n'est pas une entreprise tech

Les différences sont juridiques et méthodologiques — pas culturelles

DIMENSION	ENTREPRISE TECH TYPIQUE	INSTITUT NATIONAL DE STATISTIQUE
 Données	Surtout propres, consenties, remplaçables	Collecte obligatoire ; microdonnées confidentielles sous secret statistique
 Tolérance à l'erreur	Livrer, mesurer, itérer ; revenir en arrière discrètement	Un chiffre publié est un acte public ; une erreur entraîne révision et perte de confiance
 Rythme de diffusion	Déploiement continu, hebdomadaire	Calendrier de diffusion annoncé à l'avance ; politique formelle de révision
 Reproductibilité	Souhaitable	Obligatoire — un chiffre peut devoir être reproduit des années plus tard
 Explicabilité	Seulement si un régulateur l'exige	Documentation méthodologique, revue par les pairs, comparabilité internationale
 Marché des talents	Concurrence par les salaires	Grilles publiques ; fidélisation par la mission, les données et la formation
 Infrastructure	Cloud public élastique par défaut	Souveraineté, marchés publics, classification, électricité parfois instable

Ce qui change pour les instituts africains

Quatre faits qui pèsent sur chaque décision d'infrastructure sur le continent

~600 M



de personnes sans électricité en
Afrique subsaharienne en 2024
(47 % de la population)

AIE

0,6 %



part de l'Afrique dans la capacité
mondiale des centres de données ;
l'énergie est la contrainte n° 1

ADCA 2026

40+



pays africains ont adopté une loi sur
la protection des données

ADCA 2026

< 2 %



des ~2 000 langues africaines sont
bien prises en charge par les grands
modèles de langage

BCG 2026

CE QUE CELA IMPLIQUE EN PRATIQUE



L'énergie d'abord

Vérifier la puissance disponible et
l'autonomie de secours avant de
choisir le matériel.



Héberger, un choix souverain

Peu d'options nationales ;
l'hébergement à l'étranger exige
une base légale.



Un paysage juridique inégal

S'aligner sur la loi statistique, la loi
sur les données et les cadres de
l'UA.



L'opportunité

L'essentiel de la valeur vient de
l'inférence légère et de
l'apprentissage classique.

Sources : AIE (2025) ; Africa Data Centres Association (ADCA), Data Centres in Africa 2026 ; BCG, Advancing Africa's AI and Digital Economy (2026).

Cinq couches, un plan de gouvernance

À lire de bas en haut : chaque couche ne vaut que ce que vaut celle du dessous



À RETENIR
non budgété.

Le plan de gouvernance ne s'ajoute pas à la fin. Il contraint chaque couche, et c'est là que se cache l'essentiel de l'effort

02

Calcul, données & MLOps

Quels matériels, données et processus faut-il avant de se fier à un modèle ?

DANS CETTE SECTION

- › Entraînement ou inférence
- › Adapter le matériel
- › Le matériel IA expliqué
- › Énergie, stockage, réseau
- › Concevoir malgré les coupures
- › La plateforme de données
- › Les données annotées
- › Comment fonctionne le RAG
- › MLOps et environnements



Entraînement ou inférence : deux charges très différentes

La plupart des erreurs d'achat viennent de la confusion entre les deux



Entraînement

Comme former un nouveau codeur à la nomenclature

Fréquence	Quelques fois par an
Calcul	Lourd : GPU pendant des heures ou des jours
Données	Des milliers d'exemples annotés
Risque	Acheter une grappe qui reste inactive
Où l'exécuter	Louer ou emprunter de la capacité ponctuelle



Inférence

Comme le codeur formé qui traite des questionnaires chaque jour

Fréquence	En continu, chaque jour
Calcul	Léger par requête : CPU ou un GPU
Données	Les nouveaux enregistrements à classer
Risque	Une panne pendant une période de diffusion
Où l'exécuter	Capacité stable, propre ou contractuelle



À RETENIR

La plupart des usages d'un INS sont lourds en inférence et légers en entraînement. Dimensionnez le matériel propre pour l'inférence ; louez la capacité d'entraînement au besoin.

Adapter le matériel à la charge de travail

L'erreur la plus coûteuse : acheter du matériel d'entraînement pour un besoin d'inférence

CHARGE DE TRAVAIL	MATÉRIEL TYPE	DURÉE	POUR UN INS ?	COMMENTAIRE
Apprentissage classique (boosting, modèles linéaires)	CPU seul, 16–64 cœurs	Minutes–heures	Oui	Couvre une grande part de la codification
Affinage de petits modèles de texte (< 1 Md de paramètres)	1 GPU, 24–48 Go	Heures	Oui	Le cheval de trait de la classification
Exécution de petits LLM ouverts (7–14 Md, compressés)	1 GPU, 24–48 Go	Temps réel, équipes	Oui	Assistance, recherche, extraction
Exécution de LLM ouverts plus grands (~70 Md)	2–4 GPU de 80 Go	Temps réel, institut	Parfois	Comparer honnêtement à une API
Affinage efficace de modèles ~70 Md (LoRA)	4–8 GPU de 80 Go	Jours	Rarement	Seulement avec un vrai besoin métier
Pré-entraînement d'un modèle de fondation	Centaines à milliers de GPU	Semaines–mois	Non	Pas une activité d'institut statistique



À RETENIR Avant de demander un GPU, trois questions : entraînement ou inférence ? Charge soutenue ou pic ? La classification des données autorise-t-elle un calcul externe ?

Que contient un serveur IA ?

Sept composants — et le rôle de chacun pour l'IA

SERVEUR IA



CPU (processeur)

Orchestre, prépare les données, exécute l'apprentissage classique



GPU / accélérateur

Exécute en parallèle les calculs des réseaux de neurones



Mémoire GPU (VRAM)

Doit contenir tout le modèle : la caractéristique décisive



Mémoire système (RAM)

Alimente le GPU ; souvent $\geq 2 \times$ la mémoire GPU



Stockage NVMe

Charge vite données, modèles et points de reprise



Carte réseau

10–25 GbE pour un serveur ; plus rapide pour une grappe



Énergie et refroidissement de ~1 kW (un GPU) à plus de 10 kW (huit GPU) ; refroidissement à air ou liquide

UNE ANALOGIE



CPU = quelques chefs experts qui enchaînent des tâches complexes



GPU = des milliers de commis qui font chacun une tâche simple en même temps

POURQUOI C'EST IMPORTANT

Les réseaux de neurones répètent un calcul simple des milliards de fois — idéal pour les GPU. L'apprentissage classique reste sur CPU.

La mémoire GPU est le critère décisif

Un calcul simple indique quel modèle tient sur quelle carte

LA RÈGLE PRATIQUE

Mémoire $\approx$ paramètres $\times$ octets par paramètre + ~20 %

OCTETS PAR PARAMÈTRE

● 16 bits (complet) **2**


● 8 bits (compressé) **1**

● 4 bits (compressé) **0,5**



L'entraînement exige bien plus : un affinage complet demande ~16–20 octets par paramètre. LoRA / QLoRA le font tenir sur une carte.

Mémoire nécessaire pour exécuter un modèle (Go, ~20 % inclus)



TAILLES DE CARTES COURANTES

24 Go

entrée

48 Go

inférence

80 Go

H100

96 Go

RTX PRO 6000

141 Go

H200

180 Go

B200

Les familles d'accélérateurs en un coup d'œil

Exemples illustratifs, pas des recommandations — les gammes changent tous les 12 à 18 mois

CATÉGORIE	EXEMPLES (2026)	MÉMOIRE	PUISSANCE	POUR UN INS	USAGE TYPE
 Serveurs CPU	Processeurs serveur x86 ou Arm actuels	RAM système	0,3–1 kW	Essentiel	Apprentissage classique, petits modèles
 GPU d'entrée / d'inférence	NVIDIA L4, L40S	24–48 Go	~70–350 W	Adapté	Classifieurs, LLM de 7–14 Md
 GPU de station de travail	NVIDIA RTX PRO 6000 (Blackwell)	96 Go	~600 W	Adapté	Jusqu'à 70 Md compressé ; LoRA
 GPU de centre de données	NVIDIA H100 / H200 / B200 ; AMD Instinct	80 / 141 / 180 Go	~0,7–1 kW chacun	Sélectif	Grands modèles, entraînement multi-GPU
 Systèmes IA de bureau	NVIDIA DGX Spark	128 Go partagés	Prise standard	Adapté	Prototypage, petites équipes
 Accélérateurs cloud	Google TPU, AWS Trainium / Inferentia	En location	Chez le fournisseur	Si cloud permis	Seulement si la classification le permet



À RETENIR

Vérifiez la compatibilité logicielle avant la marque : vos outils doivent fonctionner sur la carte. La mémoire d'abord, la vitesse ensuite.

Sources : pages produits NVIDIA et fiches techniques compilées par GetDeploying (2026). Puissances indicatives maximales.

Trois configurations de référence pour un INS

Commencer petit, grandir seulement quand un usage franchit son jalon — et louer le haut de gamme

DÉMARRAGE

CONFIGURATION

1 serveur, 1–2 GPU (24–48 Go) ou système IA de bureau

PERMET

Apprentissage classique, classifieurs, LLM 7–14 Md

ÉNERGIE / FROID

~1–2 kW ; climatisation standard

PERSONNEL

Informatique existante + 0,5 ingénieur

COÛT MATÉRIEL

Quelques dizaines de milliers d'USD

STANDARD

CONFIGURATION

1–2 serveurs, 2–4 GPU de 48–96 Go chacun

PERMET

LLM 30–70 Md pour l'institut, affinage LoRA, plusieurs usages

ÉNERGIE / FROID

~3–5 kW par serveur ; baie dédiée

PERSONNEL

1–2 ingénieurs plateforme

COÛT MATÉRIEL

Environ 50–150 k USD

AVANCÉ

CONFIGURATION

Nœuds de 8 GPU (80–180 Go), liaison rapide

PERMET

Grands modèles, nombreuses équipes, recherche

ÉNERGIE / FROID

6–10 kW+ par nœud ; souvent liquide

PERSONNEL

2+ ingénieurs, support des locaux 24 h/24

COÛT MATÉRIEL

300 k USD et plus par nœud



À RETENIR

Commencez au niveau Démarrage, passez au Standard après un jalon réussi, et louez ou mutualisez le niveau Avancé.

Prix matériels indicatifs 2026, hors travaux, logiciels, personnel, droits d'importation et change. Demandez des devis actuels.

Acheter du matériel IA : liste de contrôle

Ce qu'il faut inscrire au cahier des charges — et les pièges à éviter



À EXIGER AU CAHIER DES CHARGES

- ✓ Mémoire GPU par carte et totale, selon les modèles visés
- ✓ Compatibilité avec vos logiciels (ex. CUDA, ROCm)
- ✓ Puissance par serveur et type de refroidissement (air ou liquide)
- ✓ Garantie et support sur place, délais des pièces détachées
- ✓ Mémoire à correction d'erreurs (ECC) et gestion à distance
- ✓ Mises à jour de sécurité du micrologiciel pendant au moins cinq ans
- ✓ Conditions de licence d'exportation et de livraison confirmées



À ÉVITER

- ✗ Acheter le dernier haut de gamme « pour être tranquille »
- ✗ Des cartes grand public de jeu en production
- ✗ Du marché gris ou du reconditionné sans garantie
- ✗ Spécifier le matériel avant l'audit électrique
- ✗ Des logiciels propriétaires qui enferment chez un fournisseur
- ✗ Aucun budget pour renouvellement, fin de vie et déchets



RÈGLE D'OR

Louer avant d'acheter : menez le pilote sur des GPU loués ou mutualisés pendant 3 à 6 mois, mesurez l'utilisation réelle, puis décidez.

Les goulots d'étranglement discrets

Rarement dans le dossier d'investissement — et souvent la cause de mois de retard



Hiérarchie de stockage

01

NVMe rapide pour les données actives, stockage objet pour les archives. Prévoir 3 à 5 fois le volume brut pour les points de reprise et fichiers intermédiaires.



Réseau interne

02

10 GbE au minimum ; 25 à 100 GbE pour l'entraînement multi-nœuds. Un réseau lent transforme un GPU coûteux en GPU inactif.



Énergie et refroidissement

03

Un nœud dense à 8 GPU peut consommer environ 6 à 10 kW, alors que beaucoup de salles sont conçues pour 3 à 5 kW par baie. C'est un budget d'infrastructure, pas informatique.



Sauvegarde et reprise

04

Instantanés d'entraînement, poids des modèles et registre doivent être sauvegardés et testés. Ils sont souvent hors du plan de reprise existant.



Sortie des données

05

Dans le cloud, l'entrée des données est souvent gratuite, pas leur sortie. Les allers-retours de microdonnées deviennent un coût récurrent et non plafonné.



Intégration des identités

06

Serveurs GPU et passerelles doivent utiliser l'annuaire de l'institut dès le départ. Ajouter l'authentification unique plus tard coûte bien plus cher.

Concevoir malgré une énergie et une connexion instables

Des pratiques qui maintiennent les traitements IA là où le réseau électrique et internet ne sont pas garantis



Connaître son enveloppe énergétique

Mesurer les kW par baie et l'autonomie de secours (en heures) avant de spécifier le matériel.



Protéger chaque traitement

Onduleur pour un arrêt propre, groupe ou hybride solaire pour l'autonomie ; points de reprise.



Privilégier les modèles sobres

Des modèles petits ou compressés sur CPU ou un GPU apportent l'essentiel pour une fraction de l'énergie.



Travailler hors ligne d'abord

Miroirs locaux des paquets, conteneurs et poids ; aucune installation ne dépend d'une liaison internationale.



Planifier les traitements

Lancer les calculs lourds la nuit ou aux heures stables ; mettre en file plutôt que d'échouer.



Mutualiser la capacité

Centres de données publics, centres universitaires ou pairs régionaux peuvent héberger ce qu'un institut seul ne peut pas.



CONTEXTE Mission 300 — initiative du Groupe de la Banque mondiale et de la Banque africaine de développement — vise à raccorder 300 millions de personnes en Afrique subsaharienne d'ici 2030. Concevez pour le réseau d'aujourd'hui.

Source : Groupe de la Banque mondiale, Mission 300 (2024). Puissances des nœuds GPU indicatives ; vérifier les fiches des fabricants.

Pas d'IA sur des données introuvables ou peu fiables

Six capacités qui doivent exister avant qu'un modèle vaille la peine d'être entraîné



Une plateforme gouvernée

Données d'enquête, administratives et alternatives sous un même modèle d'accès — pas des centaines d'extraits sur des lecteurs partagés.



Un catalogue de métadonnées

Métadonnées consultables, alignées sur GSIM et SDMX. Si un analyste ne trouve pas une variable, il la recrée.



Traçabilité de bout en bout

Quelle version des données, traitée par quelle version du code, a produit quel résultat.



Contrôle d'accès fin

Règles par ligne et par colonne liées aux niveaux de classification, appliquées par la plateforme.



Instantanés versionnés

Copies datées et immuables des données exactes ayant servi à entraîner et tester chaque modèle.



Jeux de référence annotés

Jeux d'entraînement et de test documentés, avec règles de codage et responsable désigné.



À RETENIR Si vous ne pouvez financer qu'une chose cette année, financez la plateforme de données : sa valeur ne dépend de la survie d'aucune technologie d'IA.

La vraie contrainte : les données annotées, pas les GPU

Le calcul se loue en un après-midi. Un jeu de référence défendable prend des mois

CE QUE VOUS POSSÉDEZ DÉJÀ

Des années de réponses codées

- ✓ Codes de profession et d'activité des recensements et enquêtes
- ✓ Décisions de contrôle enregistrées en production
- ✓ Décisions d'appariement passées, y compris la revue manuelle
- ✓ Manuels de codage et rapports qualité qui expliquent les codes

Cette archive est votre principal actif IA. Localisez-la, décrivez-la et protégez-la en priorité.




CE QU'IL RESTE À CONSTRUIRE

- 1 Figer d'abord le jeu de test**
Avant toute modélisation, sinon chaque mesure de précision est biaisée.
- 2 Budgéter l'annotation comme un vrai travail**
Temps des codeurs, consignes, arbitrage, accord mesuré.
- 3 Mesurer la performance humaine**
Les codeurs ne sont pas parfaits ; leur précision est la barre à franchir.
- 4 Stratifier pour les catégories rares**
La précision globale masque les échecs sur de petits groupes clés.
- 5 Maintenir lors des révisions**
Un jeu lié à une nomenclature périmée expire en silence.


Comment fonctionne la génération augmentée (RAG)

La méthode la plus courante pour qu'un modèle de langage réponde à partir de vos documents

RÉPONDRE À UNE QUESTION



PRÉPARÉ À L'AVANCE



la recherche utilise l'index


Pourquoi c'est utile

Les réponses s'appuient sur votre méthodologie, les sources sont citées et aucun réentraînement n'est nécessaire quand les documents changent.

Attention : l'index est une seconde copie des données. Classifiez-le, filtrez les résultats selon les droits de chaque utilisateur et versionnez-le avec le modèle.

Du notebook à la production en sept étapes

Chaque étape a un responsable et un livrable. Un pilote qui saute les étapes 2 à 5 ne peut pas être promu



À RETENIR

Les étapes 4 et 5 ne s'empruntent pas à l'industrie : c'est la méthodologie, et non l'ingénierie, qui tient la plume.

Environnements et chemin de promotion

Quelles données sont visibles où — ce schéma règle la plupart des désaccords entre analystes et sécurité



En plus : la zone de recherche sécurisée




Une enclave distincte pour les microdonnées identifiantes : pas de réseau sortant, sorties contrôlées avant diffusion, activité journalisée. C'est un quatrième environnement avec sa propre liste de modèles autorisés — jamais une extension de DEV.


La reproductibilité est une obligation statistique

On peut vous demander de reproduire un chiffre publié des années après — l'IA générative complique la tâche

SIX ÉLÉMENTS À FIGER ENSEMBLE POUR CHAQUE RÉSULTAT PUBLIÉ



LES RISQUES PROPRES AUX MODÈLES GÉNÉRATIFS



À RETENIR Quand un chiffre doit être reproductible sur demande, utilisez un modèle à poids ouverts hébergé chez vous — ou tenez l'IA générative hors du chemin critique.

03

Choix de déploiement

Où chaque traitement doit-il s'exécuter — et qui en décide ?


DANS CETTE SECTION

- › Quatre modèles d'hébergement
- › Une grille de décision
- › Sur site : la facture complète
- › Les pièges du cloud public
- › Héberger en Afrique
- › Le modèle hybride
- › Faire ou acheter
- › Modèles ouverts ou propriétaires
- › Exercice



Quatre modèles de déploiement

Du plus de contrôle au démarrage le plus rapide. La plupart des instituts en combinent plusieurs



À RETENIR

La question n'est jamais « lequel ? » mais « quel traitement va où ? » — et la classification des données tranche avant le coût.

Une grille de décision défendable

Évaluez honnêtement sept critères. En cas de conflit, la classification et le droit priment sur le coût

CRITÈRE	EN FAVEUR DU SUR SITE / SOUVERAIN	EN FAVEUR DU CLOUD / GÉRÉ	POIDS
 Classification des données	Microdonnées identifiantes sous secret statistique	Données publiées ou déjà publiques	Décisif
 Base légale et juridiction	La loi limite où et par qui les données sont traitées	Aucune restriction ; contrat et résidence suffisent	Décisif
 Profil de charge	Stable, prévisible, utilisation élevée	Irrégulier ou saisonnier — recensement, entraînement	Élevé
 Délai de premier résultat	Vous pouvez attendre l'achat et la mise en place	Il faut un pilote opérationnel ce trimestre	Élevé
 Mécanismes budgétaires	Crédits d'investissement (ou bailleurs), peu de récurrent	Budget de fonctionnement stable d'une année à l'autre	Élevé
 Compétences plateforme	Vous pouvez recruter et garder des ingénieurs	Vous ne pouvez pas les recruter ni les retenir	Élevé
 Réversibilité	Capacité de long terme que vous voulez maîtriser	Engagement réversible, formats ouverts	Moyen
 Lisez d'abord les deux lignes décisives. Si la classification ou la loi exclut une option, les cinq autres critères sont sans objet pour ce traitement. Documentez ce raisonnement une fois et réutilisez-le.			

Ce que « il suffit d'acheter un serveur » implique

La facture du matériel représente souvent moins de la moitié du coût sur cinq ans

< 50 %

du coût sur cinq ans correspond au matériel (ordre de grandeur)

Le reste : locaux, logiciels, exploitation, renouvellement — et personnel.



Matériel

Nœuds GPU, stockage rapide, réseau, baies. À dimensionner selon vos besoins réels.



Locaux techniques

Électricité, onduleurs, groupe, climatisation, sécurité incendie. Souvent un autre budget.



Logiciels de plateforme

Ordonnanceur, registre, stockage, identités, supervision, secrets, sauvegarde.



Exploitation

Pilotes, correctifs, capacité, astreinte. Un travail continu, pas une installation.



Cycle de vie

Renouvellement tous les 3 à 5 ans. Financez-le dès l'achat, pas la quatrième année.



Personnel

Environ 1,5 à 2 ingénieurs plateforme pour un petit parc GPU, plus sécurité et réseau.



Le délai des marchés : cahier des charges, appel d'offres, attribution, livraison, installation et réception prennent souvent 6 à 18 mois. Lancez l'achat en parallèle du pilote, pas après.

Cloud public : les pièges que personne ne budgète

Pas des raisons d'éviter le cloud — des raisons de les inscrire au dossier dès le premier jour



Frais de sortie

Sortir des microdonnées du cloud de façon répétée crée un coût récurrent non plafonné.



Ressources inactives

Des GPU allumés la nuit et le week-end : première source de dépassement.



Capacité et quotas

Le type de GPU prévu peut être indisponible dans votre région au moment voulu.



Résidence ≠ immunité

Des données stockées dans le pays peuvent rester accessibles à une procédure étrangère.



Retrait des modèles

Le fournisseur retire des versions à son rythme, ce qui rompt votre reproductibilité.



Dépendance par confort

Les outils propriétaires facilitent l'entrée et compliquent la sortie. Préférez l'ouvert.



Usage des données

Exigez par contrat : pas d'entraînement sur vos données, durée des journaux, sous-traitants.



Risque de change

Des factures en dollars augmentent si la monnaie locale se déprécie en cours d'année.



À RETENIR Obtenez des réponses écrites sur l'accès légal et l'usage des données avant le pilote, pas avant le renouvellement. Un juriste coûte moins cher qu'un incident.

Options d'hébergement pour les instituts africains

La capacité nationale progresse mais reste concentrée — choisissez en connaissance de cause



Salle serveurs de l'institut

Contrôle total ; limité par l'énergie, le refroidissement et le manque d'ingénieurs.



Centre de données gouvernemental

Cadre public et exploitation mutualisée ; vérifier la capacité et les GPU disponibles.



Hébergeur commercial national

Colocation ou cloud local ; en croissance dans les grands pôles, très variable selon le pays.



Région cloud à l'étranger

Surtout en Afrique du Sud ; le transfert transfrontalier exige une base légale claire.

QUESTIONS À POSER À TOUT HÉBERGEUR

- ? Où sont physiquement les données et sauvegardes ?
- ? Quel droit national régit l'accès à ces données ?
- ? Quelle autonomie électrique et quelle disponibilité ?
- ? Des GPU sont-ils disponibles, et sous quel délai ?
- ? Comment récupérer nos données si nous partons ?
- ? Notre loi statistique autorise-t-elle ce lieu ?
- ? Qui paie, et dans quelle monnaie ?



CONTEXTE

46 % des 211 centres de données opérationnels d'Afrique se trouvent dans quatre pays : Afrique du Sud, Kenya, Nigeria et Égypte.

Sources : étude Heirs Technologies (sept. 2025), via Agence Ecofin ; ADCA, Data Centres in Africa 2026 ; presse spécialisée sur la région cloud d'Oracle au Kenya (2026).

Le modèle hybride vers lequel convergent les instituts

Trois niveaux de traitement, un plan de contrôle commun. Ce sont les données qui choisissent le niveau



Faire ou acheter, composant par composant

Règle : développez ce qui incarne votre méthodologie ; adoptez la plomberie générique

COMPOSANT	CHOIX PAR DÉFAUT	POURQUOI
Modèles de fondation	ADOPTER	Aucun institut n'a de raison de pré-entraîner. Choisir entre ouvert et propriétaire.
Classifieurs et codeurs métier	DÉVELOPPER	Ils incarnent vos nomenclatures, règles et historique. Personne d'autre n'a ces données.
Plateforme de données et catalogue	ADOPTER	Des solutions libres et commerciales matures existent. Préférer les formats ouverts.
Orchestration et ordonnancement	ADOPTER	Airflow, Argo, Kubeflow et équivalents sont banalisés. N'écrivez pas le vôtre.
Index vectoriel et recherche	ADOPTER	Banalisé et évolutif ; gardez la chaîne de vectorisation dans votre propre code.
Banc d'évaluation	DÉVELOPPER	Votre jeu de référence, vos classes rares, la performance humaine. Aucun test vendeur ne le remplace.
Outils d'annotation	ADOPTER	Achetez l'outil ; gardez la maîtrise des consignes, de l'arbitrage et des données.
Passerelle IA et contrôles de confidentialité	ASSEMBLER	Règles de masquage et listes autorisées vous sont propres. Assemblez, mais maîtrisez la logique.



À RETENIR Tout ce qui est « à développer » garderait sa valeur si tous les fournisseurs d'IA disparaissaient demain. C'est le critère.

Modèles à poids ouverts ou propriétaires

Pas une question philosophique — un choix de portefeuille guidé par la classification et la reproductibilité

	 POIDS OUVERTS, AUTO-HÉBERGÉ	 PROPRIÉTAIRE, VIA API GÉRÉE
Confidentialité	S'exécute dans votre périmètre ; les données ne sortent pas	Les données sortent, sauf déploiement dédié sous contrat
Reproductibilité	Les poids peuvent être figés et archivés sans limite	Les versions sont retirées au rythme du fournisseur
Capacités	Solides et en progrès ; souvent suffisantes pour extraire et coder	Souvent en tête sur le raisonnement complexe et les langues
Profil de coût	Fixe : matériel et personnel, quel que soit le volume	Variable : au jeton, proportionnel à l'usage
Exploitation	Vous gérez service, montée en charge, correctifs, suivi	Le fournisseur exploite ; vous gérez contrat, quotas, coûts
Auditabilité	Inspection complète des poids, requêtes et traitements	Tests de comportement seulement ; fonctionnement opaque
Dépendance	Faible — formats portables, couche de service remplaçable	Moyenne à forte, surtout avec les outils du fournisseur



À RETENIR Gérez un portefeuille : poids ouverts pour le confidentiel et le reproductible, API gérées pour l'exploration. Faites tout passer par une passerelle unique pour pouvoir changer.

Exercice : où ce traitement doit-il s'exécuter ?

Discutez chaque cas deux minutes, puis comparez avec la réponse proposée

1

Coder 2 millions de réponses « profession » du recensement contenant encore noms et adresses

Réponse proposée : T3 · Sur site, modèle auto-hébergé

Microdonnées identifiantes : la classification tranche avant le coût.

2

Traduire un bulletin statistique publié en anglais, arabe et kiswahili

Réponse proposée : T0 · API gérée via la passerelle

Contenu public ; garder une relecture humaine de la qualité linguistique.

3

Un assistant qui répond aux questions du personnel sur les manuels internes

Réponse proposée : T1 · Cloud privé sous contrat

Non public sans microdonnées ; la recherche filtre selon les droits.

4

Entraîner pendant deux semaines un classifieur de cultures sur des images satellites publiques

Réponse proposée : Modèle C · Cloud dédié, ponctuel

Données publiques, charge courte et intense : louer, ne pas acheter.

04

Gouvernance & confidentialité

Comment protéger le secret statistique quand l'IA ouvre de nouvelles voies de fuite ?

DANS CETTE SECTION

- › Nouvelles voies de divulgation
- › Le cadre juridique
- › Tableau de classification
- › Contrôles techniques
- › Gouvernance des modèles
- › L'IA dans le GSBPM
- › Cinq scénarios d'échec



Sept nouvelles voies de fuite des données

Des voies de divulgation que vos contrôles actuels ne couvrent probablement pas



IA fantôme

Des agents collent des microdonnées dans des chatbots publics personnels. L'incident le plus probable.



Mémorisation

Un modèle affiné sur des microdonnées peut restituer des enregistrements. Classifiez les poids comme les données.



Index vectoriels

Un index est une seconde copie des documents, souvent hors des contrôles d'accès d'origine.



Fuite par les sorties

Un résumé généré peut révéler une petite cellule que le secret aurait masquée.



Journaux et télémétrie

Les requêtes et réponses stockées forment une troisième copie. Fixez leur durée de conservation.



Sous-traitants

Votre contrat lie un fournisseur ; le traitement peut tourner chez un autre.



Contexte d'inférence

Sans filtrage par utilisateur, la recherche peut montrer un contenu non autorisé.



À RETENIR

Une note de service ne règle pas l'IA fantôme. Un outil autorisé assez bon pour rendre l'outil non autorisé inutile, si.

Le cadre juridique : mondial, africain, national

Les obligations varient selon les pays, mais la logique d'analyse reste la même

	STATISTIQUE	DONNÉES & IA	SÉCURITÉ & EXPLOITATION
Mondial	Principes fondamentaux de la statistique officielle (ONU) — principe 6 : données individuelles strictement confidentielles	Principes de l'OCDE sur l'IA ; Recommandation de l'UNESCO sur l'éthique de l'IA ; règlement (UE) 2024/1689 comme modèle	Normes internationales de sécurité (ex. ISO/IEC 27001) ; bonnes pratiques d'archivage
Africain	Charte africaine de la statistique ; SHaSA 2 — harmonisation et indépendance professionnelle	Convention de Malabo (en vigueur en juin 2023) ; Cadre de politique des données de l'UA ; Stratégie continentale sur l'IA (juillet 2024)	Volet cybersécurité de Malabo ; cadres régionaux (CER), ex. acte additionnel de la CEDEAO sur les données
National	Loi statistique : mandat, secret statistique, limites sur le lieu et les acteurs du traitement	Loi et autorité de protection des données ; stratégie nationale d'IA le cas échéant	Loi sur la cybersécurité, code des marchés publics, droit des archives



Chronologie : associez le juridique, le délégué à la protection des données et la sécurité dès le premier atelier. Une objection soulevée à la conception coûte un après-midi ; au déploiement, un projet.

Classification des données et infrastructure autorisée

L'outil le plus utile de la gouvernance de l'IA. Rédigez-le, faites-le signer, publiez-le

NIVEAU	DONNÉES	ENVIRONNEMENT	MODÈLES	CONTRÔLES REQUIS
T3	Microdonnées identifiantes ou facilement réidentifiables	Sur site ou zone de recherche sécurisée uniquement	Modèles ouverts auto-hébergés d'une liste approuvée	Pas de réseau sortant · journalisation complète · contrôle des sorties · accès nominatif
T2	Données pseudonymisées ou détaillées non publiques	Cloud souverain ou hébergement dédié	Auto-hébergés, ou gérés mono-client sous contrat	Analyse d'impact · clause de non-entraînement · chiffrement avec clés propres · surveillance des sorties
T1	Documents internes, métadonnées et code	Cloud privé ou public sous accord d'entreprise	Modèles gérés autorisés sous contrat	Clause de non-entraînement · authentification unique · passerelle · durée de conservation
T0	Publications et contenus publics	Tout, y compris API publiques gérées	Tout modèle approuvé	Charte d'utilisation · passage par la passerelle pour coûts et audit



POURQUOI Ce tableau transforme un débat au cas par cas en simple consultation : un analyste qui sait que ses données sont T2 connaît l'environnement, les modèles et les formalités. Révissez-le chaque année.

Des contrôles techniques qui appliquent la politique

Une règle impossible à enfreindre par accident vaut mieux qu'une règle que tout le monde a lue



Contrôle des flux sortants

Aucune route vers internet depuis la zone sécurisée.



Identités et rôles

Authentification unique et forte, rôles liés aux niveaux.



Chiffrement et clés

Au repos et en transit ; clés détenues par l'institut si requis.

L'INVESTISSEMENT LE PLUS RENTABLE



La passerelle IA interne

Un point de passage audité pour chaque appel

- ✓ Modèles autorisés par niveau
- ✓ Masquage et contrôle des requêtes
- ✓ Journalisation inviolable
- ✓ Quotas et plafonds budgétaires
- ✓ Coût par code projet
- ✓ Changer de modèle par paramétrage



Recherche filtrée par droits

Appliquer les droits à chaque requête, pas seulement à l'indexation.



Gestion des secrets

Aucun mot de passe dans le code ; jetons à courte durée.



Conservation et suppression

Règles explicites pour requêtes, journaux, index et instantanés.



À RETENIR

Construisez la passerelle avant le premier usage en production, pas après le cinquième. L'ajouter après coup coûte dix fois plus.


Gouvernance des modèles : le registre et la validation

Tout modèle derrière un chiffre publié a un responsable, une version, une validation et une date d'expiration



L'IA dans le processus de production statistique

Positionnée sur les phases du GSBPM, avec le niveau de supervision humaine requis



Cinq scénarios d'échec réalistes

Chacun s'est produit quelque part. Chacun a une parade précise et abordable

SCÉNARIO	CONSÉQUENCE	LE CONTRÔLE QUI L'ÉVITE
 Un analyste colle des microdonnées identifiantes dans un chatbot public	Violation à notifier ; perte de confiance des répondants ; exposition publique	Un outil interne autorisé, un contrôle des flux sortants et une règle courte réellement lue
 Un fournisseur met à jour un modèle en silence ; le codage change en cours de série	La série publiée change pour des raisons non documentées	Figurer les versions ; retester avant tout changement ; auto-héberger sur le chemin critique
 Un classifieur de métiers se dégrade avec l'évolution du marché du travail	Érosion lente de la qualité, découverte par un utilisateur externe	Suivi de la dérive, revalidation planifiée et résultats par catégorie
 Un traitement non surveillé tourne tout le week-end sur une API payante	Un dépassement qui entame la crédibilité auprès des finances	Plafonds stricts dans la passerelle, quotas par équipe, alertes sur le rythme de dépense
 Un pilote réussi ne peut pas passer en production : pas de plateforme	Pilotes à perpétuité : enthousiasme épuisé, rien en production après deux ans	Plateforme avant le deuxième cas d'usage ; chemin de promotion exigé dès le départ



À RETENIR

l'incident.

Aucun de ces contrôles n'est coûteux — et tous coûtent bien moins avant la première mise en production qu'après

SECTION 05

05

Coûts & budget

Où va réellement l'argent sur cinq ans ?

DANS CETTE SECTION

- › La structure des coûts
- › Répartition sur cinq ans
- › Trois scénarios de coût total
- › Seuils de rentabilité
- › Où les budgets dérapent
- › Maîtrise des coûts (FinOps)
- › Construire la demande



La structure complète des coûts

Le matériel et les frais d'API sont les coûts visibles. Ce sont rarement les plus importants



Personnel

01

Salaires, charges, recrutement et rotation. Généralement le premier poste, de loin.



Calcul et stockage

02

Achat de matériel ou consommation cloud, stockage, sauvegarde, transferts.



Données et annotation

03

Codage, consignes, arbitrage et entretien des jeux de référence.



Logiciels et licences

04

Plateforme, MLOps, annotation, sécurité, supervision — et renouvellements.



Locaux techniques

05

Électricité, secours, climatisation, espace. Sur site uniquement ; souvent un autre budget.



Gouvernance et assurance

06

Revue juridique, analyses d'impact, tests de sécurité, audit, documentation.



Conduite du changement

07

Programme, formation, temps des agents et communication.



Exploitation et maintenance

08

Prévoir 15 à 25 % du coût de construction chaque année. Le poste le plus souvent oublié.




À RETENIR Si un budget IA est surtout du matériel, ce n'est pas le budget d'une capacité — c'est celui d'un équipement que personne n'est payé pour exploiter.

Où va l'argent sur cinq ans

Répartition illustrative pour un institut de taille moyenne avec deux ou trois usages en production

Part du coût total sur cinq ans (%)



Le personnel domine

Près de la moitié du coût est salariale : les effectifs pèsent plus que l'hébergement.



Le calcul est minoritaire

Matériel et locaux dépassent rarement un quart du total.



La gouvernance a un coût

L'assurance est un effort réel et récurrent. Budgétisez-la, sinon elle est prise sur la production.




L'annotation est un investissement

Le jeu de référence survit à tous les modèles entraînés dessus.

Modèle de planification illustratif fondé sur l'expérience du secteur public — pas des mesures. Remplacez par vos propres coûts unitaires.

Coût total sur cinq ans : trois scénarios

Même institut, mêmes deux usages, trois choix de déploiement (illustratif, en milliers d'unités)



3 600

Scénario A

Résultats rapides ; le coût suit directement l'usage

4 320

Scénario B

Capacité propre pour T3-T2, capacité ponctuelle pour le reste

5 450

Scénario C


Contrôle total ; rentable seulement à forte utilisation

L'hébergement fait varier environ un tiers du total. Les effectifs, davantage.

Modèle illustratif : 2 usages, 6–8 ETP, un nœud à 4 GPU en B, une petite grappe en C. Pas un devis — à reconstruire avec vos coûts.

Comment la réponse change avec le volume

Les trois mêmes scénarios à charge croissante. Les points de croisement sont les vrais points de décision



Faible volume : A gagne

Pilotes et charges modestes coûtent moins cher en service géré.

Volume moyen : B gagne

Une charge stable justifie une base propre et du ponctuel en complément.

Fort volume : C gagne

Seule une forte utilisation soutenue rentabilise un parc complet.

La classification prime

Pour des données T3, l'option A n'a jamais été possible, quel que soit le volume.

Modèle illustratif. La forme — une capacité propre plate croisant une consommation croissante — est robuste ; les croisements dépendent de vos coûts.

Sept endroits où le budget dérape

Chacun a déjà interrompu, retardé ou mis en difficulté un programme public d'IA



Transferts de données

Des allers-retours répétés entre niveaux : non plafonnés et invisibles jusqu'à la facture.



GPU inactifs

Machines de développement allumées la nuit et le week-end. Le plus fréquent, le plus simple à corriger.



Réindexation

Chaque mise à jour des documents revectorise tout ; le coût croît en silence.



Annotation sous-estimée

Consignes, arbitrage et recodage après révision de nomenclature sont un vrai travail.



Assurance « gratuite »

Sécurité, juridique et revue méthodologique se paient de toute façon en temps.



Pas de budget d'exploitation

Le projet se clôt ; la dépendance reste et se dégrade jusqu'à l'échec public.



Départs

Perdre le seul ingénieur qui connaît la chaîne coûte des mois — voire la capacité.



À RETENIR

Inscrivez les sept au dossier comme risques nommés avec des responsables. Un risque documenté est un coût maîtrisé.

Des contrôles de coûts adaptés au secteur public

L'imputation d'abord : on ne gère pas ce qu'on ne peut attribuer à une équipe et à un objectif



GARDE-FOUS

1

Imputer chaque appel

Marquer chaque requête d'un code projet via la passerelle.

2

Plafonner, pas seulement alerter

Des plafonds qui bloquent — un tableau de bord n'arrête pas un week-end.

3

Arrêt automatique

Les machines inactives s'arrêtent selon un horaire, sauf prolongation.

4

Quotas et seuils

Quotas par équipe, avec circuit d'approbation au-delà d'un seuil.



EFFICACITÉ

5

Le plus petit modèle suffisant

Commencer petit ou auto-hébergé ; monter en gamme si les tests l'exigent.

6

Cache et traitement par lots

Réutiliser les résultats ; le traitement par lots coûte moins cher.

7

S'engager une fois la charge connue

Les réservations font économiser — après un historique réel.

8

Suivre coûts et avancement ensemble

Une réunion mensuelle, mêmes personnes, pour l'avancement et la dépense.

Construire la demande budgétaire

Une demande qu'un comité peut approuver — et qu'un auditeur pourra défendre ensuite



À FAIRE

Ce que contient une demande défendable

- ✓ Exprimer les bénéfices en résultats statistiques : délais, qualité
- ✓ Comparer le coût par enregistrement avant et après, avec preuves
- ✓ Demander une plateforme à financement récurrent, pas un projet
- ✓ Phaser : pilote → plateforme → extension, avec décisions
- ✓ Inclure exploitation, renouvellement et fin de vie
- ✓ Annoncer d'emblée la position sur la confidentialité
- ✓ Nommer les inconnues ; proposer un plafond et une date de revue



À ÉVITER

Ce qui fait renvoyer une demande

- ✗ Mettre en avant la technologie ou une architecture de modèle
- ✗ Promettre des suppressions de postes — promettre un redéploiement
- ✗ Présenter une précision sans référence humaine
- ✗ Demander du matériel avant un usage testé et des données annotées
- ✗ Noyer l'effort de gouvernance dans une ligne de production
- ✗ Citer des tests de fournisseurs comme preuve sur vos données



À RETENIR

La phrase la plus forte d'un dossier IA est une comparaison mesurée avec le processus actuel, sur vos propres données. Le reste n'est qu'affirmation.

06

Équipes & feuille de route

De qui avons-nous besoin — et dans quel ordre construire ?

DANS CETTE SECTION

- › L'équipe nécessaire
- › La réalité du recrutement
- › Ce que chacun doit apprendre
- › Modèle de maturité
- › Feuille de route sur 24 mois
- › Erreurs classiques
- › Liste de vérification
- › Dix messages clés



Indicatif pour un institut moyen avec deux ou trois usages en production. Le message : la rareté, pas l'effectif

Indicatif pour un institut moyen avec deux ou trois usages en production. Le message : la rareté, pas l'effectif

À RETENIR La plupart des instituts recrutent trop de data scientists et pas assez d'ingénieurs de données et de plateforme. Résultat : d'excellents notebooks qui n'arrivent jamais en production.

La réalité du recrutement dans un institut public

Vous ne gagnerez pas sur les salaires. Vous pouvez gagner sur presque tout le reste



Ce que vous ne pouvez pas offrir

Les salaires du privé pour des ingénieurs IA et plateforme expérimentés. Acceptez-le et organisez-vous en conséquence.



Ce que vous pouvez vraiment offrir

Une mission d'intérêt public, des données exceptionnelles, la rigueur, la publication, des budgets de formation, la stabilité et des horaires prévisibles.



La dépendance à éviter : externaliser totalement la plateforme rend l'institut incapable d'évaluer, d'exploiter ou de quitter ses propres systèmes. Achetez des outils et de l'aide — jamais la compréhension de la façon dont vos statistiques sont produites.

CINQ STRATÉGIES QUI FONCTIONNENT



Former en interne

Faire des méthodologues des praticiens de l'IA — ils connaissent déjà les données.



S'associer plutôt qu'acheter

Universités, centres de formation, instituts pairs et partenaires au développement.



Mutualiser entre administrations

Une équipe nationale de plateforme est plus facile à pourvoir qu'une par agence.



Imposer le transfert aux prestataires

Faire du transfert de compétences un livrable, vérifié avant le paiement final.



Créer une filière technique

Des grades techniques seniors, pour progresser sans passer au management.

Ce que chaque groupe doit apprendre

Trois parcours différents. L'écueil : une même introduction générique pour tous



Statisticiens et méthodologues

- ✓ Apprentissage supervisé et différences avec l'inférence par modèle
- ✓ Évaluation : précision, rappel, calibration, seuils
- ✓ Python ou R, gestion de versions, environnements reproductibles
- ✓ RAG et prompts, assez pour juger de la fiabilité
- ✓ Biais, dérive et dégradation silencieuse des modèles



Informatique, plateforme et sécurité

- ✓ Conteneurs et orchestration (Kubernetes ou Slurm)
- ✓ Exploitation GPU : pilotes, ordonnancement, partage, suivi
- ✓ Service de modèles, passerelles, index vectoriels
- ✓ Intégration continue pour modèles, données et prompts
- ✓ Sécurité IA : injection de requête, fuites, chaîne d'approvisionnement



Direction et contrôle


- ✓ Ce que l'IA sait et ne sait pas faire, sans discours commercial
- ✓ Lire un rapport d'évaluation
- ✓ Les facteurs de coût qui comptent vraiment
- ✓ Obligations : confidentialité, données, transparence
- ✓ Quand et comment arrêter un projet



Le format compte plus que le contenu. Les cours en ligne génériques sont peu suivis et peu appliqués. Ce qui marche : un apprentissage lié à un vrai cas d'usage interne, avec du temps protégé, un mentor et un livrable utile.

Un modèle de maturité en cinq niveaux


Soyez lucide sur le point de départ. La plupart des instituts se situent entre les niveaux 1 et 2



À RETENIR Évaluez-vous sur votre maillon le plus faible. Le passage du niveau 2 au niveau 3 est le plus coûteux : c'est là qu'une culture du pilote devient une discipline d'exploitation.

Une feuille de route de 24 mois avec des jalons

Ne commencez une phase que lorsque le jalon précédent est réellement atteint



À RETENIR

La phase 1 ressemble à de l'infrastructure sans rien à montrer. Financez-la quand même — toutes les suivantes en dépendent. Durées indicatives.

Huit erreurs classiques

Des façons reconnaissables dont un programme d'IA bien intentionné échoue dans un institut



Le matériel avant l'usage

Des GPU achetés sur la foi d'une stratégie, inutilisés 18 mois en attendant la plateforme.



Le plus difficile d'abord

Des microdonnées confidentielles pour une statistique phare comme premier essai.



Stratégie sans plateforme

Un beau document et un comité de pilotage — mais nulle part où construire.



Le héros solitaire

Une seule personne comprend toute la chaîne. Sa démission devient une panne.



Pilotes à perpétuité

Preuve de concept après preuve de concept, applaudies mais jamais promues.



Gouvernance après coup

Des contrôles conçus une fois le système en service restent consultatifs — et coûtent plus.



La sortie prise pour vérité

Des réponses générées entrent dans un produit sans contrôle déterministe ni humain.



Viser la perfection

Rejeter un système meilleur que le manuel, dont l'erreur n'a jamais été mesurée.



À RETENIR

Sept de ces huit erreurs sont des erreurs d'ordonnancement, pas de technologie. L'ordre des travaux compte plus que le choix des outils.

Liste de vérification

Dix questions fermées. Moins de sept « oui » : vous n'êtes pas prêt à dépasser le stade du pilote

1

Un tableau de classification est approuvé et accessible au personnel

6

Chaque modèle en production a un responsable et une date de revue

2

Une plateforme de données gouvernée avec catalogue et traçabilité existe

7

Les coûts sont imputés et des plafonds stricts sont appliqués

3

Un jeu de test figé avec référence humaine mesurée existe

8

Juridique, DPD et sécurité ont été associés dès la conception

4

Chaque appel de modèle passe par une passerelle audité

9

Chaque usage en production a un plan de repli testé

5

DEV, TEST et PROD sont séparés, avec des approbateurs nommés

10

L'exploitation et le renouvellement sont financés au-delà du projet

ÉTENDRE SI

 ≥ 7

réponses « oui » sur 10

Neuf sur dix demandent du temps et de l'attention, pas de l'argent. Aucune n'exige de GPU supplémentaire.

DPD : délégué à la protection des données.

Dix messages à retenir

Si vous ne deviez garder qu'une page de cette présentation

01

L'IA dans un institut est une plateforme soumise à des obligations légales, pas un projet avec un modèle.

02

Le modèle est une petite partie du système. Tout le reste constitue le travail — et le coût.

03

La vraie contrainte : les données annotées et une plateforme gouvernée, pas les GPU.

04

La classification décide où s'exécutent les traitements. Le coût choisit parmi les options permises.

05

Rédigez le tableau de classification, faites-le signer et publiez-le.

06

Construisez une passerelle IA audité avant le premier usage en production.

07

La reproductibilité est obligatoire : figez les modèles génératifs ou écarterez-les du chemin critique.

08

Le personnel pèse environ la moitié du coût sur cinq ans : il compte plus que l'hébergement.

09

Comparez au processus humain actuel, y compris son taux d'erreur, et publiez-le.

10

Procédez dans l'ordre : fondations, plateforme, un usage, puis extension.

Sources et lectures complémentaires

Normes, cadres et données cités dans cette présentation



Cadres de la statistique officielle

- Principes fondamentaux de la statistique officielle (ONU, rés. 68/261, 2014) — principe 6
- CEE-ONU, HLG-MOS : GSBPM, GAMSO, GSIM et travaux sur l'apprentissage automatique
- Charte africaine de la statistique (UA, 2009)
- Stratégie pour l'harmonisation des statistiques en Afrique (SHaSA 2)
- Code de bonnes pratiques de la statistique européenne
- Statistique Canada, Cadre pour des processus d'apprentissage automatique responsables



Droit, politiques et technique

- Convention de l'UA sur la cybersécurité et la protection des données à caractère personnel (Malabo, 2014 ; en vigueur le 8 juin 2023)
- Cadre de politique des données de l'UA ; Stratégie continentale de l'UA sur l'IA (juillet 2024)
- Règlement (UE) 2024/1689 sur l'intelligence artificielle
- Principes de l'OCDE sur l'IA ; Recommandation de l'UNESCO sur l'éthique de l'IA (2021)
- D. Sculley et al., « Hidden Technical Debt in Machine Learning Systems », NeurIPS 2015



Données sur le contexte africain

- AIE, Financing Electricity Access in Africa (2025)
- Africa Data Centres Association, Data Centres in Africa 2026: The Economic Report
- BCG, Advancing Africa's AI and Digital Economy (2026)
- Heirs Technologies, Africa's Digital Leap (sept. 2025), repris par l'Agence Ecofin
- Groupe de la Banque mondiale et BAD, Mission 300 (2024)
- Conseil exécutif de l'UA, 45e session ordinaire, Accra (juillet 2024)