

NOTE D'INFORMATION · INTELLIGENCE ARTIFICIELLE

Génération augmentée par récupération (RAG)

Ancrer les grands modèles de langage dans des connaissances réelles et vérifiables

Fondements · Preuves · Évolution · Production



Six parties, du concept à la production

01



Fondements

Pourquoi le RAG, sa définition, ses usages

02



Fonctionnement

Indexation, découpage, embeddings, récupération, génération

03



Preuves

Résultats publiés qui chiffrent les gains

04



Évolution du RAG

Générations, axes de progrès, paradigmes

05



Techniques avancées

Boîte à outils ; RAG, fine-tuning ou contexte long

06



Production

Évaluation, sécurité, outils, points de défaillance

SECTION

01

Fondements

Pourquoi les modèles de langage ont-ils besoin d'une mémoire externe ?



Pourquoi un LLM seul ne suffit pas

**Un LLM raisonne
brillamment...**

**...mais c'est une
bibliothèque peu fiable.**

Ses connaissances sont stockées implicitement dans ses poids (mémoire paramétrique) : figées, opaques et impossibles à citer.



Date de coupure

Tout ce qui s'est passé après l'entraînement est inconnu du modèle.



Hallucinations

Faute de connaissance, le modèle peut produire des réponses fluides mais infondées.



Aucune donnée privée

Documents internes, wikis, tickets et bases de données n'ont jamais servi à l'entraînement.



Aucune traçabilité

Les réponses n'ont pas de sources : impossible de les vérifier.

Qu'est-ce que la génération augmentée (RAG) ?

RAG récupère, au moment de la question, les passages pertinents d'une source de connaissances externe et les insère dans le prompt : le LLM génère alors une réponse **fondée sur ces éléments**.



Examen à livre fermé

LLM seul

Répond de mémoire uniquement (poids du modèle). Peut être dépassé ou inventé.

Mémoire paramétrique seule



Examen à livre ouvert

LLM + RAG

Consulte d'abord les bonnes pages, puis répond — et peut les citer.

Mémoire paramétrique + externe

ORIGINE

Lewis et al., 2020

« Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks »
— NeurIPS 2020 (Facebook AI Research, UCL, NYU).

Combine une mémoire paramétrique (BART) et une mémoire non paramétrique (un index DPR sur Wikipédia).

Là où le RAG crée de la valeur



Service client

Des assistants répondent à partir de l'aide en ligne, des politiques et des tickets, avec liens vers les sources.



Savoir de l'entreprise

Une seule couche de questions-réponses sur wikis, intranets, disques et messageries.



Juridique & conformité

Contrats, règlements et dossiers ; chaque affirmation renvoie à une clause.



Santé & recherche

Réponses fondées sur les recommandations et la littérature, pas sur la mémoire du modèle.



Génie logiciel

Les assistants de code récupèrent fichiers, API et documentation interne utiles.



Finance & analyse

Interroger rapports, publications et études de marché qui changent chaque trimestre.

Point commun : un corpus volumineux, évolutif ou confidentiel + des réponses que l'on doit pouvoir vérifier.

SECTION


02

Fonctionnement


Que se passe-t-il entre la question et la réponse ?



Deux chaînes : indexation et interrogation



Le RAG en action : une question de bout en bout



Exemple illustratif — vecteurs, scores et documents simplifiés.


Transformer les documents en savoir interrogeable



Règle clé : utiliser le même modèle d'embedding pour les documents et les requêtes — sinon les vecteurs ne sont pas comparables.

Le choix de conception le plus sous-estimé

Fragments de taille fixe avec chevauchement



Le chevauchement préserve les phrases situées à cheval sur deux fragments.

Stratégies courantes

- 1 Taille fixe + chevauchement**
Simple et prévisible ; peut couper une idée en pleine phrase.
- 2 Découpage récursif**
Coupe par paragraphes, puis phrases, puis mots, jusqu'à la bonne taille.
- 3 Découpage sémantique**
Nouveau fragment là où la similarité entre phrases chute.
- 4 Selon la structure**
Suit les titres, sections, tableaux, blocs de code ou la structure Markdown.

Trop petits


Correspondance précise, mais contexte perdu.

Trop grands

Contexte riche, mais vecteurs dilués et bruités.

Embeddings : chercher par le sens, pas par les mots

Espace d'embedding (projection 2D, illustrative)



Aucun mot commun avec « remboursement », et pourtant son vecteur tombe près de ces passages.

Mesure de similarité

$$\cos(\mathbf{q}, \mathbf{d}) = (\mathbf{q} \cdot \mathbf{d}) / (\|\mathbf{q}\| \|\mathbf{d}\|)$$

Score proche de 1 = même sens. Produit scalaire et distance euclidienne sont aussi courants.

Index de plus proches voisins approchés (ANN)

HNSW

Graphe de proximité multicouche ; rapide, bon rappel

IVF

Regroupe les vecteurs ; ne fouille que les groupes proches

PQ

Comprime les vecteurs pour réduire la mémoire

L'ANN sacrifie un peu d'exactitude pour chercher en millisecondes parmi des millions de vecteurs.

Creuse, dense, hybride — puis reclassement



Creuse · BM25

Correspondance de mots-clés pondérée par fréquence.

Idéale pour termes exacts, codes produits, noms, mots rares.



Dense · Embeddings

Similarité vectorielle sur le sens.

Idéale pour paraphrases, synonymes, questions en langage naturel.



Hybride

Fusionne les deux classements (Reciprocal Rank Fusion).

$$RRF(d) = \sum 1 / (k + rank_i(d))$$

RECLASSEMENT

Recherche en deux temps : d'abord large et rapide, puis notation précise.

Top 50 / 100 candidats

Bi-encodeur ou BM25 · rapide



Renotation cross-encoder

Lit requête + passage ensemble · précis



Top 3 à 10

Envoyés au LLM

Construire le prompt augmenté

SYSTÈME

Réponds UNIQUEMENT à partir du contexte ci-dessous. Cite les sources [n]. Si la réponse n'y figure pas, dis que tu ne sais pas.

CONTEXTE

[1] Politique de remboursement, §2 – Commandes en ligne remboursées sous 14 jours...
[2] FAQ – Les retours se lancent depuis votre compte...

QUESTION

Quel est le délai de remboursement des commandes en ligne ?

Modèle illustratif



Exiger des citations

Chaque affirmation renvoie à un fragment vérifiable.



Autoriser l'abstention

« Je ne sais pas » vaut mieux qu'une hallucination assurée.



L'ordre compte

Placer les meilleurs éléments en tête : les modèles exploitent mal le milieu des longs contextes (voir Preuves).



Contexte ciblé

Peu de fragments pertinents valent mieux que beaucoup de bruit.

SECTION

03


Preuves

La récupération améliore-t-elle vraiment les réponses ?



La récupération bat la simple taille du modèle

Natural Questions — correspondance exacte (%)



626 M


paramètres entraînables pour RAG — contre 11 Md pour T5-11B, qu'il surpasse.

42,7 % vs 7,1 %

Génération Jeopardy : part des jugements humains trouvant RAG (vs BART) plus factuel.

Source : Lewis et al., NeurIPS 2020 (tableaux 1 et 4). SSM = pré-entraînement par masquage de segments saillants.

« Lost in the Middle » : la position compte



Source : Liu et al., « Lost in the Middle », TACL 2024 (tableau 6), NaturalQuestions-Open.

-22 pts

de 75,8 % (réponse en tête) à 53,8 %
(réponse au milieu).


Sous la référence

Au milieu, l'exactitude est pire que sans
aucun document (56,1 %).

Pour le RAG : reclasser pour mettre les
meilleurs éléments en tête, et envoyer
moins de fragments, mais meilleurs.

Contextual Retrieval : restaurer le contexte perdu

Taux d'échec de récupération top-20 (%) — plus bas = mieux



Source : Anthropic, « Introducing Contextual Retrieval », septembre 2024.

Génération augmentée par récupération (RAG)

Le problème

Isolé, un fragment perd son contexte :

Avant : « Le chiffre d'affaires a progressé de 3 % sur le trimestre. »

Après : « [ACME Corp, rapport T2] Le chiffre d'affaires a progressé de 3 %... »

La solution

Un LLM rédige un court contexte (≈ 50–100 tokens) situant chaque fragment dans son document, ajouté avant l'embedding et l'indexation BM25.

–49 % d'échecs · **–67 %** avec reclassement

SECTION

04


Évolution du RAG

Comment le concept a-t-il mûri depuis 2017 ?



Comment le concept de RAG a progressé

Plus adaptatif · plus structuré · plus autonome



Cinq axes de progrès

Axe	RAG initial (2020)	Pratique établie	Frontière
Quand chercher	Une fois, avant de générer	Plusieurs fois, en alternance avec le raisonnement (IRCoT, FLARE)	Le modèle décide si et quand (Self-RAG, Adaptive-RAG)
Quoi récupérer	Passages de taille fixe	Fragments hybrides, reclassés, contextualisés	Graphes, arbres de résumés, images de pages (GraphRAG, RAPTOR, ColPali)
Apprentissage de la recherche	Récupérateur entraîné avec un petit générateur	LLM figé ; récupérateur standard ou ajusté via le LLM (REPLUG)	LLM entraîné par renforcement à chercher (Search-R1)
Qui pilote le flux	Chaîne linéaire fixe	Chaînes modulaires avec routage	Agents qui planifient une recherche en plusieurs étapes
Contrôle qualité	Classement seul	Reclassement, citations, évaluation automatisée (RAGAS)	Autocritique et récupération corrective (Self-RAG, CRAG)

Sens du progrès



Du RAG naïf au RAG avancé, puis modulaire




Cumulatif, pas un remplacement : chaque paradigme s'appuie sur les composants du précédent.

Cadre issu de Gao et al., « Retrieval-Augmented Generation for Large Language Models: A Survey », 2023.

Génération augmentée par récupération (RAG)

D'une chaîne unique à une boucle de raisonnement

AVANT · UN SEUL PASSAGE




Recherche ratée = réponse ratée.

IRCoT *Trivedi et al., 2023*

Alterne recherche et étapes de raisonnement.

AUJOURD'HUI · BOUCLE AGENTIQUE



FLARE *Jiang et al., 2023*


Cherche quand la phrase suivante contient des tokens peu sûrs.

Search-R1 *Jin et al., 2025*

LLM entraîné par RL à lancer plusieurs recherches en raisonnant.

Les longs contextes ont changé le rôle du RAG

Fenêtre de contexte maximale (tokens, échelle log)



Chiffres annoncés par chaque fournisseur.

Génération augmentée par récupération (RAG)

Avant : le RAG était un palliatif — les modèles ne lisaient que quelques pages à la fois.

Constat : les modèles à long contexte peuvent battre le RAG en moyenne, mais le RAG coûte bien moins cher. Self-Route (Li et al., 2024) tente d'abord le RAG et ne passe au contexte complet qu'en cas de besoin.

Aujourd'hui : le RAG est la couche du coût, de la fraîcheur, du contrôle d'accès et de la précision.

SECTION

05

Techniques avancées

Quelles techniques améliorent encore la qualité ?



Techniques RAG avancées en pratique



Gao et al., 2022

HyDE

Le LLM rédige une réponse hypothétique dont l'embedding sert à chercher.



Transformation de requête

Reformulation multiple

Reformule ou scinde la question en sous-requêtes, puis fusionne.



Document parent

Récupération petit-à-grand

Cherche sur de petits fragments, renvoie la section parente.



Asai et al., 2023

Self-RAG

Le modèle décide quand chercher et critique ses sorties via des tokens de réflexion.



Yan et al., 2024

Corrective RAG (CRAG)

Un évaluateur note les documents et déclenche des corrections (p. ex. recherche web).



Microsoft, 2024

GraphRAG

Construit un graphe de connaissances + résumés pour les questions globales.



Sarathi et al., 2024

RAPTOR

Arbre récursif de résumés groupés pour une recherche multi-niveaux.



Agents + outils

RAG agentique

Un agent planifie, appelle les outils de recherche en boucle et vérifie avant de répondre.



Requête & indexation



Méthodes de recherche



Agentique

RAG, fine-tuning ou contexte long

	RAG	Fine-tuning	Contexte long
Mise à jour du savoir	Réindexer les documents	Réentraîner le modèle	Modifier le prompt
Citation des sources	Native (fragments récupérés)	Non disponible	Possible
Volume de savoir	Des millions de documents	Absorbé dans les poids, imprécis	Limité par la fenêtre de contexte
Coût par requête	Faible — fragments utiles seuls	Faible	Élevé pour les longs contextes
Contrôle d'accès	Filtrage par droits à la recherche	Très difficile	Par requête
Idéal pour	Faits privés et évolutifs	Style, comportement spécialisé	Petits corpus autonomes



Complémentaires, pas exclusifs : fine-tuning = comportement, RAG = savoir, contexte long = petits corpus.

SECTION


06

Production

Comment exploiter le RAG de façon fiable et sûre ?



Mesurer séparément récupération et génération



La « triade RAG » (TruLens)

Métriques RAGAS (Es et al., 2023)

Fidélité: Les affirmations sont-elles étayées par le contexte ?

Pertinence de la réponse: Traite-t-elle bien la question ?

Précision du contexte: Les bons fragments sont-ils en tête ?

Rappel du contexte: Toute l'information utile a-t-elle été récupérée ?

Métriques de récupération

Recall@k · Precision@k · MRR · nDCG

Outils : RAGAS · TruLens · DeepEval · Arize Phoenix

Sécuriser un système RAG



Injection de prompt indirecte

Des instructions cachées dans les documents ingérés sont lues par le LLM comme des ordres.



Empoisonnement du savoir

PoisonedRAG (Zou et al., 2024) : 5 textes forgés par question cible ont atteint ~90 % de réussite dans un corpus de millions de textes.



Fuite de permissions

Les vecteurs n'héritent pas des droits des sources : un utilisateur peut récupérer ce qu'il ne devrait pas voir.



Inversion d'embeddings

Une grande partie du texte d'origine peut être reconstruite depuis son embedding (Morris et al., 2023).




Parades

- Valider et assainir les documents à l'ingestion
- Appliquer les droits à la recherche ; cloisonner les clients
- Traiter le texte récupéré comme des données, jamais comme des ordres
- Limiter les outils et actions que le LLM peut déclencher
- Chiffrer les bases vectorielles ; journaliser et surveiller



OWASP Top 10 for LLM Applications 2025 inclut désormais « LLM08: Vector and Embedding Weaknesses ».

La pile technologique du RAG



Conseil : comparez les modèles d'embedding sur MTEB, puis validez-les sur vos données et vos langues.

Points de défaillance et bonnes pratiques



7 points de défaillance

Barnett et al., 2024

- 1 Contenu absent — la réponse n'est pas dans le corpus
- 2 Bons documents mal classés
- 3 Hors contexte — écarté lors de la consolidation
- 4 Non extrait — présent mais ignoré par le LLM
- 5 Mauvais format
- 6 Niveau de détail inadéquat
- 7 Réponse incomplète



Bonnes pratiques

Ce qui fonctionne durablement

- ✓ Créer un jeu d'évaluation avant d'optimiser
- ✓ Extraction propre, découpage structuré
- ✓ Recherche hybride + reclassement par défaut
- ✓ Filtres de métadonnées et contrôle des droits
- ✓ Prompt d'ancrage avec citations et abstention
- ✓ Surveiller, actualiser l'index, itérer

À RETENIR

La qualité de la récupération plafonne celle des réponses.



Ancré

Le RAG donne aux LLM un savoir à jour, privé et citable, sans réentraînement.



Bien chercher

Découpage, recherche hybride et reclassement font l'essentiel des gains.



Mesuré

Évaluer récupération et génération séparément, sur vos données.



En évolution

Des chaînes fixes vers une récupération adaptative et agentique.

Commencer simple · mesurer · améliorer la récupération.



Références (1/2)

- Chen et al. (2017). Reading Wikipedia to Answer Open-Domain Questions (DrQA). ACL.
- Lee et al. (2019). Latent Retrieval for Weakly Supervised Open Domain QA (ORQA). ACL.
- Guu et al. (2020). REALM: Retrieval-Augmented Language Model Pre-Training. ICML.
- Karpukhin et al. (2020). Dense Passage Retrieval for Open-Domain Question Answering. EMNLP.
- Lewis et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS.
- Izacard & Grave (2021). Leveraging Passage Retrieval with Generative Models (FiD). EACL.
- Borgeaud et al. (2022). Improving Language Models by Retrieving from Trillions of Tokens (RETRO). ICML.
- Izacard et al. (2022). Atlas: Few-shot Learning with Retrieval Augmented Language Models.
- Gao, Ma et al. (2022). Precise Zero-Shot Dense Retrieval without Relevance Labels (HyDE).
- Ram et al. (2023). In-Context Retrieval-Augmented Language Models. TACL.
- Shi et al. (2023). REPLUG: Retrieval-Augmented Black-Box Language Models.
- Trivedi et al. (2023). Interleaving Retrieval with Chain-of-Thought Reasoning (IRCoT). ACL.
- Jiang et al. (2023). Active Retrieval Augmented Generation (FLARE). EMNLP.
- Asai et al. (2023). Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection.
- Liu et al. (2023). Lost in the Middle: How Language Models Use Long Contexts. TACL 2024.
- Gao, Xiong et al. (2023). Retrieval-Augmented Generation for Large Language Models: A Survey.

Références (2/2)



- Es et al. (2023). RAGAS: Automated Evaluation of Retrieval Augmented Generation.
- Morris et al. (2023). Text Embeddings Reveal (Almost) As Much As Text. EMNLP.
- Yan et al. (2024). Corrective Retrieval Augmented Generation (CRAG).
- Jeong et al. (2024). Adaptive-RAG: Adapting Retrieval-Augmented LLMs through Question Complexity. NAACL.
- Edge et al. (2024). From Local to Global: A Graph RAG Approach to Query-Focused Summarization. Microsoft.
- Sarthi et al. (2024). RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval. ICLR.
- Gutiérrez et al. (2024). HippoRAG: Neurobiologically Inspired Long-Term Memory for LLMs. NeurIPS.
- Faysse et al. (2024). ColPali: Efficient Document Retrieval with Vision Language Models.
- Li et al. (2024). Retrieval Augmented Generation or Long-Context LLMs? (Self-Route). EMNLP Industry.
- Barnett et al. (2024). Seven Failure Points When Engineering a RAG System.
- Zou et al. (2024). PoisonedRAG: Knowledge Corruption Attacks to RAG of LLMs.
- Anthropic (2024). Introducing Contextual Retrieval.
- Li et al. (2025). Search-o1: Agentic Search-Enhanced Large Reasoning Models.
- Jin et al. (2025). Search-R1: Training LLMs to Reason and Leverage Search Engines with RL.
- OWASP (2025). Top 10 for LLM Applications — LLM08: Vector and Embedding Weaknesses.
- Cormack et al. (2009). Reciprocal Rank Fusion. SIGIR · Malkov & Yashunin (2018). HNSW. IEEE TPAMI.