

NOTE DE SYNTHÈSE

Agents IA & IA agentique

Des modèles qui répondent aux systèmes qui agissent

Concepts

Architectures

Écosystème

Risques

Data Innovation For Africa (DI4A) - African Development Bank



Ce que nous allons voir

01



Le basculement

Pourquoi l'IA passe de la réponse aux questions à l'exécution de tâches

02



Définitions

Agent ou agentique, et le spectre de l'autonomie

03



Fonctionnement

Anatomie, boucle de l'agent, raisonnement et mémoire

04



Architectures

Outils et protocoles, workflows, systèmes multi-agents

05



État des lieux

Jalons, écosystème, benchmarks et dynamique

06



Bonnes pratiques

Risques, principes de conception et guide de décision

PARTIE

01

Le basculement

Pourquoi l'IA passe-t-elle de la réponse à l'action ?



De la réponse à l'action



Assistant d'IA générative

ex. : un chatbot classique

DÉCLENCHEUR Répond à une requête unique

PROCESSUS Un seul passage : requête → réponse

RÉSULTAT Texte, code ou images à relire

QUI AGIT ? L'humain fait le travail



Système d'IA agentique

ex. : un agent de code ou de recherche

DÉCLENCHEUR Poursuit un objectif

PROCESSUS Boucle : planifier → agir → observer

RÉSULTAT Tâche accomplie, état modifié

QUI AGIT ? L'agent, sous supervision humaine

L'IA générative crée du contenu. L'IA agentique accomplit des tâches.

PARTIE

02

Définitions

Qu'est-ce qu'un agent — et qu'est-ce qui n'en est pas un ?



Qu'est-ce qu'un agent IA ?

IA CLASSIQUE

Tout ce qui peut être vu comme percevant son environnement par des capteurs et agissant sur cet environnement par des effecteurs.

— d'après Russell & Norvig, Artificial Intelligence: A Modern Approach

ÈRE DES LLM

Systèmes où le LLM dirige lui-même son processus et l'usage des outils, en gardant la maîtrise de la façon d'accomplir la tâche.

— d'après Anthropic, « Building Effective Agents » (déc. 2024)

En pratique : un LLM + des outils + une mémoire, en boucle vers un objectif.

PROPRIÉTÉS CLÉS



Autonomie

Décide de l'étape suivante sans script



Orienté objectif

Vise un résultat, pas une simple réponse



Usage d'outils

Appelle des API, exécute du code, cherche, clique



Mémoire

Conserve le contexte pendant et entre les tâches



Adaptation

Observe les résultats et corrige sa trajectoire

Agent ou agentique : une question de degré

AGENT (nom)

Un système qui perçoit, décide et agit pour atteindre un objectif — le « quoi ».

AGENTIQUE (adjectif)

Le degré d'autonomie d'un système. Popularisé par Andrew Ng (2024) pour dépasser le débat oui/non.

LE SPECTRE DE L'AUTONOMIE

Plus d'autonomie = plus de flexibilité... mais plus de coût, de latence et de risque

LLM conversationnel

Répond à partir de son entraînement et de la requête

LLM augmenté

Ajoute recherche, outils et mémoire

Workflow

Étapes LLM sur des chemins prédéfinis

Agent

Le LLM choisit ses étapes et ses outils

Multi-agents

Plusieurs agents coordonnés vers un objectif

Tout ce qui automatise n'est pas un agent



Robot RPA



Assistant IA



Agent IA

FONCTIONNEMENT

Suit des règles et scripts fixes

Répond aux requêtes en langage naturel

Raisonne, planifie et utilise des outils en boucle

IMPRÉVU

Échoue si écrans ou formats changent

Le comprend, mais ne fait que répondre

Adapte son plan à ce qu'il observe

QUI DÉCIDE DES ÉTAPES

Le développeur, à l'avance

L'humain, tour après tour

L'agent, dans un cadre défini

IDÉAL POUR

Tâches stables, répétitives, à règles

Questions, rédaction, synthèse

Tâches variables à étapes, objectif clair

EXEMPLE

Saisir des factures dans un ERP

Expliquer une politique RH

Résoudre un ticket de support de bout en bout



Attention à l'« agent washing » : vendre assistants, chatbots ou RPA comme des agents sans vraie capacité agentique (Gartner).

PARTIE


03

Fonctionnement

Que se passe-t-il à l'intérieur d'un agent ?




Anatomie d'un agent IA



Vue par composants adaptée de Lilian Weng, « LLM Powered Autonomous Agents » (2023)

La boucle de l'agent



REACT EN ACTION · exemple illustratif

Objectif : « Relancer Acme pour sa facture impayée »

Pensée Trouver la dernière facture impayée.

Action `search_invoices(client="Acme")`

Observ. FAC-2291 · 12 400 € · 34 jours de retard

Pensée Rédiger une relance courtoise.

Action `create_email_draft(to="billing@acme...")`

Observ. Brouillon enregistré → validation humaine

La boucle s'arrête quand l'objectif est atteint, une limite est dépassée (étapes, temps, budget) ou une intervention humaine est requise.

Techniques de raisonnement et de planification

Chain-of-Thought

2022

Raisonner étape par étape avant de répondre ; améliore la résolution de problèmes complexes.

Wei et al.

ReAct

2022

Alterner raisonnement, actions et observations — la base de la plupart des agents.

Yao et al.

Reflexion

2023

Autocritique après retour ; leçons mémorisées pour la tentative suivante.

Shinn et al.

Tree of Thoughts

2023

Explorer plusieurs pistes de raisonnement, les évaluer et revenir en arrière.

Yao et al.

Plan-and-Solve

2023

Établir d'abord un plan de sous-tâches, puis les exécuter une à une.

Wang et al.

Modèles raisonneurs

2024

Modèles entraînés à réfléchir longuement avant d'agir (ex. : OpenAI o1, sept. 2024).

Industrie

La mémoire : comment les agents se souviennent

TYPE	CE QU'ELLE CONTIENT	MISE EN ŒUVRE TYPIQUE	ANALOGIE HUMAINE
 De travail	La tâche en cours : consignes, étapes récentes, résultats d'outils	La fenêtre de contexte	<i>Ce que l'on garde en tête à l'instant</i>
 Épisodique	Interactions et expériences passées	Journaux, historique, réflexions	<i>Se souvenir de la réunion de la semaine dernière</i>
 Sémantique	Faits et connaissances sur le monde ou le métier	Bases vectorielles, RAG, graphes de connaissances	<i>Savoir que Dakar est au Sénégal</i>
 Procédurale	Savoir-faire et compétences	Poids du modèle, prompts, code, compétences réutilisables	<i>Savoir faire du vélo</i>

Typologie issue de CoALA — Sumers et al., « Cognitive Architectures for Language Agents » (2023)

PARTIE

04

Architectures

Comment construit-on des systèmes agentiques ?



Outils et protocoles : relier les agents au monde



Appel de fonctions

Le modèle émet un appel d'outil structuré ; l'application l'exécute et renvoie le résultat.



Model Context Protocol (MCP)

Standard ouvert pour relier les agents aux outils et aux données. Anthropic, nov. 2024 ; confié à l'Agentic AI Foundation (Linux Foundation) en déc. 2025.



Agent2Agent (A2A)

Protocole ouvert permettant aux agents de se découvrir et de collaborer. Google, avr. 2025 ; désormais projet de la Linux Foundation.




Usage d'ordinateur

Les agents pilotent des interfaces via captures d'écran, souris et clavier (Anthropic, oct. 2024 ; OpenAI Operator, janv. 2025, intégré depuis à ChatGPT agent).


POURQUOI UN STANDARD COMPTE

Sans standard



$M \times N$ intégrations sur mesure

Avec MCP



$M + N$ — une fois, réutilisable

MCP = agent ↔ outils et données A2A = agent ↔ agent

Briques de base : workflows ou agents




Chaînage de prompts

Suite fixe d'appels au LLM, avec contrôles possibles entre les étapes.




Routage

Classer l'entrée, puis l'orienter vers le traitement spécialisé adapté.




Parallélisation

Sous-tâches simultanées (découpage) ou répétées (vote), puis fusion.



Orchestrateur-exécutants

Un LLM central découpe la tâche à la volée et délègue aux exécutants.



Évaluateur-optimiseur

Un LLM produit, un autre critique, en boucle jusqu'à la qualité visée.




Agent autonome

Le LLM décide de ses étapes, guidé par l'environnement, jusqu'à l'arrêt.


WORKFLOWS suivent des chemins prédéfinis — prévisibles. **AGENTS** se dirigent eux-mêmes — flexibles. Source : Anthropic (2024)

Systèmes multi-agents




Orchestrateur-sous-agents

Un agent pilote planifie et délègue à des spécialistes en parallèle



Hiérarchique

Des managers de managers — équipes d'agents organisées en niveaux




Réseau de pairs

Les agents se passent le relais ou négocient directement entre eux

+90,2 %

Système de recherche multi-agents d'Anthropic (pilote Claude Opus 4 + sous-agents Sonnet 4) vs un agent Opus 4 seul, sur une évaluation interne (2025)

Consommation relative de tokens (chat = 1×)



PARTIE


05

État des lieux

Où en sommes-nous aujourd'hui ?



Les grands jalons de l'ère agentique



Exemples de févr. 2025 : Claude Code d'Anthropic (préversion) et Deep Research d'OpenAI.

L'écosystème en un coup d'œil



Frameworks open source

- LangGraph (LangChain)
- CrewAI
- Microsoft Agent Framework (successeur d'AutoGen et Semantic Kernel)
- LlamaIndex
- goose (désormais sous l'AAIF)



SDK d'agents des éditeurs

- OpenAI Agents SDK
- Claude Agent SDK (Anthropic)
- Agent Development Kit (Google)
- Amazon Bedrock Agents



Produits agentiques

- Code : Claude Code, OpenAI Codex, GitHub Copilot, Cursor
- Recherche : Deep Research (OpenAI, Google)
- Entreprise : Salesforce Agentforce, Microsoft Copilot Studio



Standards ouverts

- MCP — agent ↔ outils
- A2A — agent ↔ agent
- AGENTS.md — consignes pour agents de code

Sélection non exhaustive — le paysage évolue rapidement.

Mesurer les agents : benchmarks et progrès

SWE-bench Verified

Corriger de vrais tickets GitHub (500 tâches validées)

SWE-bench Pro

Successeur plus difficile, moins contaminé (Scale AI, 2025)

OSWorld

Tâches sur de vrais systèmes d'exploitation

WebArena • GAIA


Tâches web • questions d'assistant avec outils

τ-bench

Dialogues de service client avec outils et règles

Réserve : en févr. 2026, OpenAI a cessé de publier SWE-bench Verified (contamination, tests défectueux) et recommande SWE-bench Pro.

SWE-bench Verified, août 2024 – nov. 2025 (% résolus)



Scores annoncés au lancement (GPT-5 sur 477 des 500 tâches). Environnements différents : comparer les tendances, pas les décimales.

Dynamique : capacités et adoption

~7 mois

Temps de doublement de la durée des tâches réussies à 50 % par les agents de pointe (2019–2025)

METR, mars 2025

<5 % → 40 %

Applications d'entreprise intégrant des agents IA spécialisés, 2025 → fin 2026 (prévision)

Gartner, août 2025

2 % → ~30 %

Part des revenus des logiciels d'entreprise portée par l'IA agentique, 2025 → 2035 (scénario optimiste, >450 Md\$)

Gartner, août 2025

ÉVOLUTION ATTENDUE DE L'IA EN ENTREPRISE SELON GARTNER

2025

Assistants IA dans presque toutes les applications d'entreprise

2026

Agents spécialisés dans 40 % des applications

2029

Écosystèmes multi-agents collaborant entre applications

Là où les agents créent de la valeur



Génie logiciel

Explorer le code, écrire et tester, corriger des bugs, ouvrir des pull requests



Service client

Traiter les demandes de bout en bout, escalader vers un humain si besoin



Recherche et analyse

Explorer de nombreuses sources, les recouper, rédiger des rapports sourcés



Exploitation IT et sécurité

Trier alertes et incidents, réunir les preuves, proposer des correctifs



Finance et back-office

Traiter des documents, rapprocher des écritures, préparer des rapports



Ventes et marketing

Analyser des comptes, qualifier des prospects, personnaliser les messages

PARTIE

06

Bonnes pratiques

*Comment déployer des agents en sécurité — et
créer de la valeur ?*




Pourquoi la fiabilité est le vrai défi

Des erreurs qui s'accumulent

Si chaque étape réussit indépendamment avec une probabilité p , une tâche de n étapes réussit avec la probabilité :

$$P(\text{succès}) = p^n$$

- 95 % par étape → seulement 36 % après 20 étapes
- Les étapes réelles ne sont pas totalement indépendantes — modèle simplifié
- Remèdes : vérifications, points de contrôle, nouvelles tentatives, relecture humaine



Principaux risques et défis



Injection de prompt

Des instructions malveillantes cachées (pages, documents, e-mails) détournent l'agent. N° 1 du Top 10 OWASP LLM (2025).



Autonomie excessive

Trop de droits ou d'autonomie transforment une petite erreur en vrai dommage (OWASP LLM06:2025).



Erreurs assurées

Faits inventés ou actions erronées, amplifiés sur les tâches longues.



Coût et latence

Nombreux appels par tâche : bien plus de tokens et de temps qu'un chat.



Responsabilité

Qui a validé quoi ? Les actions doivent être traçables, auditable, réversibles.



Fuite de données

Un agent aux accès étendus peut divulguer des informations sensibles (OWASP LLM02:2025).

40 %+

des projets d'IA agentique seront abandonnés d'ici fin 2027 — coûts croissants, valeur incertaine ou contrôle des risques insuffisant.

~130

fournisseurs réellement agentiques parmi des milliers — le reste relève de l'« agent washing ».

Gartner, juin 2025

Principes de conception d'agents fiables



CONCEVOIR

● Commencer simple

D'abord un appel LLM ou un workflow ; n'ajouter de l'autonomie que si elle apporte un gain mesurable.

● Soigner les outils

Noms, descriptions, exemples et messages d'erreur clairs.

● Évaluer en continu

Évaluations tirées de cas réels, lancées avant chaque changement.



SÉCURISER

● Moindre privilège

Droits minimaux ; exécution de code et navigation isolées.

● Se méfier des entrées

Séparer consignes et données pour limiter l'injection de prompt.

● Contrôler les actions à risque

Validation humaine des étapes irréversibles, coûteuses ou sensibles.



EXPLOITER

● Fixer des limites

Plafonner étapes, temps et budget ; définir des conditions d'arrêt.

● Rendre observable

Tracer chaque raisonnement, appel d'outil et résultat.

● Prévoir l'échec

Privilégier actions réversibles, points de contrôle et retour arrière.

À RETENIR

Avec les agents, l'IA passe d'un outil que l'on utilise à un système qui travaille pour nous.



Un agent est un LLM qui utilise des outils en boucle, vers un objectif.



« Agentique » est un spectre — choisir le minimum d'autonomie suffisant.



Les standards ouverts (MCP, A2A) rendent les agents interopérables.



La valeur exige de la rigueur : évaluations, garde-fous, supervision humaine.

Merci · Questions ?

Sources et lectures complémentaires

- Russell & Norvig — Artificial Intelligence: A Modern Approach (4e éd., 2020)
- Anthropic — « Building Effective Agents » (déc. 2024)
- Anthropic — « How we built our multi-agent research system » (juin 2025)
- L. Weng — « LLM Powered Autonomous Agents » (2023)
- Wei et al. — Chain-of-Thought Prompting (2022)
- Yao et al. — ReAct: Synergizing Reasoning and Acting (2022)
- Shinn et al. — Reflexion (2023)
- Yao et al. — Tree of Thoughts (2023)

- Wang et al. — Plan-and-Solve Prompting (2023)
- Sumers et al. — Cognitive Architectures for Language Agents (2023)
- Kwa et al. (METR) — Measuring AI Ability to Complete Long Tasks (2025)
- Jimenez et al. — SWE-bench (2023) ; OpenAI — SWE-bench Verified (2024) et note d'abandon (févr. 2026)
- Communiqués Gartner — 25 juin 2025 et 26 août 2025
- Linux Foundation — annonce de l'Agentic AI Foundation (9 déc. 2025)
- OWASP — Top 10 for LLM Applications (2025)
- modelcontextprotocol.io · a2a-protocol.org