

Du bon à l'excellent

Optimiser les prompts en statistique officielle

Une amélioration systématique plutôt que des essais au hasard : jeux d'évaluation, mesure de la qualité, variance, coût en jetons, mise en cache, et quand aller au-delà du prompt.



BON



EXCELLENT

Ce que vous saurez faire



Construire un jeu d'évaluation

représentatif de vos données, langues et cas limites.



Mesurer la qualité des sorties

avec une métrique adaptée à la tâche, pas à l'œil.



Maîtriser la variance

pour qu'une même entrée donne la même sortie, défendable.



Maîtriser contexte et coûts

estimer les jetons, utiliser le cache et les lots.



Choisir la bonne approche

entre prompt, RAG et affinage (fine-tuning).

DÉROULÉ DE LA SÉANCE



Exposé

Concepts et exemples commentés



Atelier en binômes

Optimiser un prompt de codification sur un jeu figé



Synthèse

Meilleurs scores et passage au banc d'essai Groq

Six étapes d'un bon prompt à un excellent prompt

01

De l'art à la méthode

Pourquoi « ça a l'air correct » ne suffit pas en statistique officielle.

02

Le jeu d'évaluation

Le test figé qui dit si une modification a aidé.

03

Mesurer la qualité

Métriques par type de tâche, tableaux de scores, LLM juge.

04

Maîtriser la variance

Pourquoi les réponses changent d'une exécution à l'autre, et comment l'éviter.

05

Contexte, jetons, coûts

Estimer la facture, réduire le contexte, cache et lots.

06

Prompt, RAG ou affinage ?

Choisir l'outil selon l'échec observé.

Ensuite : atelier pratique · pièges pour les INS · liste de contrôle du prompt excellent

SECTION 1 SUR 6

01

De l'art à la méthode

Pourquoi un prompt efficace hier échoue-t-il sur le bulletin du jour ?



« Ça a l'air correct » ne suffit pas

UN « BON » PROMPT

Testé sur

✗ le seul exemple essayé par hasard

Jugé par

✗ une lecture et une impression favorable

Taux d'erreur

✗ inconnu

Reproductibilité

✗ des réponses qui dérivent sans prévenir

Coût

✗ découvert sur la facture

UN PROMPT « EXCELLENT »

✓ un jeu figé de 30 à 50 cas représentatifs

✓ des critères écrits et un score chiffré

✓ mesuré, avec des types d'échec identifiés

✓ stable : modèle figé, prompt versionné

✓ estimé à l'avance pour 1 000 documents



La statistique officielle place la barre plus haut. Les Principes fondamentaux de l'ONU exigent des méthodes choisies selon des critères professionnels et scientifiques (principe 2) et la protection des données individuelles (principe 6). Une étape LLM en production doit y satisfaire aussi.

Source : Assemblée générale des Nations Unies, rés. 68/261, Principes fondamentaux de la statistique officielle (2014).

Les six briques, sur une vraie tâche d'INS

PROMPT v0 · CODIFICATION DES PROFESSIONS

RÔLE

Vous êtes codificateur à l'Institut national de la statistique.

OBJECTIF

Attribuez à chaque description d'emploi un code CIP-08 à quatre chiffres.

CONTEXTE

Texte libre de l'enquête sur la population active, en français ou en anglais, saisi par les enquêteurs.

RÈGLES

Codes de la liste CIP-08 jointe uniquement. Codez l'emploi principal. En cas de doute : NON_CODABLE, jamais de supposition.

FORMAT

JSON uniquement : {"id", "code_cip", "confiance": "haute|moyenne|faible"}

EXEMPLES

« Vendeuse de tomates au marché » → 5211 · « Moto-taxi driver » → 8321



Ce matin :

comment l'écrire ?

Cet après-midi :

comment prouver qu'il fonctionne, et l'améliorer ?

Le prompt v0 est votre point de départ en atelier.

Codes : OIT, Classification internationale type des professions (CIP-08). 5211 = vendeurs sur les marchés et éventaies ; 8321 = conducteurs de motocycles.

SECTION 2 SUR 6


02

Le jeu d'évaluation

Comment saurez-vous que la version 2 est meilleure que la version 1 ?



La boucle d'optimisation



Une seule variable à la fois. Si vous changez trois choses et que le score monte, vous ignorez laquelle a aidé.

À quoi ressemble un jeu d'évaluation

ID	Entrée (saisie par l'enquêteur)	Référence	Type de cas
E01	Vendeuse de tomates au marché central	5211	Typique
E02	Moto-taxi driver, owns the motorcycle	8321	Typique
E03	Agent de saisie à l'institut de statistique	4132	Typique · FR
E04	Primary teacher, sells airtime at weekends	2341	Limite · 2 emplois
E05	Ingénieur	NON_CODABLE	Limite · vague
E06	works	NON_CODABLE	Négatif

Extrait illustratif. Codes CITP-08 : 5211, 8321, 4132, 2341.

UNE RÉPARTITION DE DÉPART

~60%

Cas typiques

Cas courants, toutes langues



~25%

Cas limites

Éprouvent les règles de décision



~15%

Cas négatifs

Le modèle doit refuser ou signaler



Règle empirique : commencer avec 30 à 50 cas, puis ajouter chaque nouvel échec rencontré en production.

Cinq règles pour un jeu fiable



Représentatif

Couvre chaque langue, région, source et format rencontrés en production, y compris scans médiocres et fautes.



Annoté par des experts

Réponses de référence d'experts métier. Double codification, désaccords résolus avant notation.



Figé et versionné

Aucun cas modifié une fois la notation lancée. Jeu stocké dans Git avec un numéro de version.



Jamais dans le prompt

Les exemples du prompt viennent d'un autre réservoir. Sinon, le modèle est noté sur les réponses fournies.



Nourri par les échecs

Chaque erreur trouvée en production devient un nouveau cas dans la version suivante du jeu.

SECTION 3 SUR 6

03

Mesurer la qualité

Mesurer, plutôt que ressentir.




Choisir la métrique adaptée à la tâche

Type de tâche	Exemple dans un INS	Métrique	Mode de notation
 Extraction	Chiffres de l'IPC tirés d'un bulletin PDF	Correspondance exacte par champ	Automatique : script vs référence
 Codification	Codification CITP, CITI ou COICOP de réponses d'enquête	Exactitude + précision / rappel par classe	Automatique + matrice de confusion
 Sortie structurée	JSON alimentant un tableau de bord public	Taux de validité du schéma	Automatique : validateur JSON Schema
 Q&R ancrées (RAG)	Questions sur les notes méthodologiques	Fidélité, exactitude des citations	Grille : humain ou juge calibré
 Rédaction	Communiqué, note méthodologique	Grille 1–5 : exactitude, complétude, ton, longueur	Relecteurs humains, juge calibré

 Lignes vertes : notation entièrement automatique, peu coûteuse et objective. Commencez par là.

Un tableau de scores pour chaque version

Codification des professions, jeu de 50 cas (illustratif)




JOURNAL DES ITÉRATIONS

v0	Base : prompt de ce matin	62%	BASE
v1	Règle « coder l'emploi principal »	71%	RETENU
v2	Ajout de 3 exemples de cas limites	80%	RETENU
v2b	Ajout de 15 règles supplémentaires	76%	REJETÉ
v3	Schéma JSON imposé	84%	RETENU
v4	Critères NON_CODABLE clarifiés	88%	RETENU

Chiffres illustratifs à visée pédagogique. Construisez votre propre tableau à partir de votre jeu d'évaluation.

Utiliser un LLM comme juge, en toute sécurité



CALIBRER AVANT DE FAIRE CONFIANCE

- 1 Des humains notent 20 à 30 sorties
- 2 Le juge note les mêmes sorties
- 3 Juge retenu seulement si l'accord est élevé

BIAIS CONNUS DU JUGE

⚠ Position

Favorise la réponse présentée en premier. Inverser l'ordre et moyenner.

⚠ Verbose

Favorise les réponses longues. Intégrer la longueur à la grille.

⚠ Autopréférence

Favorise son propre style. Utiliser une autre famille de modèles.


Source : Zheng et al. (2023), « Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena », NeurIPS Datasets & Benchmarks.

SECTION 4 SUR 6

04

Maîtriser la variance

Même prompt, même entrée : pourquoi une autre réponse ?



D'où vient la variance



Aléa d'échantillonnage

Température et top-p laissent le modèle choisir parmi les jetons probables.



Consignes ambiguës

Une règle floue est tranchée différemment à chaque exécution.



Mises à jour silencieuses

Un alias générique peut pointer vers une nouvelle version sans préavis.



Variation des entrées

Langue, mise en page, qualité du scan et fautes modifient la sortie.

TEST DE COHÉRENCE EN 5 EXÉCUTIONS

E01	5211	5211	5211	5211	5211	100%
E04	2341	2341	5249	2341	5249	60%
E05	NC	NC	NC	NC	NC	100%

Taux d'accord = part des exécutions donnant la réponse la plus fréquente. Sous 100 % en codification, il faut regarder de près.

Exécutions illustratives. NC = NON_CODABLE. 5249 = vendeurs non classés ailleurs (erreur plausible pour « vend du crédit téléphonique »).

Six leviers pour des sorties reproductibles

PARAMÈTRES DU MODÈLE



Température basse

0 à 0,2 pour extraire et coder ; plus haut seulement pour rédiger.



Figurer la version du modèle

Utiliser l'identifiant daté du modèle et le noter au journal.



Plafonner la sortie

Fixer max tokens et une limite de mots ; les réponses longues dérivent.

CONCEPTION DU PROMPT



Contraindre le format

Schéma JSON avec une liste fermée de valeurs autorisées.



Écrire des règles d'arbitrage

« Si deux emplois, coder celui qui compte le plus d'heures. »



Voter sur les cas difficiles

3 à 5 exécutions, réponse majoritaire, désaccords vers un humain.



Une température de 0 réduit l'aléa ; elle ne garantit pas des sorties identiques. Mesurez toujours l'accord sur votre jeu d'évaluation.

Auto-cohérence : Wang et al. (2022), « Self-Consistency Improves Chain of Thought Reasoning in Language Models », arXiv:2203.11171.

SECTION 5 SUR 6

05

Contexte, jetons, coûts

*Combien coûterait la codification de 100 000
réponses d'enquête ?*



Les jetons : unité du contexte et du coût

COMMENT UN MODÈLE LIT UNE PHRASE (DÉCOUPAGE ILLUSTRATIF)

L ' indice des prix a augmenté de 2 , 4 %

13 jetons

≈ 4

caractères par jeton

en anglais, soit environ ¾ de mot (règle empirique d'OpenAI).

Plus

de jetons par mot

dans beaucoup de langues autres que l'anglais : prévoir une marge.

E + S

entrée et sortie facturées

les jetons de sortie coûtent en général plus cher que ceux d'entrée.


Coût = jetons d'entrée × prix entrée + jetons de sortie × prix sortie

Fenêtre de contexte ≥ consignes + exemples + document + réponse

Sources : OpenAI Help Center, « What are tokens and how to count them? » ; Petrov et al. (2023), NeurIPS.

Exemple chiffré : coder 100 000 emplois

Coût pour 100 000 descriptions (prix illustratifs)



HYPOTHÈSES PAR APPEL

2 500	jetons fixes : consignes, extrait CITP, exemples
50	jetons par description d'emploi
40	jetons de sortie par réponse codée
0,50 / 1,50 \$	par million de jetons entrée / sortie
90 %	de remise sur l'entrée en cache (hypothèse)

≈ 15 fois moins cher par la seule conception du prompt. Re-testez l'exactitude après regroupement en lots.

Prix et remise illustratifs, pas un tarif fournisseur. Surcoûts d'écriture en cache ignorés.

Moins de contexte, mieux placé

Usage d'une information selon sa position dans un long contexte (schéma)




Schéma d'après Liu et al. (2023) : pas leurs chiffres exacts.



N'envoyer que le pertinent

Présélectionner pages ou fragments (RAG) plutôt que des rapports entiers.



Résumer ou découper

Traiter les longs documents par section, puis assembler.



Règles clés aux extrémités

Consignes critiques en tête ; rappeler la règle clé à la fin.



Limiter la réponse

Limites de mots et max tokens réduisent coût et dérive.

Source : Liu et al. (2023), « Lost in the Middle: How Language Models Use Long Contexts », Transactions of the ACL (2024).

Deux types de mise en cache



Cache de prompt

chez le fournisseur

STRUCTURER CHAQUE APPEL AINSI

Consignes · liste CIP · exemples

Cas

stable : en cache, remisé

variable

- Contenu stable d'abord, variable à la fin.
- Une date ou un ID en tête casse le cache.
- Remise, taille minimale et durée de vie varient selon le fournisseur.



Cache de réponses

dans votre propre chaîne de traitement

CLÉ = EMPREINTE DE

version modèle

version prompt

texte d'entrée



Instantané et gratuit si la requête se répète



Réponses parfaitement reproductibles



Une piste d'audit pour chaque chiffre publié

Vérifiez dans la documentation de chaque fournisseur les conditions actuelles de mise en cache.


Trois outils, trois problèmes différents

	 Ingénierie du prompt COMMENCER ICI	 RAG AJOUTER DU SAVOIR	 Affinage MODIFIER LE MODÈLE
Corrige	Un comportement descriptible en mots	Savoir manquant, changeant ou à citer	Comportement constant sur une tâche étroite à fort volume
Données requises	Quelques exemples	Un corpus documentaire	Centaines à milliers de paires annotées
1er résultat	Heures	Jours	Semaines
Profil de coût	Faible : paiement à l'appel	Moyen : embeddings + base vectorielle	Élevé : entraînement + hébergement
Mise à jour	Modifier le prompt	Réindexer les documents	Ré-entraîner
Exemple INS	<i>Rédiger un communiqué de presse</i>	<i>Q&R sur notes méthodologiques et métadonnées</i>	<i>Codification CITP nationale, petit modèle hébergé en interne</i>

Durées et volumes de données : ordres de grandeur indicatifs.

Du bon à l'excellent · Optimisation des prompts | Atelier technique STG17

Un parcours de décision guidé par vos résultats



Contrôle de souveraineté


Ces données peuvent-elles sortir de l'institut ?

Sinon, seuls des fournisseurs sous votre contrôle juridique, ou des modèles ouverts auto-hébergés, sont éligibles.

Quelle que soit la voie :

relancer le même jeu d'évaluation et consigner le résultat.

Optimiser le prompt de codification sur un jeu figé



CE QUE REMET CHAQUE BINÔME



Liste de contrôle du prompt excellent

Évaluation



Critères de succès et score cible écrits



Jeu figé et versionné de 30 à 50 cas annotés par des experts

Qualité



Métrique adaptée au type de tâche



Journal : un seul changement par version

Variance



Version du modèle figée ; température choisie



Accord entre exécutions répétées mesuré

Coût



Coût pour 1 000 documents estimé



Contenu stable en tête, pour le cache

Gouvernance



Confidentialité et conditions d'usage vérifiées



Sorties vérifiées ; prompt versionné, avec un responsable

Messages clés

01



Mesurer avant de changer

Un jeu d'évaluation figé transforme les opinions en chiffres.

02



Construire la reproductibilité

Figé, contraindre, tester les répétitions, vérifier avant publication.

03



Concevoir pour le coût

Structure du prompt, cache et lots peuvent diviser la facture par dix.

DU BON À L'EXCELLENT

Un bon prompt obtient une réponse.

**Un excellent prompt obtient une
réponse défendable.**



Merci. Questions et échanges.

Sources



ATELIER

Programme de l'atelier STG17, « Enjeux émergents, pratiques émergentes : innover dans la chaîne de valeur des données », version du 01/09/2026. BAD, UA STATAFRIC, NISR.

PRINCIPES

Assemblée générale des Nations Unies (2014). Résolution 68/261, Principes fondamentaux de la statistique officielle.

CLASSIFICATION

Organisation internationale du Travail (2012). Classification internationale type des professions, CIP-08.

JUGES LLM

Zheng, L. et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. NeurIPS Datasets and Benchmarks Track.

VARIANCE

Wang, X. et al. (2022). Self-Consistency Improves Chain of Thought Reasoning in Language Models. arXiv:2203.11171 (ICLR 2023).

JETONS

OpenAI Help Center. What are tokens and how to count them?

LANGUES

Petrov, A. et al. (2023). Language Model Tokenizers Introduce Unfairness Between Languages. NeurIPS 2023.

CONTEXTE

Liu, N. F. et al. (2023). Lost in the Middle: How Language Models Use Long Contexts. Transactions of the ACL, 12 (2024).

Les chiffres signalés « illustratif » ou « schéma » sont des exemples pédagogiques, pas des résultats mesurés.