

# Du bon à l'excellent

## Optimiser les prompts en statistique officielle

*Une amélioration systématique plutôt que des essais au hasard : jeux d'évaluation, mesure de la qualité, variance, coût en jetons, mise en cache, et quand aller au-delà du prompt.*



BON



EXCELLENT

# Ce que vous saurez faire



## Construire un jeu d'évaluation

représentatif de vos données, langues et cas limites.



## Mesurer la qualité des sorties

avec une métrique adaptée à la tâche, pas à l'œil.



## Maîtriser la variance

pour qu'une même entrée donne la même sortie, défendable.



## Maîtriser contexte et coûts

estimer les jetons, utiliser le cache et les lots.



## Choisir la bonne approche

entre prompt, RAG et affinage (fine-tuning).

### DÉROULÉ DE LA SÉANCE



#### Exposé

Concepts et exemples commentés



#### Atelier

Optimiser un prompt de codification sur un jeu figé



#### Synthèse

Meilleurs scores et passage au banc d'essai Groq

# Six étapes d'un bon prompt à un excellent prompt

**01**

## De l'art à la méthode

Pourquoi « ça a l'air correct » ne suffit pas en statistique officielle.

**02**

## Le jeu d'évaluation

Le test figé qui dit si une modification a aidé.

**03**

## Mesurer la qualité

Métriques par type de tâche, tableaux de scores, LLM juge.

**04**

## Maîtriser la variance

Pourquoi les réponses changent d'une exécution à l'autre, et comment l'éviter.

**05**

## Contexte, jetons, coûts

Estimer la facture, réduire le contexte, cache et lots.

**06**

## Prompt, RAG ou affinage ?

Choisir l'outil selon l'échec observé.

*Ensuite : atelier pratique · pièges pour les INS · liste de contrôle du prompt excellent*

SECTION 1 SUR 6

# 01

## De l'art à la méthode

*Pourquoi un prompt efficace hier échoue-t-il sur le bulletin du jour ?*



# « Ça a l'air correct » ne suffit pas

## UN « BON » PROMPT

### Testé sur

✗ le seul exemple essayé par hasard

### Jugé par

✗ une lecture et une impression favorable

### Taux d'erreur

✗ inconnu

### Reproductibilité

✗ des réponses qui dérivent sans prévenir

### Coût

✗ découvert sur la facture

## UN PROMPT « EXCELLENT »

✓ un jeu figé de 30 à 50 cas représentatifs

✓ des critères écrits et un score chiffré

✓ mesuré, avec des types d'échec identifiés

✓ stable : modèle figé, prompt versionné

✓ estimé à l'avance pour 1 000 documents



**La statistique officielle place la barre plus haut.** Les Principes fondamentaux de l'ONU exigent des méthodes choisies selon des critères professionnels et scientifiques (principe 2) et la protection des données individuelles (principe 6). Une étape LLM en production doit y satisfaire aussi.

Source : Assemblée générale des Nations Unies, rés. 68/261, Principes fondamentaux de la statistique officielle (2014).

# Les six briques, sur une vraie tâche d'INS

## PROMPT v0 · CODIFICATION DES PROFESSIONS

### RÔLE

Vous êtes codificateur à l'Institut national de la statistique.

### OBJECTIF

Attribuez à chaque description d'emploi un code CIP-08 à quatre chiffres.

### CONTEXTE

Texte libre de l'enquête sur la population active, en français ou en anglais, saisi par les enquêteurs.

### RÈGLES

Codes de la liste CIP-08 jointe uniquement. Codez l'emploi principal. En cas de doute : NON\_CODABLE, jamais de supposition.

### FORMAT

JSON uniquement : {"id", "code\_cip", "confiance": "haute|moyenne|faible"}

### EXEMPLES

« Vendeuse de tomates au marché » → 5211 · « Moto-taxi driver » → 8321



Ce matin :

**comment l'écrire ?**

Cet après-midi :

**comment prouver qu'il fonctionne, et l'améliorer ?**

*Le prompt v0 est votre point de départ en atelier.*

Codes : OIT, Classification internationale type des professions (CIP-08). 5211 = vendeurs sur les marchés et éventaies ; 8321 = conducteurs de motocycles.

SECTION 2 SUR 6


# 02

## Le jeu d'évaluation

*Comment saurez-vous que la version 2 est meilleure que la version 1 ?*



# La boucle d'optimisation



**Une seule variable à la fois.** Si vous changez trois choses et que le score monte, vous ignorez laquelle a aidé.



# À quoi ressemble un jeu d'évaluation

| ID  | Entrée (saisie par l'enquêteur)             | Référence   | Type de cas        |
|-----|---------------------------------------------|-------------|--------------------|
| E01 | Vendeuse de tomates au marché central       | 5211        | Typique            |
| E02 | Moto-taxi driver, owns the motorcycle       | 8321        | Typique            |
| E03 | Agent de saisie à l'institut de statistique | 4132        | Typique · FR       |
| E04 | Primary teacher, sells airtime at weekends  | 2341        | Limite · 2 emplois |
| E05 | Ingénieur                                   | NON_CODABLE | Limite · vague     |
| E06 | works                                       | NON_CODABLE | Négatif            |

Extrait illustratif. Codes CITP-08 : 5211, 8321, 4132, 2341.

## UNE RÉPARTITION DE DÉPART

**~60%** Cas typiques  
Cas courants, toutes langues



**~25%** Cas limites  
Éprouvent les règles de décision



**~15%** Cas négatifs  
Le modèle doit refuser ou signaler



Règle empirique : commencer avec 30 à 50 cas, puis ajouter chaque nouvel échec rencontré en production.

# Cinq règles pour un jeu fiable



## Représentatif

Couvre chaque langue, région, source et format rencontrés en production, y compris scans médiocres et fautes.



## Annoté par des experts

Réponses de référence d'experts métier. Double codification, désaccords résolus avant notation.



## Figé et versionné

Aucun cas modifié une fois la notation lancée. Jeu stocké dans Git avec un numéro de version.



## Jamais dans le prompt

Les exemples du prompt viennent d'un autre réservoir. Sinon, le modèle est noté sur les réponses fournies.



## Nourri par les échecs

Chaque erreur trouvée en production devient un nouveau cas dans la version suivante du jeu.

SECTION 3 SUR 6

# 03

## Mesurer la qualité

*Mesurer, plutôt que ressentir.*




# Choisir la métrique adaptée à la tâche

| Type de tâche                                                                                                  | Exemple dans un INS                                     | Métrique                                                  | Mode de notation                     |
|----------------------------------------------------------------------------------------------------------------|---------------------------------------------------------|-----------------------------------------------------------|--------------------------------------|
|  <b>Extraction</b>            | Chiffres de l'IPC tirés d'un bulletin PDF               | <b>Correspondance exacte par champ</b>                    | Automatique : script vs référence    |
|  <b>Codification</b>          | Codification CITP, CITI ou COICOP de réponses d'enquête | <b>Exactitude + précision / rappel par classe</b>         | Automatique + matrice de confusion   |
|  <b>Sortie structurée</b>     | JSON alimentant un tableau de bord public               | <b>Taux de validité du schéma</b>                         | Automatique : validateur JSON Schema |
|  <b>Q&amp;R ancrées (RAG)</b> | Questions sur les notes méthodologiques                 | <b>Fidélité, exactitude des citations</b>                 | Grille : humain ou juge calibré      |
|  <b>Rédaction</b>             | Communiqué, note méthodologique                         | <b>Grille 1–5 : exactitude, complétude, ton, longueur</b> | Relecteurs humains, juge calibré     |

 Lignes vertes : notation entièrement automatique, peu coûteuse et objective. Commencez par là.

# Un tableau de scores pour chaque version

Codification des professions, jeu de 50 cas (illustratif)




## JOURNAL DES ITÉRATIONS

|     |                                    |     |        |
|-----|------------------------------------|-----|--------|
| v0  | Base : prompt de ce matin          | 62% | BASE   |
| v1  | Règle « coder l'emploi principal » | 71% | RETENU |
| v2  | Ajout de 3 exemples de cas limites | 80% | RETENU |
| v2b | Ajout de 15 règles supplémentaires | 76% | REJETÉ |
| v3  | Schéma JSON imposé                 | 84% | RETENU |
| v4  | Critères NON_CODABLE clarifiés     | 88% | RETENU |

Chiffres illustratifs à visée pédagogique. Construisez votre propre tableau à partir de votre jeu d'évaluation.

# Utiliser un LLM comme juge, en toute sécurité



## CALIBRER AVANT DE FAIRE CONFIANCE

- 1 Des humains notent 20 à 30 sorties
- 2 Le juge note les mêmes sorties
- 3 Juge retenu seulement si l'accord est élevé

## BIAIS CONNUS DU JUGE

### ⚠ Position

Favorise la réponse présentée en premier. Inverser l'ordre et moyenner.

### ⚠ Verbose

Favorise les réponses longues. Intégrer la longueur à la grille.

### ⚠ Autopréférence

Favorise son propre style. Utiliser une autre famille de modèles.


Source : Zheng et al. (2023), « Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena », NeurIPS Datasets & Benchmarks.

SECTION 4 SUR 6

# 04

## Maîtriser la variance

*Même prompt, même entrée : pourquoi une autre réponse ?*



# D'où vient la variance



## Aléa d'échantillonnage

Température et top-p laissent le modèle choisir parmi les jetons probables.



## Consignes ambiguës

Une règle floue est tranchée différemment à chaque exécution.



## Mises à jour silencieuses

Un alias générique peut pointer vers une nouvelle version sans préavis.



## Variation des entrées

Langue, mise en page, qualité du scan et fautes modifient la sortie.

### TEST DE COHÉRENCE EN 5 EXÉCUTIONS

|     |      |      |      |      |      |      |
|-----|------|------|------|------|------|------|
| E01 | 5211 | 5211 | 5211 | 5211 | 5211 | 100% |
| E04 | 2341 | 2341 | 5249 | 2341 | 5249 | 60%  |
| E05 | NC   | NC   | NC   | NC   | NC   | 100% |

Taux d'accord = part des exécutions donnant la réponse la plus fréquente. Sous 100 % en codification, il faut regarder de près.

Exécutions illustratives. NC = NON\_CODABLE. 5249 = vendeurs non classés ailleurs (erreur plausible pour « vend du crédit téléphonique »).



# Six leviers pour des sorties reproductibles

## PARAMÈTRES DU MODÈLE



### Température basse

0 à 0,2 pour extraire et coder ; plus haut seulement pour rédiger.



### Figurer la version du modèle

Utiliser l'identifiant daté du modèle et le noter au journal.



### Plafonner la sortie

Fixer max tokens et une limite de mots ; les réponses longues dérivent.

## CONCEPTION DU PROMPT



### Contraindre le format

Schéma JSON avec une liste fermée de valeurs autorisées.



### Écrire des règles d'arbitrage

« Si deux emplois, coder celui qui compte le plus d'heures. »



### Voter sur les cas difficiles

3 à 5 exécutions, réponse majoritaire, désaccords vers un humain.



**Une température de 0 réduit l'aléa ; elle ne garantit pas des sorties identiques.** Mesurez toujours l'accord sur votre jeu d'évaluation.

Auto-cohérence : Wang et al. (2022), « Self-Consistency Improves Chain of Thought Reasoning in Language Models », arXiv:2203.11171.

SECTION 5 SUR 6

# 05

## Contexte, jetons, coûts

*Combien coûterait la codification de 100 000  
réponses d'enquête ?*



# Les jetons : unité du contexte et du coût

## COMMENT UN MODÈLE LIT UNE PHRASE (DÉCOUPAGE ILLUSTRATIF)

L ' indice des prix a augmenté de 2 , 4 %

13 jetons

≈ 4

### caractères par jeton

en anglais, soit environ ¾ de mot (règle empirique d'OpenAI).

Plus

### de jetons par mot

dans beaucoup de langues autres que l'anglais : prévoir une marge.

E + S

### entrée et sortie facturées

les jetons de sortie coûtent en général plus cher que ceux d'entrée.


**Coût** = jetons d'entrée × prix entrée + jetons de sortie × prix sortie

**Fenêtre de contexte** ≥ consignes + exemples + document + réponse

Sources : OpenAI Help Center, « What are tokens and how to count them? » ; Petrov et al. (2023), NeurIPS.

## Exemple chiffré : coder 100 000 emplois

Coût pour 100 000 descriptions (prix illustratifs)



### HYPOTHÈSES PAR APPEL

|                |                                                  |
|----------------|--------------------------------------------------|
| 2 500          | jetons fixes : consignes, extrait CITP, exemples |
| 50             | jetons par description d'emploi                  |
| 40             | jetons de sortie par réponse codée               |
| 0,50 / 1,50 \$ | par million de jetons entrée / sortie            |
| 90 %           | de remise sur l'entrée en cache (hypothèse)      |

≈ 15 fois moins cher par la seule conception du prompt. Re-testez l'exactitude après regroupement en lots.

Prix et remise illustratifs, pas un tarif fournisseur. Surcoûts d'écriture en cache ignorés.

# Moins de contexte, mieux placé

Usage d'une information selon sa position dans un long contexte (schéma)




Schéma d'après Liu et al. (2023) : pas leurs chiffres exacts.



## N'envoyer que le pertinent

Présélectionner pages ou fragments (RAG) plutôt que des rapports entiers.



## Résumer ou découper

Traiter les longs documents par section, puis assembler.



## Règles clés aux extrémités

Consignes critiques en tête ; rappeler la règle clé à la fin.



## Limiter la réponse

Limites de mots et max tokens réduisent coût et dérive.

Source : Liu et al. (2023), « Lost in the Middle: How Language Models Use Long Contexts », Transactions of the ACL (2024).

# Deux types de mise en cache



## Cache de prompt

chez le fournisseur

### STRUCTURER CHAQUE APPEL AINSI

Consignes · liste CIP · exemples

Cas

*stable : en cache, remisé*

*variable*

- Contenu stable d'abord, variable à la fin.
- Une date ou un ID en tête casse le cache.
- Remise, taille minimale et durée de vie varient selon le fournisseur.



## Cache de réponses

dans votre propre chaîne de traitement

### CLÉ = EMPREINTE DE

version modèle

version prompt

texte d'entrée



Instantané et gratuit si la requête se répète



Réponses parfaitement reproductibles



Une piste d'audit pour chaque chiffre publié

Vérifiez dans la documentation de chaque fournisseur les conditions actuelles de mise en cache.



# Trois outils, trois problèmes différents


|                  |  <b>Ingénierie du prompt</b><br>COMMENCER ICI |  <b>RAG</b><br>AJOUTER DU SAVOIR |  <b>Affinage</b><br>MODIFIER LE MODÈLE |
|------------------|--------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------|
| Corrige          | Un comportement descriptible en mots                                                                                           | Savoir manquant, changeant ou à citer                                                                             | Comportement constant sur une tâche étroite à fort volume                                                                 |
| Données requises | Quelques exemples                                                                                                              | Un corpus documentaire                                                                                            | Centaines à milliers de paires annotées                                                                                   |
| 1er résultat     | <b>Heures</b>                                                                                                                  | <b>Jours</b>                                                                                                      | <b>Semaines</b>                                                                                                           |
| Profil de coût   | Faible : paiement à l'appel                                                                                                    | Moyen : embeddings + base vectorielle                                                                             | Élevé : entraînement + hébergement                                                                                        |
| Mise à jour      | Modifier le prompt                                                                                                             | Réindexer les documents                                                                                           | Ré-entraîner                                                                                                              |
| Exemple INS      | <i>Rédiger un communiqué de presse</i>                                                                                         | <i>Q&amp;R sur notes méthodologiques et métadonnées</i>                                                           | <i>Codification CITP nationale, petit modèle hébergé en interne</i>                                                       |

Durées et volumes de données : ordres de grandeur indicatifs.

Du bon à l'excellent · Optimisation des prompts | Atelier technique STG17



# Un parcours de décision guidé par vos résultats



## Contrôle de souveraineté


**Ces données peuvent-elles sortir de l'institut ?**

Sinon, seuls des fournisseurs sous votre contrôle juridique, ou des modèles ouverts auto-hébergés, sont éligibles.

**Quelle que soit la voie :**

relancer le même jeu d'évaluation et consigner le résultat.

# Optimiser le prompt de codification sur un jeu figé



## CE QUE REMET CHAQUE BINÔME



# Liste de contrôle du prompt excellent

## Évaluation



Critères de succès et score cible écrits



Jeu figé et versionné de 30 à 50 cas annotés par des experts

## Qualité



Métrique adaptée au type de tâche



Journal : un seul changement par version

## Variance



Version du modèle figée ; température choisie



Accord entre exécutions répétées mesuré

## Coût



Coût pour 1 000 documents estimé



Contenu stable en tête, pour le cache

## Gouvernance



Confidentialité et conditions d'usage vérifiées



Sorties vérifiées ; prompt versionné, avec un responsable

# Messages clés

## 01



### Mesurer avant de changer

Un jeu d'évaluation figé transforme les opinions en chiffres.

## 02



### Construire la reproductibilité

Figé, contraindre, tester les répétitions, vérifier avant publication.

## 03



### Concevoir pour le coût

Structure du prompt, cache et lots peuvent diviser la facture par dix.

DU BON À L'EXCELLENT

**Un bon prompt obtient une réponse.**

**Un excellent prompt obtient une  
réponse défendable.**



*Merci. Questions et échanges.*

# Sources



## ATELIER

Programme de l'atelier STG17, « Enjeux émergents, pratiques émergentes : innover dans la chaîne de valeur des données », version du 01/09/2026. BAD, UA STATAFRIC, NISR.

## PRINCIPES

Assemblée générale des Nations Unies (2014). Résolution 68/261, Principes fondamentaux de la statistique officielle.

## CLASSIFICATION

Organisation internationale du Travail (2012). Classification internationale type des professions, CIP-08.

## JUGES LLM

Zheng, L. et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. NeurIPS Datasets and Benchmarks Track.

## VARIANCE

Wang, X. et al. (2022). Self-Consistency Improves Chain of Thought Reasoning in Language Models. arXiv:2203.11171 (ICLR 2023).

## JETONS

OpenAI Help Center. What are tokens and how to count them?

## LANGUES

Petrov, A. et al. (2023). Language Model Tokenizers Introduce Unfairness Between Languages. NeurIPS 2023.

## CONTEXTE

Liu, N. F. et al. (2023). Lost in the Middle: How Language Models Use Long Contexts. Transactions of the ACL, 12 (2024).

*Les chiffres signalés « illustratif » ou « schéma » sont des exemples pédagogiques, pas des résultats mesurés.*