

# Sources de données non traditionnelles

*Le trésor caché — taxonomie, qualité, accès et éthique  
pour la statistique officielle*

---

Jour 3 · Au-delà de l'enquête | Session 1 · 09h00–10h30 | Exposé et laboratoire

Banque africaine de développement · Union africaine (STATAFRIC) · Institut national de la statistique du Rwanda



# La place de cette session dans la semaine

Cet exposé apporte les concepts ; les laboratoires des jours 3 à 5 les transforment en produits nationaux publiés.



## LE JOUR 3 EN DÉTAIL

09h00

Cette session

Taxonomie · qualité · accès · éthique

10h45

Labo : Ookla +  
WorldPop

Connectivité par région pondérée  
par la population

14h00

Moteurs à grande  
échelle

Ingestion, lakehouse, Spark,  
recherche

14h45

Labo : Ookla à  
l'échelle

Elasticsearch, geo\_shape, GitHub

Source : agenda de l'atelier technique STG17, « Emerging Issues, Emerging Practice » (BAD · UA STATAFRIC · NISR, version du 01/09/2026).

## À 10h30, vous serez capables de...



### Classer

Situer toute nouvelle source dans une taxonomie claire — six familles, trois processus de production.



### Juger l'adéquation à l'usage

Distinguer le concept cible de l'indicateur indirect et expliciter l'écart.



### Diagnostiquer le biais de couverture

Expliquer pourquoi le volume ne corrige pas le biais, et comment le détecter.



### Choisir un modèle d'accès

Comparer accès ouvert, achat, accord, collaboratif et obligation légale.



### Protéger la confidentialité

Appliquer des garde-fous juridiques, éthiques et techniques avant tout transfert.



### Évaluer une source réelle

Remplir en équipe un canevas d'évaluation et défendre le verdict.

## Six sections, un fil conducteur



01

### Pourquoi c'est important

Pressions sur les INS et mandat d'innover

8 min



02

### Taxonomie

Six familles de sources et ce qu'elles mesurent

15 min



03

### Qualité et biais

Cadres de qualité adaptés, paradoxe du big data

12 min



04

### Accès et partenariats

Cinq modèles d'accès, accords de partage

8 min



05

### Éthique et confidentialité

Droit, réidentification, les « Five Safes »

7 min



06

### Laboratoire et perspectives

Canevas d'évaluation, puis restitution

40 min

# 01

## Pourquoi c'est important

*Pourquoi un institut statistique africain devrait-il s'intéresser à des données qu'il n'a pas collectées ?*



# La demande dépasse la collecte traditionnelle

Quatre pressions convergent simultanément sur les instituts nationaux de statistique.

## CÔTÉ DEMANDE

# 231

indicateurs uniques dans le cadre mondial des ODD — la plupart à désagréger par sexe, âge, lieu et revenu

*« Ne laisser personne de côté » impose de voir les petites zones et les petits groupes hors de portée des échantillons nationaux.*



### Coût

Terrain, enquêteurs et relances absorbent des budgets stables ou en baisse.



### Délais

Recensement tous les ~10 ans, enquêtes tous les 3 à 5 ans : la décision précède souvent le chiffre.



### Granularité

Un échantillon national ne renseigne pas de façon fiable un district, une semaine ou un petit groupe.



### Fragilité

Épidémies, inondations, conflits interrompent le terrain au moment où l'information est la plus utile.

Sources : Division de statistique de l'ONU, cadre mondial d'indicateurs ODD ; cycles de recensement/enquête indicatifs, variables selon les pays.

# Le mandat d'innover est déjà écrit

Principes, stratégie continentale et infrastructures vont dans le même sens — sous conditions.

**2014**

## Principes fondamentaux ONU

Principe 5 : toutes sources possibles, choisies selon qualité, actualité, coût et charge des répondants.

**2018**

## SHaSA II adoptée

Le Conseil exécutif de l'UA adopte la stratégie continentale, mise en œuvre par 18 groupes techniques spécialisés.

**2020**

## Hub big data ONU, Kigali

Le Rwanda signe avec l'ONU un accord pour accueillir le Hub régional big data pour l'Afrique au NISR.

**2025**

## Plan d'action STG17

1re réunion annuelle (Kigali) : Bureau, TdR et Plan d'action 2025–2030 sur big data, données ouvertes et IA.



La condition commune : l'innovation n'est bienvenue que si la qualité, la confidentialité et l'indépendance professionnelle sont préservées.

Sources : AGNU A/RES/68/261 (2014) ; note conceptuelle de l'atelier STG17 (2026) ; UN-CEBD, Hub régional big data pour l'Afrique ([unstats.un.org/bigdata](https://unstats.un.org/bigdata)).

# Données conçues et données trouvées

Aucune n'est supérieure : leurs faiblesses sont opposées — c'est pourquoi elles se combinent bien.



## Traditionnelles (conçues)



## Non traditionnelles (trouvées)

|                             |                                     |                                          |
|-----------------------------|-------------------------------------|------------------------------------------|
| <b>Origine</b>              | Conçues pour mesurer                | Sous-produit d'une autre activité        |
| <b>Concepts</b>             | Définis par le statisticien         | Définis par le producteur des données    |
| <b>Population</b>           | Base de sondage connue              | Utilisateurs auto-sélectionnés, inconnus |
| <b>Délais</b>               | Des mois à des années               | Des heures à des jours                   |
| <b>Granularité</b>          | Limitée par la taille d'échantillon | Très fine — tuile, heure, produit        |
| <b>Coût marginal</b>        | Élevé par observation               | Faible une fois l'accès obtenu           |
| <b>Continuité</b>           | Garantie par le mandat              | Dépend d'un tiers                        |
| <b>Faiblesse principale</b> | Coût, délai, non-réponse            | Biais de couverture, instabilité         |

# 02

## Taxonomie

*Comment nommer, classer et comparer des sources qui n'ont jamais été conçues comme des statistiques ?*



# Qu'est-ce qu'une source « non traditionnelle » ?



**Définition de travail.** Données produites comme sous-produit d'une activité menée à une autre fin que la statistique — une transaction, un service, un capteur, une publication — et réutilisées pour produire des éléments probants statistiques.

## Classification de la CEE-ONU selon le processus de production



### D'origine humaine

**Des personnes consignent leurs expériences, souvent en ligne.**

Réseaux sociaux · recherches web · avis · cartographie participative · tests de débit



### Issues de processus

**Traces laissées par des processus commerciaux ou administratifs.**

Données de caisse et de carte · mobile money · CDR · factures électroniques



### Générées par machine

**Capteurs et appareils qui observent le monde physique.**

Imagerie satellitaire · compteurs intelligents · GPS et AIS · capteurs de qualité de l'air



**Test rapide :** si l'enregistrement existerait même si aucun statisticien ne le regardait jamais, la source est non traditionnelle.

Source : CEE-ONU (2013), *Classification of Types of Big Data*, équipe spéciale Big Data du HLG-MOS.

# La carte au trésor : six familles de sources

Regroupées selon ce qu'un INS manipule réellement. Nous ouvrons chaque coffre dans les diapositives suivantes.



Labo : jour 4 (LN)

1

**Imagerie satellitaire**

Sols, lumière, eau, bâti



Labo : jour 3 (Ookla)

2

**Mesure participative**

Connectivité, cartes, prix



3

**Caisse, transactions et télécoms**


Prix, dépenses, mobilité



4

**Moissonnage du web**

Prix en ligne, emplois, entreprises



5

**Capteurs et IoT**

Énergie, trafic, environnement



6

**Données citoyennes**

Réalités locales, voix, services

# Imagerie satellitaire et observation de la Terre



## DE QUOI S'AGIT-IL ?

Images optiques, radar et de lumières nocturnes issues de missions publiques (Sentinel, Landsat, VIIRS) et de fournisseurs commerciaux — mondiales, répétées et largement gratuites en moyenne résolution.

## OÙ LA TROUVER

Copernicus Sentinel-2

Landsat 8/9

NASA Black Marble

Google Earth Engine

## CE QU'ELLE PERMET DE MESURER

- ✓ Occupation du sol, surfaces et état des cultures
- ✓ Surfaces bâties et croissance urbaine
- ✓ Radiance nocturne : électrification, activité
- ✓ Inondations, sécheresse, plans d'eau
- ✓ Cartographie de la pauvreté, avec les enquêtes

## EXEMPLE DOCUMENTÉ

Jean et al. (Science, 2016) ont entraîné un modèle sur l'imagerie diurne et les lumières nocturnes pour prédire la consommation et les actifs des ménages dans cinq pays africains, dont le Rwanda.

## ! VIGILANCE

Le capteur voit un indicateur indirect, jamais le concept : la lumière n'est pas le PIB, le vert n'est pas le rendement. Calibrer sur le terrain et revalider.

10 m

résolution de Sentinel-2

~500 m

grille Black Marble (15")

1992–2013

archive DMSP-OLS

Sources : ESA Copernicus ; NASA Black Marble (Román et al., 2018) ; Jean et al. (2016), Science 353(6301).

# Mesure participative (crowdsourcing)



## DE QUOI S'AGIT-IL ?

Observations fournies volontairement par de nombreux utilisateurs via une application ou une plateforme — tests de débit, cartographie collaborative, prix signalés — puis agrégées.

## OÙ LA TROUVER

[Ookla Speedtest \(ouvert\)](#)[OpenStreetMap](#)[Applis de prix](#)[WorldPop \(auxiliaire\)](#)

## CE QU'ELLE PERMET DE MESURER

- ✓ Débit montant/descendant et latence par tuile
- ✓ Fracture numérique entre régions et trimestres
- ✓ Routes, bâtiments et équipements
- ✓ Prix de marché signalés par des bénévoles
- ✓ Disponibilité des services au niveau local

## EXEMPLE DOCUMENTÉ

Ookla publie chaque trimestre des tuiles d'environ 611 m (zoom 16) avec avg\_d\_kbps, avg\_lat\_ms, tests et appareils. Pondérées par WorldPop, elles donnent un indicateur régional de connectivité — le labo d'aujourd'hui.

## VIGILANCE

Les tests viennent de personnes qui choisissent de tester, souvent en ville et sur smartphone. Une tuile sans test n'est pas une tuile sans signal. Vérifier d'abord la couverture.

**~611 m**

côté d'une tuile à l'équateur

**Trimestriel**

depuis 2019

**CC BY-NC-SA**

licence v4.0, non commerciale

Sources : Ookla, *Global Fixed and Mobile Network Performance Maps* ([github.com/teamookla/ookla-open-data](https://github.com/teamookla/ookla-open-data)) ; WorldPop, Université de Southampton.

# Données de caisse, de transaction et de télécoms



## DE QUOI S'AGIT-IL ?

Enregistrements issus de processus commerciaux : fichiers de caisse, transactions par carte et mobile money, factures électroniques, et enregistrements détaillés des appels (CDR) des opérateurs.

## OÙ LA TROUVER

Fichiers de caisse

Opérateurs mobile money

E-facturation (fisc)

CDR / signalisation

## CE QU'ELLE PERMET DE MESURER

- ✓ Prix et quantités par produit (IPC)
- ✓ Chiffre d'affaires et prévisions immédiates
- ✓ Inclusion financière
- ✓ Présence et mobilité quotidienne
- ✓ Déplacements après un choc

## EXEMPLE DOCUMENTÉ

Le Ghana Statistical Service, Vodafone Ghana et Flowminder ont utilisé des CDR agrégés pour publier, dès avril 2020, des rapports de mobilité mesurant le respect des restrictions COVID-19 par district.

## ⚠ VIGILANCE

Seule l'activité formelle et enregistrée est visible. Espèces, commerce informel et non-abonnés disparaissent ; les clients d'un opérateur ne sont pas la population.

## Années 2000

premiers IPC sur données de caisse (Europe)

## 2018

accord GSS–Vodafone–Flowminder

## Agrégés

seuls les résultats quittent l'opérateur

Sources : UN Statistics Wiki, guide sur les données de téléphonie mobile, annexe 1.5 Ghana ; Flowminder (2020–2023) ; Blumenstock et al. (2015), Science 350(6264).

# Moissonnage du web et plateformes en ligne



## DE QUOI S'AGIT-IL ?

Collecte automatisée d'informations affichées publiquement en ligne — prix, offres d'emploi et annonces immobilières, sites d'entreprises — et données de plateformes et de recherche.

## OÙ LA TROUVER

Sites de e-commerce

Portails d'emploi

Annonces immobilières

Annuaire d'entreprises

## CE QU'ELLE PERMET DE MESURER

- ✓ Prix en ligne, mis à jour chaque jour
- ✓ Demande de travail par compétence et métier
- ✓ Loyers et offre de logements
- ✓ Répertoires et activité des entreprises
- ✓ Signaux précoces de chocs de prix

## EXEMPLE DOCUMENTÉ

Le Billion Prices Project du MIT a collecté chaque jour les prix en ligne de détaillants dans des dizaines de pays et produit des séries d'inflation qui suivaient — et parfois anticipaient — les IPC officiels.

## ⚠ VIGILANCE

Les sites changent du jour au lendemain ; une offre n'est pas une vente ; les vendeurs urbains et formels dominent. « Visible publiquement » ne veut pas dire « réutilisable légalement ».

**Quotidien**

fréquence possible

**Robots.txt**

et conditions d'utilisation s'appliquent

**Offre ≠ vente**

l'écart central de l'indicateur

Sources : Cavallo et Rigobon (2016), « The Billion Prices Project », *Journal of Economic Perspectives* 30(2) ; travaux CEE-ONU / SSE sur l'intelligence web.

# Capteurs, IoT et télématique



## DE QUOI S'AGIT-IL ?

Instruments fixes ou mobiles qui mesurent en continu : compteurs intelligents d'électricité et d'eau, compteurs de trafic, stations de qualité de l'air, traceurs GPS, transpondeurs de navires (AIS).

## OÙ LA TROUVER

Compteurs intelligents

Suivi des navires AIS

Réseaux qualité de l'air

GPS de flottes

## CE QU'ELLE PERMET DE MESURER

- ✓ Consommation d'électricité et d'eau
- ✓ Escales et flux du commerce maritime
- ✓ Volumes de trafic et congestion
- ✓ Exposition à la pollution
- ✓ Indicateurs d'activité à haute fréquence

## EXEMPLE DOCUMENTÉ

Les signaux AIS des navires sont utilisés au niveau international pour estimer en temps quasi réel l'activité portuaire et les volumes échangés, des semaines avant les statistiques douanières.

## ⚠ VIGILANCE

Les capteurs dérivent, tombent en panne, sont déplacés. Une rupture de série est souvent un événement matériel, pas économique : les métadonnées des appareils font partie de la statistique.

### Minutes

intervalle de transmission  
typique

### Journaux

nécessaires pour expliquer  
les ruptures

### Eau, énergie

services publics :  
partenaires naturels

Sources : UN Global Platform / travaux du UN-CEBD sur les données AIS ; CEE-ONU (2014), dimensions temporelles et de validité.

# Données générées par les citoyens



## DE QUOI S'AGIT-IL ?

Données que des personnes ou leurs organisations produisent délibérément pour suivre les questions qui les concernent — enquêtes communautaires, cartographie participative, science citoyenne, fiches d'évaluation.

## OÙ LA TROUVER

Suivi par la société civile

Science citoyenne

Cartographie  
participative

Fiches communautaires

## CE QU'ELLE PERMET DE MESURER

- ✓ Services publics vus par les usagers
- ✓ Conditions environnementales locales
- ✓ Groupes absents des registres
- ✓ Écarts liés au genre et au handicap
- ✓ Indicateurs ODD sans autre source

## EXEMPLE DOCUMENTÉ

Au Ghana, des observations de science citoyenne sur les déchets marins ont servi à éclairer la politique environnementale et le suivi des ODD — un exemple cité autour du Cadre de Copenhague.

## ⚠ VIGILANCE

Précieuses pour la voix et le détail local, mais rarement représentatives. Protocoles, formation et métadonnées décident de leur entrée en statistique officielle.

2024

Cadre de Copenhague  
salué (CSNU 55)

2025

v1.0 approuvée (CSNU 56)

La voix

comme atout de qualité

Sources : Collaborative on Citizen Data, Copenhagen Framework on Citizen Data v1.0 (Commission de statistique, 56e session, 2025) ; IISD SDG Knowledge Hub (2024).

# Les six familles comparées d'un coup d'œil

Appréciation indicative pour un INS africain type — à confronter à l'expérience de votre pays.

|                                                                                                                    | Actualité | Granularité | Couverture en Afrique | Facilité d'accès | Risque de confidentialité |
|--------------------------------------------------------------------------------------------------------------------|-----------|-------------|-----------------------|------------------|---------------------------|
|  Imagerie satellitaire            | ● ● ●     | ● ● ●       | ● ● ●                 | ● ● ●            | ● ● ●                     |
|  Mesure participative             | ● ● ●     | ● ● ●       | ● ● ●                 | ● ● ●            | ● ● ●                     |
|  Caisse, transactions et télécoms | ● ● ●     | ● ● ●       | ● ● ●                 | ● ● ●            | ● ● ●                     |
|  Moissonnage du web               | ● ● ●     | ● ● ●       | ● ● ●                 | ● ● ●            | ● ● ●                     |
|  Capteurs et IoT                  | ● ● ●     | ● ● ●       | ● ● ●                 | ● ● ●            | ● ● ●                     |
|  Données citoyennes               | ● ● ●     | ● ● ●       | ● ● ●                 | ● ● ●            | ● ● ●                     |

Appréciation indicative de l'auteur, à visée pédagogique : ●●● = élevé, ●○○ = faible. La couverture désigne la part de la population que la source reflète habituellement.

# 03

## Qualité et biais

*Avec dix millions d'enregistrements, comment une source peut-elle se tromper sur tout le monde ?*



# Étendre les cadres de qualité aux données trouvées

La CEE-ONU propose trois « hyperdimensions », évaluées aux phases d'entrée, de traitement et de sortie.




Des questions nouvelles : cette source existera-t-elle encore dans trois ans ? Quelle solution de repli si le fournisseur se retire ?

Source : CEE-ONU (2014), *A Suggested Framework for the Quality of Big Data*, équipe spéciale sur la qualité du big data (HLG-MOS).

# Le paradoxe du big data : le volume ne corrige pas le biais

## Décomposition de Meng de l'erreur de toute moyenne d'échantillon



### EXEMPLE · ÉLECTION AMÉRICAINE DE 2016

2 300 000

réponses auto-déclarées (1 % des électeurs)

≈ 400

entretiens aléatoires — pour une corrélation de défaut d'à peine  $-0,005$

### CE QUE CELA SIGNIFIE POUR LES INS


- Les intervalles de confiance du big data sont étroits — et faux.
- Une petite enquête aléatoire peut battre une énorme source biaisée.
- Mesurer  $\rho$ , même grossièrement, avant de publier des niveaux.

Source : Meng, X.-L. (2018), « Statistical paradises and paradoxes in big data (I) », *Annals of Applied Statistics* 12(2) : 685–726.

# Qui manque ? La fracture numérique comme biais

Toute source fondée sur l'usage d'internet ou du smartphone hérite de ces écarts.

Part de la population utilisant internet, Afrique, 2024 (%)

**36 %****contre 74 %**

usage d'internet, Afrique vs monde, 2025

**2,5x****urbain / rural**

taux urbain rapporté au taux rural, 2024

**63 %****couverts, non connectés**

Africains couverts par le haut débit mobile sans l'utiliser

Sources : UIT (2025), *State of Digital Development in Africa* ; UIT, *Facts and Figures 2025* ; GSMA Intelligence, *The Mobile Economy Africa 2026*.

Sources de données non traditionnelles · Le trésor caché · Atelier STG17

# Traiter le biais : diagnostiquer, corriger, recadrer

Illustré par l'indicateur de connectivité Ookla que vous construirez après la pause.



# Nommer le concept, l'indicateur indirect et l'écart

Les problèmes de validité sont rarement techniques : ils sont conceptuels et doivent être écrits.

## 🎯 CONCEPT CIBLE

## 👁️ INDICATEUR OBSERVÉ

## ⚠️ ÉCART À DOCUMENTER

Activité économique locale

→ Radiance des lumières nocturnes

→ Saturation urbaine, torchères, activité informelle non éclairée, agriculture

Qualité de l'accès internet

→ Tests de débit participatifs

→ Un test n'est pas un usager ; auto-sélection ; tuile vide ≠ absence de signal

Population présente

→ Cartes SIM actives par antenne

→ Multi-SIM, téléphones partagés, enfants et non-connectés

Prix à la consommation

→ Prix affichés en ligne

→ Une offre n'est pas une transaction ; marchés informels absents

Opinion publique

→ Tonalité des réseaux sociaux

→ Opinion des utilisateurs actifs, amplifiée par les algorithmes

# 04

## Accès et partenariats

*Les données existent. Pourquoi les obtenir est-il la partie la plus difficile du projet ?*



# Cinq façons d'obtenir des données détenues par d'autres

Du plus rapide à mettre en place au plus durable. Les programmes matures en combinent plusieurs.

*plus rapide à lancer*

*plus durable*



## Données ouvertes

Publiées sous licence : archives satellitaires, tuiles Oukla, OpenStreetMap.

✓ Immédiat

⚠ Limites de licence



## Achat

Licence acquise auprès d'un vendeur ou agrégateur pour un usage défini.

✓ Rapide, propre

⚠ Coût, dépendance



## Accord bilatéral

Protocole avec une entreprise : périmètre, produits, garanties, bénéfice mutuel.

✓ Sur mesure

⚠ Négociation lente



## Collaboratif de données

Plusieurs détenteurs mutualisent leurs données via un tiers de confiance.

✓ Échelle, neutralité

⚠ Gouvernance lourde



## Obligation légale

La loi statistique oblige les détenteurs à fournir les données.


✓ Durable

⚠ Lent, politique

# Comment les données circulent : un choix clé

Quatre modes techniques d'accès, du plus au moins exposant pour les données individuelles.

EXPOSITION  
INDIVIDUELLE



## Transfert de microdonnées

*Enregistrements copiés à l'INS*

Souplesse maximale ; risque de divulgation le plus élevé ; rarement accepté.



## Indicateurs pré-agrégés

*Le fournisseur calcule les tableaux convenus*

Simple et sûr ; la méthode devient une boîte noire difficile à modifier.



## Code vers les données

*Le code de l'INS tourne derrière le pare-feu du fournisseur*

Seuls des agrégats vérifiés sortent. Modèle de référence pour les télécoms.



## Technologies de confidentialité

*Enclaves, confidentialité différentielle, analyse fédérée*

Protection forte ; exige des compétences et infrastructures avancées.

## RÈGLE D'OR

**Déplacer le code vers les données, pas l'inverse.**

*Agréger tôt, de façon irréversible, et seulement ce que la question exige.*

# Étude de cas : données mobiles au Ghana

Ghana Statistical Service · Vodafone Ghana · Fondation Flowminder

- 2017**  
Premiers contacts au Forum mondial de l'ONU sur les données, Le Cap
- Déc. 2018**  
Accord signé ; chaîne FlowKit installée derrière le pare-feu de l'opérateur
- Avr. 2020**  
Premier rapport de mobilité COVID-19, quelques semaines après les restrictions
- Janv. 2023**  
Signature de la phase 2 du partenariat « Data for Good »

## LES FACTEURS DE RÉUSSITE

-  Code vers les données : seuls des résultats agrégés et anonymisés sortent.
-  Comité de pilotage présidé par le Statisticien général, avec la société civile.
-  Critères convenus à l'avance pour tout partage avec des tiers.
-  Renforcement durable des capacités des data scientists du GSS.



Construire le partenariat avant la crise : la chaîne existait avant la COVID-19, les résultats sont arrivés en semaines, non en mois.

Sources : UN Statistics Wiki, guide sur les données mobiles, annexe 1.5 (Ghana) ; Flowminder (2020, 2023) ; SDSN TREnds / C4DC.

Sources de données non traditionnelles · Le trésor caché · Atelier STG17

# Dix clauses indispensables d'un accord de partage

Une liste à apporter à la table des négociations — et au guide de référence STG17 sur la gouvernance des données.

1

**Finalité**

Usage statistique seul, précisément défini.

3

**Base juridique**

Loi statistique, loi sur les données personnelles, consentement.

5

**Sécurité**

Stockage, contrôle d'accès, traçabilité, notification des violations.

7

**Droits de publication**

Droit de publier résultats et méthodes ; délai de relecture.

9

**Durée et sortie**

Durée, renouvellement, préavis, suppression, solution de repli.

2

**Spécification des données**

Champs, granularité, fréquence, historique et format.

4

**Agrégation et seuils**

Effectifs minimaux ; ce qui peut sortir de quel environnement.

6

**Rôles et coûts**

Qui fait quoi ; qui paie ; contributions en nature.

8

**Propriété intellectuelle**

Propriété des données brutes, du code et des indicateurs dérivés.

10

**Gouvernance**

Comité de pilotage, règlement des différends, revue périodique.

# 05

## Éthique et confidentialité

*Techniquement possible, juridiquement permis,  
socialement acceptable : les trois sont-ils vrais ?*



# Quatre niveaux de règles s'appliquent simultanément

Un INS doit vérifier chaque niveau avant tout transfert d'enregistrement.



## MONDIAL

**Principes fondamentaux de la statistique officielle**

Principe 5 : toute source, choisie selon qualité, actualité, coût et charge. Principe 6 : données individuelles strictement confidentielles.



## CONTINENTAL

**Charte africaine de la statistique • Convention de Malabo**

Indépendance professionnelle et confidentialité ; traité de l'UA sur les données personnelles en vigueur depuis le 8 juin 2023.



## NATIONAL

**Loi statistique • Loi sur les données personnelles**

Pouvoirs d'accès à des fins statistiques ; base légale ; autorité de contrôle ; règles sectorielles (télécoms, banque).



## CONTRACTUEL

**Accords • Conditions d'utilisation • Licences**

Ex. : données ouvertes Ookla sous CC BY-NC-SA 4.0 : attribution, pas d'usage commercial, partage à l'identique.

Sources : AGNU A/RES/68/261 (2014) ; Charte africaine de la statistique (2009) ; Convention de Malabo (2014, en vigueur 2023) ; licence Ookla.

Sources de données non traditionnelles • Le trésor caché • Atelier STG17

# L'anonymisation est plus fragile qu'il n'y paraît

UNIQUE DANS LA FOULE

4

points lieu–heure

suffisaient à isoler

95 %

*des 1,5 million de personnes d'un jeu de données de mobilité téléphonique — sans aucun nom.*



## Réidentification individuelle

Des combinaisons rares de lieux et d'heures trahissent une personne, même sans nom ni numéro.



## Préjudice collectif

Des agrégats peuvent exposer une communauté — déplacés, minorités, quartiers informels.



## Détournement de finalité

Des données partagées pour la statistique ne doivent jamais servir à la surveillance, à la répression ou au ciblage commercial.



## Effet mosaïque

Des tableaux anodins, combinés à d'autres données publiques, révèlent ce que chacun cachait.

Source : de Montjoye, Y.-A., Hidalgo, C., Verleysen, M. et Blondel, V. (2013), « Unique in the Crowd », *Scientific Reports* 3 : 1376.

# Les « Five Safes » : un cadre pour un accès sécurisé

Le risque se gère en combinant cinq contrôles — aucun ne suffit seul.



 Les contrôles se compensent : des données plus riches ne sont acceptables que dans un environnement plus sûr, avec des personnes formées et un contrôle des résultats.

Source : Desai, T., Ritchie, F. et Welpton, R. (2016), « Five Safes: designing data access for research », UWE Economics Working Paper 1601.

# Les questions éthiques : avant, pendant, après

Assez courtes pour chaque revue de projet ; assez fortes pour arrêter un mauvais projet.

## AVANT

### Conception et accès

- ? La finalité d'intérêt public est-elle claire ?
- ? Quelle base légale, et qui l'a validée ?
- ? Les personnes concernées jugeraient-elles l'usage raisonnable ?
- ? Existe-t-il une source moins intrusive ?

## PENDANT

### Traitement

- ? Les données sont-elles minimisées et agrégées au plus tôt ?
- ? Qui voit quoi, où, et est-ce tracé ?
- ? Les modèles sont-ils documentés et reproductibles ?
- ? Les petites cellules sont-elles masquées ?

## APRÈS

### Publication et usage

- ? Les limites sont-elles publiées aussi visiblement que les résultats ?
- ? Un résultat peut-il nuire à un groupe ?
- ? Qui devient invisible dans ces données ?
- ? Quand les données brutes seront-elles supprimées ?

# 06

## Laboratoire et perspectives

*Votre équipe peut-elle décider, en 30 minutes, si  
une source est apte à un usage officiel ?*



# Défi d'équipe : cette source est-elle adaptée ?

30 minutes en équipe · 10 minutes de restitution · un canevas par équipe.

## A Connectivité par région

Le ministère des TIC veut un indicateur infranational trimestriel de qualité internet.

 *Tuiles Ookla + WorldPop*

## B Activité économique locale

Le Plan demande des estimations annuelles d'activité par district entre deux enquêtes.

 *Lumières nocturnes VIIRS Black Marble*

## C Suivi des prix alimentaires

L'unité d'alerte précoce veut des prix hebdomadaires sur les principaux marchés.

 *Moissonnage web + appli commerçants*

## D Déplacements après inondation

L'agence de gestion des catastrophes veut savoir où les gens sont allés dans les deux semaines.

 *CDR d'opérateur + satellite*

## DÉROULÉ

**5'** Choisir un scénario, cadrer la question

**20'** Remplir le canevas d'évaluation

**5'** Arrêter un verdict et un risque clé

**10'** Plénière : deux minutes par équipe

*Verdict : publier · diagnostic seul · inadapté*

# Le canevas d'évaluation des sources

Remplir les cases 1 à 8 dans l'ordre. La case 8 doit se justifier par les cases 1 à 7.

## 1 Question politique

*Qui a besoin de quoi, quand, à quel niveau ?*

-----  
-----



## 2 Concept cible

*Que faut-il mesurer exactement ?*

-----  
-----



## 3 Indicateur et source

*Qu'observe-t-on, par qui, à quelle fréquence ?*

-----  
-----



## 4 Qui manque ?

*Lacunes de couverture et auto-sélection*

-----  
-----



## 5 Modèle d'accès

*Ouvert, achat, accord, collaboratif, loi*

-----  
-----



## 6 Risque juridique et éthique

*Base légale, réidentification, préjudice collectif*

-----  
-----



## 7 Validation

*Référence à laquelle se comparer*

-----  
-----



## 8 Verdict

*Publier · diagnostic seul · inadapté — pourquoi ?*

-----  
-----



# Exemple : scénario A — connectivité par région

Un canevas rempli à titre d'illustration, à affiner dans le labo Ookla après la pause.

## 1 Question politique

Ministère des TIC : qualité internet trimestrielle par région, pour cibler l'investissement.

## 2 Concept cible

Qualité de l'internet mobile vécue par la population de chaque région.

## 3 Indicateur et source

Moyennes Ookla par tuile (débit, latence, tests, appareils), trimestrielles, ~611 m.

## 4 Qui manque ?

Ruraux et non-utilisateurs de smartphone ; tuiles sans test ; tests lancés quand ça rame.

## 5 Modèle d'accès

Données ouvertes (CC BY-NC-SA 4.0) — sans négociation ; licence respectée.

## 6 Risque juridique et éthique

Faible : tuiles agrégées, pas de données personnelles. Citer Ookla ; partage à l'identique.

## 7 Validation

Questions TIC du recensement/enquête ; cartes du régulateur ; indicateurs opérateurs.

## 8 Verdict

Publier en expérimental, pondéré WorldPop, limites explicites ; privilégier évolutions et classement.

# Intégrer, pas remplacer

La question n'est jamais « nouvelle source ou enquête ? », mais « que fait chacune le mieux, et comment les combiner ? »

**A**

## Variable auxiliaire

La nouvelle source est une covariable d'un modèle bâti sur l'enquête — petits domaines, cartes de pauvreté.

LN + grappes EDS

**B**

## Calage et étalonnage

La source à haute fréquence donne le profil de la série ; la statistique officielle ancre le niveau.

Cartes + enquête commerce

**C**

## Prévision immédiate

La nouvelle source estime le présent ; la statistique traditionnelle confirme et révisé ensuite.

Électricité + PIB trimestriel

**D**

## Substitution directe

Là où la qualité est démontrée, la nouvelle source remplace une partie de la collecte.

Données de caisse dans l'IPC


exigences croissantes de qualité et de sécurité →



Règle d'or : la source traditionnelle ancre la vérité ; la source non traditionnelle apporte vitesse et détail.

# Du pilote à la production

## PARCOURS DE MATURITÉ EN CINQ ÉTAPES



### CETTE SEMAINE ALIMENTE LE PLAN D'ACTION STG17 2025–2030

2.1.1

Guide nouvelles sources

3.1

Partenariats secteur privé

4.3

Guide gouvernance des données

Source : agenda de l'atelier technique STG17 (2026), tableau « Produit de l'atelier → activité du Plan d'action STG17 ».

## Cinq idées à rapporter dans votre institut



01

**Le trésor est réel**

Actualité, granularité et couverture que les données conçues ne peuvent offrir seules.



02

**Le biais est le risque central**

Volume n'est pas représentativité. Toujours demander qui manque, et comparer.



03

**L'accès est une relation**

Bâtir les partenariats avant les crises ; déplacer le code ; prévoir la sortie.



04

**La confiance est l'infrastructure**

Droit, éthique et transparence font durer l'innovation.



05

**Combiner, ne pas remplacer**

Les nouvelles sources apportent vitesse et détail ; les sources officielles ancrent la vérité.

# Glossaire des termes essentiels

## Données non traditionnelles

Données produites à une fin non statistique puis réutilisées comme éléments probants.

## Biais de couverture

Erreur due à des unités observées systématiquement différentes de la population cible.

## Calage

Ajustement des poids pour reproduire des totaux connus issus d'une source fiable.

## CDR (enregistrement d'appel)

Journal d'opérateur d'un événement téléphonique : antenne, heure, durée.

## Code vers les données

Mode d'accès où le code de l'analyste tourne chez le fournisseur.

## Indicateur indirect (proxy)

Variable observable utilisée à la place d'un concept non mesurable directement.

## Corrélation de défaut ( $\rho$ )

Corrélation entre le fait d'être enregistré et la valeur ; nulle en tirage aléatoire.

## Estimation sur petits domaines

Estimations par modèle à fine échelle, combinant enquête et données auxiliaires.

## Quadkey

Chaîne identifiant une tuile web-Mercator ; identifiant des tuiles Oookla.

## Five Safes

Projets, personnes, environnements, données, résultats — cadre d'accès sécurisé.

# Sources et lectures complémentaires

- BAD, UA STATAFRIC et NISR (2026). Atelier technique STG17 — Emerging Issues, Emerging Practice. Agenda, v. 01/09/2026.
- Blumenstock, J., Cadamuro, G. & On, R. (2015). Predicting poverty and wealth from mobile phone metadata. *Science* 350(6264).
- Cavallo, A. & Rigobon, R. (2016). The Billion Prices Project. *Journal of Economic Perspectives* 30(2).
- Collaborative on Citizen Data (2025). The Copenhagen Framework on Citizen Data, v1.0. Commission de statistique de l'ONU, 56e session.
- de Montjoye, Y.-A. et al. (2013). Unique in the Crowd: the privacy bounds of human mobility. *Scientific Reports* 3: 1376.
- Desai, T., Ritchie, F. & Welpton, R. (2016). Five Safes: designing data access for research. *UWE Working Paper* 1601.
- GSMA Intelligence (2026). The Mobile Economy Africa 2026.
- UIT (2025). Facts and Figures 2025 ; State of Digital Development in Africa 2025.

- Jean, N. et al. (2016). Combining satellite imagery and machine learning to predict poverty. *Science* 353(6301).
- Meng, X.-L. (2018). Statistical paradises and paradoxes in big data (I). *Annals of Applied Statistics* 12(2): 685–726.
- Ookla. Speedtest Global Fixed and Mobile Network Performance Maps. [github.com/teamookla/ookla-open-data](https://github.com/teamookla/ookla-open-data).
- Román, M.O. et al. (2018). NASA's Black Marble nighttime lights product suite. *Remote Sensing of Environment* 210.
- Assemblée générale des Nations Unies (2014). Principes fondamentaux de la statistique officielle, A/RES/68/261.
- Division de statistique de l'ONU. Guide méthodologique sur les données de téléphonie mobile, annexe 1.5 (Ghana). *UN Statistics Wiki*.
- CEE-ONU (2013). Classification of Types of Big Data ; CEE-ONU (2014). A Suggested Framework for the Quality of Big Data.
- Union africaine (2009). Charte africaine de la statistique ; UA (2014). Convention sur la cybersécurité et la protection des données à caractère personnel.

# Merci

*Le trésor, ce ne sont pas les données : ce sont les décisions qu'elles permettent — en toute sécurité.*

**Q1**

Quelle source non traditionnelle votre institut est-il le plus près d'utiliser en statistique officielle ?

**Q2**

Quel est le principal obstacle : l'accès, les compétences, le droit ou la confiance ?

**Q3**

Quel partenariat le STG17 pourrait-il aider votre pays à reproduire ?

