

Passer à l'échelle

Technologies big data pour les systèmes statistiques


Des fichiers bruts aux indicateurs de confiance : les six briques de toute plateforme de données

Jour 3 · Au-delà de l'enquête : données non traditionnelles et technologies pour les traiter


Banque africaine de développement · Union africaine (STATAFRIC) · Institut national de la statistique du Rwanda



La place de cette présentation dans le jour 3



À 14 h 30, vous devriez être capables de...



Source : programme de l'atelier STG17, jour 3 ; Plan d'action STG17 2025–2030, activité 4.2.

Passer à l'échelle · Technologies big data pour les systèmes statistiques · STG17

Pourquoi les INS ont besoin de moteurs

≈ 611 m

Tuiles Ookla Speedtest

Tuiles de niveau 16, réseaux fixe et mobile, chaque trimestre depuis 2019

≈ 3 milliards

Grille WorldPop à 100 m

Calcul : ≈ 30 millions de $\text{km}^2 \times 100$ cellules par km^2 , par couche et par an

Quotidien

Radiance Black Marble

Lumières nocturnes VNP46A2 à ~ 500 m (15 secondes d'arc)

Le mur de la mémoire — et trois façons de le franchir



Tient aisément en mémoire vive

pandas, R — règle empirique : RAM $\approx 5\text{--}10\times$ la taille des données



Tient sur le disque d'une machine

DuckDB, Polars — lecture des colonnes Parquet, hors mémoire



Dépasse une machine ou doit être partagé

Stockage objet, Spark, lakehouse




Doit répondre vite à des requêtes interactives

Moteur de recherche : Elasticsearch

Sources : Ookla Open Data (GitHub) ; WorldPop ; NASA Black Marble ; W. McKinney, « Apache Arrow and the 10 things I hate about pandas » (2017).

Les six briques de toute plateforme de données



Transversales : elles couvrent les quatre briques ci-dessus

SECTION 01 SUR 06

01

Ingestion

*Comment les données entrent-elles dans le système
— et restent-elles fiables dès le premier octet ?*



Cinq façons de faire entrer les données



Transfert par lots

Fichiers complets selon un calendrier

EXEMPLE

Tuiles Ookla : Parquet trimestriel depuis un bucket S3 public

Heures-jours



Appel d'API

Requêtes programmées vers un fournisseur

EXEMPLE

Lumières nocturnes via NASA Earthdata ou Google Earth Engine

Minutes-jours



Capture des changements

Seules les lignes nouvelles ou modifiées sont copiées

EXEMPLE

Registres fiscaux, d'entreprises et d'état civil

Minutes



Streaming

Événements en flux continu dans un journal (Kafka)

EXEMPLE

Collecte de prix en ligne, capteurs, événements réseau

Secondes



Dépôt sécurisé

Transfert chiffré et journalisé

EXEMPLE

Microdonnées partenaires, ex. extraits d'opérateurs télécoms

Selon l'accord

Délais indicatifs. Bucket Ookla : `s3://ookla-open-data` (AWS Open Data Registry).

Passer à l'échelle · Technologies big data pour les systèmes statistiques · STG17

Le contrat d'ingestion : cinq règles à l'entrée

1

Ne jamais modifier les données brutes

Conserver les octets tels que reçus ; les corrections se font en aval.

2

Tracer la provenance

Source, URL, date et licence (Ookla : CC BY-NC-SA 4.0).

3

Vérifier l'intégrité

Sommes de contrôle, nombre de lignes et de fichiers attendus par période.

4

Contrôler le schéma

Ookla a ajouté des colonnes en 2022-23 : détecter la dérive, jamais en silence.

5

Rendre les chargements idempotents

Relancer un même trimestre donne le même résultat, sans doublons.

ENREGISTREMENT DE PROVENANCE (ILLUSTRATIF)

```
# provenance.json - un par fichier brut
{
  "source": "Speedtest by Ookla",
  "layer": "mobile",
  "period": "2025-Q4",
  "uri": "s3://ookla-open-data/
    parquet/performance/type=mobile/
    year=2025/quarter=4/",
  "retrieved_at": "2026-01-15T08:12Z",
  "licence": "CC BY-NC-SA 4.0",
  "sha256": "9f2c...e41a",
  "schema_version": "2023-Q3",
  "loaded_by": "pipeline v1.4.0"
}
```

Source : *documentation Ookla Open Data (historique des colonnes et licence).*

SECTION 02 SUR 06

02

Stockage

Où conserver les données pour qu'elles soient peu coûteuses, rapides à lire et impossibles à perdre ?



Stockage distribué : découper et répliquer



Partitionner

Les gros fichiers sont découpés en blocs de taille fixe — 128 Mo par défaut dans HDFS — répartis sur les nœuds.




Répliquer

Chaque bloc est stocké sur trois nœuds par défaut. La panne matérielle est considérée comme normale.



Calculer sur place


Envoyer le code vers les données, pas l'inverse : la clé de la vitesse à grande échelle.



Source : guide Apache Hadoop « HDFS Architecture » (taille de bloc et facteur de réplication par défaut).

Le format de fichier est un choix de performance

Octets lus pour une requête analytique (CSV = 100)



Lire des colonnes, pas des lignes

Une vitesse moyenne pondérée n'utilise que 2 des 11 colonnes des fichiers Ookla récents.



Compresser les valeurs proches

Dans une colonne, les valeurs voisines se ressemblent : la compression est bien meilleure.



Ignorer l'inutile

Les min/max par groupe de lignes permettent de sauter des blocs entiers (predicate pushdown).

Ordres de grandeur illustratifs, pas un banc d'essai. Sources : documentation Apache Parquet ; schéma Ookla Open Data.

Entrepôt, lac, lakehouse



Entrepôt de données

CONTENU

Tables structurées et curées

SCHÉMA

Schéma imposé à l'écriture

ATOUT

SQL rapide, gouvernance forte

POINT DE VIGILANCE

Rigide ; coûteux à faire grandir

EXEMPLES

BigQuery, Snowflake, PostgreSQL



Lac de données

CONTENU

Fichiers bruts, tout format

SCHÉMA

Schéma interprété à la lecture

ATOUT

Bon marché, souple, illimité

POINT DE VIGILANCE

Devient un « marécage » sans discipline

EXEMPLES

Stockage objet + Parquet, GeoTIFF, HDF5



Lakehouse

CONTENU

Du brut au curé, en un seul lieu

SCHÉMA

À la lecture + tables contrôlées

ATOUT

Transactions, voyage dans le temps, évolution du schéma

POINT DE VIGILANCE

Exige une maturité en ingénierie

EXEMPLES

Apache Iceberg, Delta Lake, Apache Hudi

Source : Armbrust et al., « Lakehouse: A New Generation of Open Platforms... », CIDR 2021.

Le modèle médaillon appliqué à nos données



Contrôle qualité à chaque flèche : chaque zone a un responsable, un contrat de schéma et des tests. Rien n'avance tant qu'ils ne sont pas validés.

Ce qu'apporte un format de table lakehouse



Transactions ACID

Des écritures simultanées ne laissent jamais une table incohérente.



Voyage dans le temps

Interroger une table telle qu'elle était à une date passée.



Évolution du schéma

Ajouter une colonne sans réécrire l'historique.



Élagage des partitions

Une requête sur un trimestre ignore tous les autres.

SPARK SQL + APACHE ICEBERG

```
-- La table exactement telle qu'elle  
-- était lors de la publication du T2  
SELECT admin1, dl_kbps_weighted  
FROM lake.gold.connectivity  
TIMESTAMP AS OF '2026-07-15 00:00:00'  
WHERE year = 2026 AND quarter = 2;
```

Pourquoi c'est utile au statisticien

Une révision s'explique en rejouant l'état exact des entrées d'un chiffre publié.

03


Traitement distribué

Comment cent machines calculent-elles une statistique comme si elles n'en faisaient qu'une ?



MapReduce : l'idée au cœur de chaque moteur

Exemple — débit descendant moyen pondéré par les tests, par région, à partir des tuiles Ookla




Shuffle = l'étape réseau coûteuse



Ne jamais faire la moyenne des moyennes. Chaque tuile Ookla est déjà une moyenne sur un nombre de tests différent. Transportez sommes et effectifs et divisez à la fin : c'est correct et parfaitement parallèle. Médianes et quantiles ne se décomposent pas ainsi : les moteurs les approchent.

Apache Spark : comment un traitement s'exécute



Partitions

Les données sont découpées ; une tâche traite une partition.

Évaluation paresseuse

Les transformations sont enregistrées ; une action (write, count) déclenche le calcul.

Optimiseur (Catalyst)

Réécrit tout le plan : filtres au plus tôt, choix des jointures.

Shuffle

Regroupements et jointures déplacent les données sur le réseau : le goulot habituel.

Sources : documentation Apache Spark (Cluster Mode Overview) ; Zaharia et al., Communications of the ACM, 2016.

Passer à l'échelle · Technologies big data pour les systèmes statistiques · STG17

Spark en pratique : un indicateur de connectivité

PYSPARK

```
from pyspark.sql import SparkSession, functions as F
spark = SparkSession.builder.appName("connectivity").getOrCreate()

# 1. Lire les tuiles validées (argent), déjà rattachées aux régions
tiles = spark.read.parquet("s3://nso-lake/silver/ookla_admin/")

# 2. Débit moyen pondéré par les tests + diagnostics de couverture
kpi = (tiles
      .filter(F.col("tests") > 0)
      .groupBy("country", "admin1", "year", "quarter")
      .agg((F.sum(F.col("avg_d_kbps") * F.col("tests"))
            / F.sum("tests")).alias("dl_kbps_weighted"),
           F.sum("tests").alias("n_tests"),
           F.countDistinct("quadkey").alias("n_tiles")))

# 3. Publier en zone or, un dossier par trimestre
kpi.write.mode("overwrite") \
      .partitionBy("year", "quarter") \
      .parquet("s3://nso-lake/gold/connectivity/")
```

Identique à toute échelle

Même script sur un échantillon (mode local) ou sur tout un historique continental. Seule la taille du cluster change.

La statistique d'abord

n_tests et n_tiles accompagnent l'estimation : les chiffres régionaux trop fragiles sont signalés avant publication.

Une grammaire familière

Filtrer, regrouper, agréger, écrire : les mêmes verbes qu'en SQL, R dplyr ou pandas.

Noms de colonnes conformes au schéma Ookla Open Data ; chemins et noms de tables illustratifs.

Passer à l'échelle · Technologies big data pour les systèmes statistiques · STG17

Lots ou flux : choisir le modèle temporel



Par lots (batch)

Données bornées, traitées selon un calendrier

- Délai : heures à jours
- Simple à comprendre et à relancer
- Adapté aux statistiques mensuelles, trimestrielles et annuelles
- Outils : Spark, DuckDB, dbt, entrepôts SQL




En flux (streaming)

Données sans fin, traitées en continu

- Délai : secondes
- Fenêtres, watermarks et temps d'événement
- Adapté au nowcasting, au suivi, aux prix en ligne
- Outils : Apache Kafka, Apache Flink, Spark Structured Streaming

Fenêtres fixes (5 min)



Chaque événement appartient à une seule fenêtre ; chaque fenêtre produit un agrégat.



La seule question à se poser : une décision change-t-elle si le chiffre arrive une heure plus tard ? Sinon, choisissez les lots : moins cher, plus simple, plus facile à auditer. Les indicateurs Ookla trimestriels et les composites mensuels de lumières nocturnes relèvent des lots.

Dimensionner juste : la renaissance du nœud unique



Portable, en mémoire

Jusqu'à quelques Go · pandas · R data.frame



Nœud unique, en colonnes

Jusqu'à des centaines de Go · DuckDB · Polars · Apache Arrow



Cluster ou entrepôt cloud

Téraoctets, nombreux utilisateurs · Spark · Trino · BigQuery



Plateforme de streaming

Flux continus · Kafka + Flink

DUCKDB SQL

```
-- DuckDB : interroger Ookla sur place
INSTALL https; LOAD https;
SET s3_region = 'us-west-2';
SELECT count(*) AS tiles,
       sum(tests) AS tests
FROM read_parquet('s3://ookla-open-data/
  parquet/performance/type=mobile/
  year=2025/quarter=4/*.parquet');
```

Seules les colonnes utiles à la requête sont lues à travers le réseau.



L'erreur la plus coûteuse : exploiter un cluster pour des données qui tiennent sur une seule machine. Mesurez d'abord, puis passez à l'échelle.

Seuils empiriques. Sources : documentation DuckDB (<https>, [read_parquet](#)) ; région du bucket Ookla selon l'AWS Open Data Registry.

Passer à l'échelle · Technologies big data pour les systèmes statistiques · STG17

04

Indexation et recherche

Pourquoi un moteur de recherche répond-il en millisecondes quand un parcours complet prend des minutes ?



Du parcours complet à l'indexation



Parcours complet

Lire chaque enregistrement, tester chacun



Le travail croît avec le volume : 10× plus de tuiles, ~10× plus de temps.



Index inversé

Chercher la valeur, aller droit aux enregistrements

admin1 = "Kigali" → doc 2, 5, 9, 14...

admin1 = "Huye" → doc 1, 7, 11...

quarter = 2025-Q4 → doc 5, 7, 9...

Arbre B

Bases relationnelles : intervalles et tris

Index inversé


Moteurs de recherche : termes, mots-clés, filtres

Index spatial

Quadkey, geohash, arbre BKD : « à proximité / à l'intérieur »

Un index échange du travail à l'écriture et de l'espace disque contre de la vitesse à la lecture. Identifiants illustratifs.

Le quadkey : un index spatial déjà entre vos mains



Chaque niveau ajoute un chiffre (0–3)

16 chiffres

Un quadkey de niveau 16 $\approx$ une tuile Ookla de 611 m

Préfixe = voisinage

Garder les 12 premiers chiffres agrège en cellules d' $\approx$ 9,8 km, sans fonction SIG

Identifiant stable

Relier la même tuile d'un trimestre à l'autre (de 2019 à aujourd'hui) par le seul quadkey

Formes réelles $\rightarrow$ geo_shape

Tuile face à une limite de district : Elasticsearch indexe les formes dans un arbre BKD


Sources : README Ookla Open Data ; système de tuiles Bing Maps ; documentation geo_shape d'Elasticsearch. Largeur = $40\,075\text{ km} \div 2^{\text{zoom}}$.

Passer à l'échelle · Technologies big data pour les systèmes statistiques · STG17

Elasticsearch en une image

Cluster

index : ookla-tiles · 3 shards primaires (P) + 1 réplique chacun (R)



Une réplique n'est jamais sur le même nœud que son primaire : on peut perdre un nœud sans perdre de données — et les répliques servent aussi les requêtes.

Si vous pensez en SQL...

Table → Index

Ligne → Document (JSON)

Schéma → Mapping

Type de colonne → Type de champ : keyword, integer, geo_shape...

WHERE → Requête (bool, term, range, geo_shape)

GROUP BY → Agrégation (terms, weighted_avg...)

Source : Elasticsearch Reference (clusters, index, shards et mappings).

Passer à l'échelle · Technologies big data pour les systèmes statistiques · STG17

Mapping et requête : ce que vous taperez à 14 h 45

1 · MAPPING — LE SCHÉMA

```
PUT ookla-tiles
{ "mappings": { "properties": {
  "quadkey":    { "type": "keyword" },
  "admin1":     { "type": "keyword" },
  "quarter":    { "type": "date" },
  "avg_d_kbps": { "type": "integer" },
  "tests":      { "type": "integer" },
  "devices":    { "type": "integer" },
  "tile":       { "type": "geo_shape" }
}}}

// keyword    = valeur exacte
//              (filtrer, regrouper)
// geo_shape = vrai polygone de tuile
```

2 · REQUÊTE + AGRÉGATION — PAR RÉGION

```
GET ookla-tiles/_search
{ "size": 0,
  "query": { "geo_shape": { "tile": {
    "shape": { "type": "envelope",
      "coordinates": [[28.8, -1.0], [30.9, -2.9]] },
    "relation": "intersects" }}}},
  "aggs": { "by_region": {
    "terms": { "field": "admin1" },
    "aggs": { "dl_weighted": { "weighted_avg": {
      "value": { "field": "avg_d_kbps" },
      "weight": { "field": "tests" } }}}}}}
```

// size 0 = ne renvoyer que l'agrégation
// envelope = [haut-gauche], [bas-droit], lon d'abord

Sources : Elasticsearch Reference (requête geo_shape, agrégation weighted_avg). Rectangle approximatif du Rwanda ; le mapping de l'atelier peut différer.

Un moteur de recherche : quand est-ce utile ?

	pandas	DuckDB sur Parquet	Elasticsearch
Idéal pour	Un analyste, travail exploratoire	SQL analytique lourd sur une machine	Nombreux utilisateurs, filtres et cartes interactifs
Mémoire	Tout le jeu de données en RAM	Lit les colonnes ; déborde sur disque	Répartie entre les nœuds
Géo et texte	Via GeoPandas, en mémoire	Extension spatiale	geo_shape et plein texte natifs
Latence interactive	Correcte tant que les données sont petites	Rapide pour parcours et jointures	Conçu pour des réponses < 1 s
Coût d'exploitation	Nul	Très faible	Un cluster à gérer, sécuriser et surveiller

 **Un moteur de recherche est un index, pas un système de référence.** Le lakehouse reste la source de vérité ; l'index se reconstruit à partir de lui.

Comparaison qualitative — la partie 2 de l'atelier vous demande de mesurer vous-mêmes temps de requête et empreinte mémoire.

SECTION 05 SUR 06


05

Orchestration

Qui lance la chaîne à 2 heures du matin — et que se passe-t-il quand une étape échoue ?



Une chaîne de traitement est un graphe de tâches

**Planification****Dépendances****Relances****Alertes****Rattrapage**

Outils, du plus simple au plus complet : cron · GitHub Actions → Apache Airflow · Dagster · Prefect · dbt pour les transformations SQL

La chaîne en code, avec contrôles qualité

APACHE AIRFLOW (API TASKFLOW)

```
from airflow.decorators import dag
import pendulum
# download_tiles, validate... = fonctions @task

@dag(schedule="@quarterly",
      start_date=pendulum.datetime(2019, 1, 1),
      catchup=True,           # = rattrapage
      default_args={"retries": 2})
def ookla_connectivity():
    raw    = download_tiles()
    ok     = validate(raw)    # contrôle
    pop    = population_per_tile()
    silver = join_admin(ok, pop)
    gold   = indicators(silver)
    index_elasticsearch(gold)
    publish_github(gold)

ookla_connectivity()
```

Contrôles qualité, écrits comme des tests

- ✓ tests > 0 pour chaque tuile
- ✓ quadkey unique par trimestre
- ✓ avg_d_kbps dans une plage plausible
- ✓ chaque tuile dans une seule unité admin.
- ✓ nb de tuiles à $\pm X$ % du trimestre précédent

En cas d'échec : arrêter, alerter une personne, ne jamais publier en silence. Outils : Great Expectations · tests dbt · Soda · pandera

Source : documentation Apache Airflow (API TaskFlow, catchup). Les seuils sont fixés par le méthodologue.

SECTION 06 SUR 06

06


Métadonnées et versionnage

Pouvez-vous prouver, des mois plus tard, comment un chiffre publié a été produit ?





Trois couches de métadonnées et le lignage



Lignage : chaque chiffre publié remonte à des entrées exactes



Outils de catalogue : DataHub, OpenMetadata, CKAN ; description des jeux de données : W3C DCAT. Identifiants illustratifs.

Passer à l'échelle · Technologies big data pour les systèmes statistiques · STG17

Versionner trois choses, pas une seule



Code

- Dépôt Git, demandes de fusion relues
- Versions étiquetées (v1.2.0)
- Tests automatiques en CI



Données

- Instantanés de tables : Iceberg, Delta Lake
- Versionnage de fichiers : DVC, lakeFS
- La zone bronze n'est jamais écrasée



Environnement

- Dépendances figées : fichiers de verrouillage
- Environnements Conda ou conteneurs
- Mêmes entrées + même code + même env. = même chiffre



La version publiée = ce que produiront les jours 3 à 5

Version GitHub étiquetée + README (méthode, sources, licence, limites) + DOI citable via Zenodo + responsable de maintenance désigné

Une plateforme qu'un INS peut faire grandir

D É P A R T

Un serveur ou un portable

- **Stockage** : Dossiers ou MinIO + Parquet
- **Traitement** : DuckDB · Polars · pandas
- **Recherche** : Facultative
- **Orchestration** : cron · GitHub Actions
- **Métadonnées** : README + fichiers de provenance
- **Versionnage** : Git + GitHub

*grandir selon
les mesures*



É C H E L L E

Plateforme nationale ou régionale

- **Stockage** : Stockage objet + Iceberg / Delta
- **Traitement** : Spark · Trino
- **Recherche** : Cluster Elasticsearch
- **Orchestration** : Airflow · Dagster
- **Métadonnées** : DataHub / OpenMetadata, SDMX
- **Versionnage** : Instantanés, conteneurs, CI/CD



Mutualiser : le Hub régional big data des Nations unies hébergé par le NISR et la mutualisation régionale STG17 (Plan d'action 3.1.2) permettent de partager plateformes, code et compétences.

Choisir le bon moteur

Si votre situation est...

Données en mémoire, un analyste

Dizaines à centaines de Go, SQL complexe

Téraoctets, plusieurs équipes, tables partagées

Nombreux utilisateurs filtrant par lieu et période

Latence inférieure à la minute réellement requise

Microdonnées confidentielles (CDR, fiscalité)

Privilégier

pandas, R, DuckDB

DuckDB ou Polars sur un serveur puissant

Lakehouse + Spark ou Trino

Elasticsearch alimenté par le lakehouse

Kafka + Flink

Enclave sur site ou souveraine

Éviter

Monter un cluster

Copier des CSV entre portables

Partages réseau non gouvernés

L'index comme unique copie

Du streaming pour des statistiques trimestrielles

Cloud public sans base légale

Choisissez pour les données que vous avez, pas pour celles que vous imaginez avoir dans cinq ans.

Six choses à retenir



01

Ingérer avec rigueur

Garder les données brutes intactes ; tracer source, date et licence dès le premier octet.



02

Stocker en zones et en colonnes

Parquet + bronze / argent / or : vitesse et chaîne de production claire.



03

Calculer avec des sommes

Les moteurs parallèles exigent des statistiques décomposables ; dimensionner avant de multiplier.



04

Indexer pour l'interactivité

Un moteur de recherche répond vite, mais reste un index, jamais la source de vérité.



05

Automatiser avec des contrôles

Les chaînes s'exécutent au calendrier et s'arrêtent en cas d'échec : jamais de publication silencieuse.



06

Rendre chaque chiffre traçable

Versionner code, données et environnement ; documenter méthodes et limites.

Maintenant : Ookla à l'échelle avec Elasticsearch

1

14 h 45 Partie 1 · Indexer

- Créer le mapping (keyword, integer, geo_shape)
- Charger les tuiles Ookla dans le cluster
- Lancer les premières agrégations et requêtes géo

2

15 h 45 Partie 2 · Explorer et comparer

- Exploration par région et trimestre
- Mesurer temps de requête et mémoire vs pandas
- Décider quand la complexité en vaut la peine

3

≈16 h 30 Publier

- Déposer notebooks, requêtes et résultats
- README : méthode, sources, licence
- Énoncer honnêtement les limites



À renseigner dans votre README

- 1 Elasticsearch a-t-il été plus rapide — ou plus lent — que pandas pour votre pays, et pourquoi ?
- 2 Quelle requête ne voudriez-vous jamais lancer sans index ?
- 3 La couverture nationale d'Ookla suffit-elle pour un indicateur régional — ou seulement pour un diagnostic ?

Source : programme de l'atelier STG17, jour 3 après-midi.

Passer à l'échelle · Technologies big data pour les systèmes statistiques · STG17

QUESTIONS ET DISCUSSION

Merci

Une question pour la salle

Quelle statistique de votre institut gagnerait le plus à l'un des moteurs présentés — et le premier obstacle est-il juridique, méthodologique ou technique ?

Cette session contribue au Plan d'action STG17 2025–2030 : 2.1.1 lignes directrices méthodologiques · 4.2 renforcement des capacités sur les technologies émergentes



Sources et lectures complémentaires

Données utilisées cette semaine

- Ookla — Speedtest Global Performance Open Data, github.com/teamookla/ookla-open-data
- WorldPop — données démographiques spatiales ouvertes, worldpop.org
- NASA — lumières nocturnes Black Marble (produits VNP46)
- Programme de l'atelier STG17 et Plan d'action 2025–2030

Fondements

- Dean & Ghemawat, « MapReduce », OSDI 2004
- Zaharia et al., « Apache Spark: A Unified Engine for Big Data Processing », CACM 2016
- Armbrust et al., « Lakehouse », CIDR 2021
- McKinney, « Apache Arrow and the 10 Things I Hate About pandas », 2017

Documentation technique

- Apache Hadoop HDFS Architecture · Apache Parquet
- Apache Spark · Apache Iceberg · Delta Lake
- DuckDB · Elasticsearch Reference
- Apache Airflow · intégration GitHub–Zenodo

Cadres de la statistique officielle

- CEE-ONU — Modèle générique du processus de production statistique (GSBPM)
- CEE-ONU — Cadre de qualité pour les statistiques issues du big data
- SDMX · DDI · GSIM · W3C DCAT
- Comité d'experts des Nations unies sur le big data et la science des données pour la statistique officielle