

Passer à l'échelle

Rechercher, agréger et cartographier les mégadonnées avec la suite Elastic (ELK)

Des tuiles Ookla Speedtest à un indicateur infranational de connectivité pondéré par la population

Enjeux émergents, pratiques émergentes — Innover dans la chaîne de valeur des données
Data Innovation For Africa (DI4A) - AfDB

SECTION 01


01

Pourquoi changer d'échelle

Quand un portable et pandas ne suffisent-ils plus ?



La chaîne de valeur du big data : six briques



Lac, lakehouse ou index de recherche : qui fait quoi ?



Lac de données

Répond à : Où est le fichier brut ?

- Fichiers en stockage objet (Parquet, CSV, rasters)
- Schéma à la lecture, coût très faible
- Conserve la source intacte pour l'audit



Lakehouse

Répond à : Quel est l'agrégat officiel ?

- Tables sur le lac (Delta Lake, Apache Iceberg)
- SQL, transactions, retour dans le temps
- Production reproductible des statistiques



Index de recherche

Répond à : Que montre cette sélection, tout de suite ?

- Elasticsearch / OpenSearch
- Index inversé et arbres BKD
- Filtres, texte, géo et tableaux de bord en moins d'une seconde



Par lots

Traiter un jeu de données fini à intervalles — ex. chaque publication trimestrielle d'Ookla.



En flux

Traiter des événements continus à leur arrivée — ex. capteurs, réseaux, transactions.

Le cas Ookla : un jeu de données qui éprouve vos outils

610,8 m

côté d'une tuile à l'équateur (Web Mercator, niveau de zoom 16)

T1 2019

premier trimestre disponible ; nouvelles tuiles chaque trimestre depuis

2 séries

haut débit fixe et mobile, publiés séparément

CHAMPS CLÉS DE CHAQUE TUILE

quadkey

avg_d_kbps

avg_u_kbps

avg_lat_ms

tests

devices

tile (WKT)



Pourquoi un seul portable peine. Ookla agrège des centaines de millions de tests mensuels en tuiles, mais un panel multi-pays, multi-trimestres, fixe + mobile grossit vite. Ajoutez la géométrie, les jointures avec les limites et WorldPop, et plusieurs collègues qui interrogent en même temps : c'est la mémoire, non la compétence, qui devient le goulot d'étranglement.

Source : Ookla, [README ookla-open-data \(GitHub\)](#) et [Registry of Open Data on AWS](#) — licence CC BY-NC-SA 4.0.

SECTION 02


02

La suite Elastic expliquée

Que sont E, L et K, et comment fonctionnent-ils ensemble ?



ELK en une image



De « ELK » à « Elastic Stack ». Beats (agents légers d'envoi de données) a rejoint E, L et K, et Elastic a renommé la famille. On dit encore « ELK » : les deux noms désignent la même suite.

L'idée clé : l'index inversé

DOCUMENTS

D1	Kigali · urbain · mobile
D2	Musanze · rural · fixe
D3	Kigali · rural · mobile

*indexer
une fois*

TERME → DOCUMENTS

kigali	D1, D3
musanze	D2
urbain	D1
rural	D2, D3
mobile	D1, D3
fixe	D2

REQUÊTE

kigali AND rural

$\{D1, D3\} \cap \{D2, D3\}$
= {D3}

Trouvé sans lire un seul document : on compare seulement deux listes courtes.




Pensez à l'index en fin d'annuaire statistique : on cherche le terme et on va droit aux pages. Nombres et coordonnées utilisent une structure voisine (arbres BKD) pour les intervalles et la géographie. La contrepartie : l'indexation coûte du temps, du disque et de la mémoire au départ, pour des requêtes rapides ensuite.

Parler Elasticsearch : lexique depuis pandas et SQL

EN PANDAS / SQL		EN ELASTICSEARCH	CE QUE CELA SIGNIFIE
DataFrame / table	→	Index	Une collection nommée, ex. ookla-tiles
Ligne	→	Document	Une tuile par trimestre, en JSON avec un _id unique
Colonne	→	Champ	quadkey, avg_d_kbps, tile... chacun est indexé
dtypes / schéma	→	Mapping	Types déclarés ; en changer impose de réindexer
df[filtre] / WHERE	→	Requête	Query DSL (JSON) ou ES QL (texte en pipeline)
groupby().agg() / GROUP BY	→	Agrégation	Buckets (groupes) et métriques (statistiques)

Anatomie d'un cluster : nœuds, shards et réplicas



ookla-tiles : 3 primaires (P) × 1 réplica (R), jamais sur le même nœud.

Source : documentation Elastic, « Size your shards ».

Atelier technique STG17 · Passer à l'échelle : la suite Elastic (ELK) pour la statistique officielle



Nœud

Un processus Elasticsearch actif, en général une machine.



Shard

Une tranche d'index ; l'unité qui circule entre les nœuds.



Réplica

Une copie sur un autre nœud : résilience et capacité de recherche.

DIMENSIONNEMENT

10–50 Go

par shard, moins de 200 millions de documents chacun. Un ou deux primaires suffisent pour un index Ookla national.

03

Modéliser les données

Comment transformer une tuile Ookla en document interrogeable ?



D'une ligne Parquet à un document JSON enrichi

TEL QUE PUBLIÉ PAR OOKLA

```
quadkey      "3001010303300022"  
avg_d_kbps   21450  
avg_u_kbps   9870  
avg_lat_ms   38  
tests        142  
devices      57  
tile         "POLYGON((30.0586  
              -1.9552, ...))"
```

ENRICHI



INDEXÉ DANS ELASTICSEARCH

```
{  
  "quadkey": "3001010303300022",  
  "service_type": "mobile",  
  "quarter": "2025-Q2",  
  "quarter_start": "2025-04-01",  
  "avg_d_kbps": 21450, "avg_u_kbps": 9870,  
  "avg_lat_ms": 38, "tests": 142, "devices": 57,  
  "admin1": "Kigali City",  
  "admin2": "Nyarugenge",  
  "pop_worldpop": 4830.5,  
  "centroid": {"lat": -1.9525, "lon": 30.0614},  
  "tile": "POLYGON((30.0586 -1.9552, ...))"  
}
```

Texte vert = ajouté lors de l'enrichissement

- **Trimestre et service** depuis le chemin du fichier
- **admin1 / admin2** jointure spatiale avec les limites
- **pop_worldpop** somme zonale du matin
- **centroid** calculé à partir du polygone

Quadkey et polygone : une vraie tuile de zoom 16 à Kigali. Débits, tests et population sont illustratifs.

Mapping : déclarer le schéma avant d'indexer

```
PUT ookla-tiles
{
  "mappings": {
    "dynamic": "strict",  ◀ refuser l'imprévu
    "properties": {
      "quadkey": { "type": "keyword"},
      "service_type": { "type": "keyword"},
      "quarter": { "type": "keyword"},
      "quarter_start": { "type": "date"},
      "avg_d_kbps": { "type": "integer"},
      "avg_u_kbps": { "type": "integer"},
      "avg_lat_ms": { "type": "integer"},
      "tests": { "type": "integer"},
      "devices": { "type": "integer"},
      "admin1": { "type": "keyword"},
      "admin2": { "type": "keyword"},
      "pop_worldpop": { "type": "float"},
      "centroid": { "type": "geo_point"},
      "tile": { "type": "geo_shape" }
    }
  }
}
```

keyword

Valeurs exactes : codes, noms, catégories.
Filtres, regroupements, tris.

integer · float

Mesures et comptages. Intervalles et statistiques.

date

Filtres temporels et histogrammes de dates (quarter_start).


geo_point · geo_shape

Coordonnées et polygones pour requêtes spatiales et cartes.



Gardez les codes en texte. Une tuile sur Dakar a le quadkey 0333... ; converti en nombre, il perd son zéro initial sans alerte. Déclarez quadkeys et codes administratifs en keyword.


geo_point ou geo_shape ? Deux vues d'une même tuile



geo_point

le centroïde de la tuile

- Compact et très rapide
- Cartes de chaleur, buckets geotile_grid
- Requêtes de distance (≤ 10 km)
- Une tuile frontalière ne compte que d'un côté



geo_shape

le polygone complet de 610 m

- Intersection exacte avec les limites
- Tuiles frontalières comptées des deux côtés
- Rendu fidèle des polygones dans Maps
- Plus lourd à indexer et à interroger



Recommandation : stocker les deux. Le centroïde pour la vitesse, le polygone pour les intersections exactes. Attention à l'ordre des axes : WKT et GeoJSON placent la longitude en premier, comme les fichiers Oukla.

Quatre façons de charger les données, et celle du jour



LABO 1

Client Python

Helper bulk dans un notebook.
Scriptable, versionné, reproductible.



Import Kibana

Glisser-déposer un petit CSV ou NDJSON pour explorer vite.



Logstash

Pipelines récurrents : entrée,
analyse, enrichissement, sortie.



Pipelines d'ingestion

Traitement dans Elasticsearch :
convertir, renommer, enrichir.

```
import pandas as pd
from elasticsearch import Elasticsearch
from elasticsearch import helpers

es = Elasticsearch(URL, api_key=KEY)
df = pd.read_parquet("rw_tiles.parquet")

def actions(df):
    for r in df.to_dict("records"):
        yield {
            "_index": "ookla-tiles",
            # même tuile = même id : pas de doublon
            "_id": f"{r['quadkey']}-{r['quarter']}-mobile",
            "_source": r}

ok, errors = helpers.bulk(
    es, actions(df), chunk_size=5000)
```

SECTION 04

04

Interroger et agréger

Comment poser des questions statistiques au cluster ?



Anatomie d'une requête de recherche

```
GET ookla-tiles/_search
{
  "size": 0,    ◀ 1
  "query": {
    "bool": {
      "filter": [ ◀ 2
        { "term": { "service_type": "mobile" } },
        { "term": { "quarter": "2025-Q2" } }
      ]
    }
  },
  "aggs": {
    "by_region": {
      "terms": { "field": "admin1", "size": 50 }, ◀ 3
      "aggs": {
        "mean_dl": {
          "weighted_avg": { ◀ 4
            "value": { "field": "avg_d_kbps" },
            "weight": { "field": "tests" }
          }
        }
      }
    }
  }
}
```

1

size: 0

Ne renvoyer que les résultats agrégés, pas les milliers de documents sous-jacents.

2

filter

Conditions oui/non : sans score de pertinence, en cache, rapides. C'est votre clause WHERE.

3

terms

Un bucket par région : le GROUP BY. Fixez size au-delà du nombre de régions.

4

weighted_avg

Débit descendant moyen par région, pondéré par le nombre de tests de chaque tuile.

La boîte à outils des agrégations et ses mises en garde



Métrique

calculer une valeur

`avg · sum · min · max`

≈ mean(), sum()

`weighted_avg`

≈ np.average(w=)

`percentiles`

≈ quantile()

`cardinality`

≈ nunique()



Bucket

former des groupes

`terms`

≈ groupby(col)

`range · histogram`

≈ pd.cut()

`date_histogram`

≈ resample()

`geotile_grid`

≈ grouper par tuile



Pipeline

agrégér des agrégations

`derivative`

≈ diff()

`cumulative_sum`

≈ cumsum()

`bucket_sort`

≈ sort + head()

`bucket_script`

≈ ratio calculé



Approchées par construction : cardinality (HyperLogLog++), percentiles (TDigest) et comptages terms multi-shards. Suffisant pour explorer ; vérifiez la précision ou calculez exactement avant de publier.


Un indicateur de connectivité pondéré par la population

FORMULE POUR LA RÉGION r

$$C_r = \Sigma (\text{pop}_i \times \text{débit}_i) \div \Sigma \text{pop}_i$$

Tuile	Population	Tests	Mbit/s
A · urbaine	5 000	400	20
B · périurbaine	1 200	40	8
C · rurale	300	5	2


Mêmes trois tuiles, trois réponses (Mbit/s)



⚠ Deux règles. Documentez la pondération utilisée : elle change le résultat. Et les tuiles sans test n'ont pas de débit, leur population disparaît : publiez la part de population couverte à côté de l'indicateur.

Chiffres illustratifs à visée pédagogique, non observés. Dans Elasticsearch : `weighted_avg` avec `pop_worldpop` comme poids.


Poser des questions géographiques



geo_shape

Quelles tuiles touchent ce district ?


Indicateurs infranationaux, tuiles frontalières comprises.



geo_distance

Quelles tuiles à moins de 10 km de ce point ?

Accès autour des hôpitaux, écoles ou marchés.



geotile_grid

Combien de tests par cellule ?

Cartes de chaleur et synthèses multi-échelles.

RÉUTILISER UNE LIMITE STOCKÉE PLUTÔT QUE COLLER DES COORDONNÉES

```
"query": {"bool": {"filter": {"geo_shape": {"tile": {  
  "indexed_shape": {"index": "admin-boundaries", "id": "RW-02", "path": "geometry"},  
  "relation": "intersects"}}}}}}
```

ES|QL : la même question, écrite en pipeline

```
FROM ookla-tiles
| WHERE service_type == "mobile"
  AND quarter == "2025-Q2"
| EVAL w = TO_DOUBLE(avg_d_kbps) * tests ◀ en décimal
| STATS sum_w = SUM(w),
  n_tests = SUM(tests) BY admin1
| EVAL mean_mbps = ROUND(sum_w / n_tests / 1000, 1)
| SORT mean_mbps DESC
| KEEP admin1, mean_mbps, n_tests
```



Chaque étape reçoit la table produite par la précédente, comme un pipe en R ou un chaînage pandas.

Query DSL · JSON

- Toutes les fonctions Elasticsearch
- Idéal pour applications et tableaux de bord
- Verbeux, mais précis

ES|QL · *texte en pipeline*

- Se lit comme une recette
- Idéal pour explorer dans Discover
- GA depuis la 8.14 (juin 2024)

Source : Elastic, « Elastic 8.14: Announcing the GA of ES|QL » (juin 2024).

SECTION 05

05

Explorer avec Kibana

Comment les collègues qui ne codent pas obtiennent-ils des réponses ?



Kibana : cinq outils utilisés cet après-midi



Dev Tools

Console pour exécuter des requêtes Query DSL et ES|QL.

Labo 1 : mapping, contrôles d'indexation, premières requêtes



Discover

Parcourir et filtrer les documents ; inspecter les champs.

Labo 2 : contrôles de cohérence, filtres KQL



Lens

Graphiques par glisser-déposer : barres, courbes, tableaux.

Labo 2 : débit par trimestre, fixe vs mobile



Maps

Polygones de tuiles, points et choroplèthes.

Labo 2 : carte régionale, zoom sur les tuiles



Dashboards


Combiner des panneaux avec filtres communs.

Labo 2 : l'explorateur de connectivité

KQL — LE LANGAGE DE LA BARRE DE FILTRES DANS DISCOVER ET DASHBOARDS

```
service_type : "mobile" and tests >= 5 and admin1 : "Kigali City"
```

Labo 2 : construire un explorateur de connectivité



Livrable : un tableau de bord qui répond à « Où la connectivité mobile est-elle la plus faible, et s’améliore-t-elle ? » — avec une capture d’écran et l’export des objets sauvegardés (NDJSON) versionnés dans le dépôt de l’équipe.

pandas ou Elasticsearch ? Décidez sur vos propres mesures



Restez sur pandas / DuckDB si...

- Les données tiennent aisément en mémoire
- Un analyste, une analyse ponctuelle ou périodique
- Le script reproductible est le produit
- Aucune compétence serveur pour maintenir un cluster



Passez à Elasticsearch si...

- Les données dépassent une seule machine
- Beaucoup de collègues veulent des réponses interactives
- Requêtes filtrées et spatiales répétées
- De nouvelles données arrivent en continu

VOTRE COMPARATIF — À REMPLIR PENDANT LE LABO 2

Tâche (mêmes données, même question)	Temps pandas	Mémoire pandas	Temps ES	Disque/heap ES
1 · Charger / indexer un trimestre	...	...	...	...
2 · Débit moyen pondéré par région	...	...	...	...
3 · Tuiles touchant un district	...	...	...	...

SECTION 06

06

Gouverner et pérenniser

Que garantir avant de publier depuis un moteur de recherche ?



Qualité et éthique : ce que l'index ne corrige pas



Biais de couverture

Testeurs volontaires : pas un échantillon probabiliste. Biais urbain et smartphone probable.



Petits effectifs

Fixez un seuil minimal de tests ; masquez ou signalez les régions en dessous et indiquez n.



Licence

CC BY-NC-SA 4.0 : citer Ookla, usage non commercial, partage des dérivés à l'identique.



Confidentialité

Pas de microdonnées sur un cluster ouvert. Authentification, accès par rôles, transport chiffré.



Reproductibilité

Mapping, code d'ingestion et requêtes versionnés dans Git avec le millésime des données.



Limites assumées

Un proxy n'est pas une statistique officielle. Écrivez ce qu'il ne permet pas d'affirmer.

Licence : Registry of Open Data on AWS, Speedtest by Ookla Global Fixed and Mobile Network Performance Maps.

Atelier technique STG17 · Passer à l'échelle : la suite Elastic (ELK) pour la statistique officielle

Options de déploiement pour un institut statistique



Autogéré

sur site ou centre de données national



Maîtrise de la localisation des données



Pas de facture cloud à l'usage



Compétences requises : mises à jour, sécurité



Cloud managé

Elastic Cloud ou autre fournisseur



Opérationnel en minutes, évolutif



Exploitation assurée par le fournisseur



Résidence des données, coût récurrent



OpenSearch

Fork Apache 2.0, Linux Foundation



Licence entièrement open source



Les concepts du jour s'appliquent



Les API divergent par endroits



Licences en bref. Depuis septembre 2024, le code d'Elasticsearch et de Kibana est aussi disponible sous AGPLv3 (licence approuvée par l'OSI), à côté de SSPL et de l'Elastic License ; les téléchargements par défaut restent sous Elastic License. Faites valider par votre service juridique.

Sources : Elastic, « [FAQ on Software Licensing](#) » et « [Elasticsearch is Open Source. Again!](#) » ; Reverera (2025) sur [OpenSearch](#).

Publier sur GitHub : le dépôt que votre équipe emporte

STRUCTURE SUGGÉRÉE

```
stg17-<pays>-connectivity/  
├── README.md  
├── LICENSE  
├── mappings/  
│   └── ookla-tiles.json  
├── notebooks/  
│   ├── 01_index_tiles.ipynb  
│   └── 02_benchmark.ipynb  
├── queries/  
│   ├── by_region.json  
│   └── by_region.esql  
├── kibana/  
│   └── dashboard.ndjson  
└── outputs/  
    └── connectivity_by_region.csv
```

LE README DOIT PRÉCISER



Méthode

Enrichissement, choix de pondération, seuil minimal de tests.



Sources

Ookla, WorldPop et limites, avec millésime et date d'accès.



Licences

CC BY-NC-SA 4.0 pour les données ; licence distincte pour le code.



Limites

Biais de couverture, population non couverte, limites du proxy.



Reproduire

Versions logicielles, commandes, résultats attendus.

Alimente → Plan d'action 2.1.1 · Présentations pays du jour 5

Six idées à rapporter dans votre institut

01

Une brique parmi d'autres

Gardez le brut dans le lac ; indexez un sous-ensemble enrichi.

02

L'index inversé est la clé

Le travail fait à l'indexation se paie en vitesse à la requête.

03

Modéliser avant de charger

Mappings stricts, codes en keyword, point et polygone.

04

Pondérer est un choix de méthode

Documentez-le et publiez la couverture de population.

05

Kibana ouvre les données à tous

Mais choisissez l'outil sur votre propre comparatif.

06

Vitesse ne vaut pas qualité

Licence, confidentialité et limites assumées d'abord.

Sources

	Contexte de l'atelier	BAD, UA STATAFRIC et NISR — Atelier technique STG17 « Emerging Issues, Emerging Practice » : programme et liens avec le Plan d'action STG17 2025–2030 (v. 01/09/2026).
	Données Ookla	Ookla — README ookla-open-data, github.com/teamookla/ookla-open-data (taille des tuiles, champs, publications trimestrielles depuis T1 2019).
	Licence Ookla	Registry of Open Data on AWS — Speedtest by Ookla Global Fixed and Mobile Network Performance Maps (CC BY-NC-SA 4.0).
	Taille des shards	Documentation Elastic — « Size your shards », elastic.co/docs (10–50 Go par shard, moins de 200 millions de documents).
	ES QL	Blog Elastic — « Elastic 8.14: Announcing the GA of Elasticsearch Query Language (ES QL) », juin 2024.
	Licences	Elastic — « FAQ on Software Licensing » et S. Banon, « Elasticsearch is Open Source. Again! » (option AGPLv3, 2024).
	OpenSearch	Blog Revenera — « Elastic's Return to Open Source » (janvier 2025) : fork OpenSearch et transfert à la Linux Foundation.

QUESTIONS · PUIS PLACE AU LABO

Des tuiles à l'analyse

Votre cluster tourne. Vos notebooks vous attendent. Rejoignez votre équipe.