



Enjeux émergents, pratiques émergentes

Innové dans la chaîne de valeur des données — IA, LLM et Big Data pour la statistique officielle

DATES**28 septembre – 2 octobre 2026****LIEU****Kigali, Rwanda****FORMAT****5 jours · 29 séances · 13 laboratoires**

Cinq jours, du concept au dépôt publié. Chaque demi-journée associe un exposé bref à un laboratoire prolongé sur machine.

Jour 1 · Concepts de l'IA et l'infrastructure qui les porte

Lundi — Un vocabulaire commun, l'expérience des pays, et ce qu'exige réellement la construction et l'exploitation de l'IA

Heure	Séance
09h00–09h15	Cérémonie d'ouverture Mots de bienvenue et d'ouverture de la Banque africaine de développement et de l'UA STATAFRIC. Objectifs de la semaine, présentation du Plan d'action STG17 2025-2030 et de la place de cet atelier en son sein. Tour de table. CÉRÉMONIE
09h15–09h35	Data Innovation for Africa (DI4A) à la BAD : mission, portefeuille actuel et prochaines étapes Pourquoi la Banque a créé DI4A, ce que finance le portefeuille actuel, et les prochaines étapes. L'initiative s'inscrit dans l'African Information Highway et constitue le véhicule de la Banque pour l'innovation par les données avec les offices statistiques africains. EXPOSÉ
09h35–10h05	Le Hub régional des Nations Unies pour les mégadonnées au Rwanda : jalons et cas d'usage Dix ans du Comité d'experts des Nations Unies sur les mégadonnées et la science des données pour la statistique officielle, et ce que le Hub régional hébergé par le NISR a produit depuis son lancement : les cas d'usage menés le plus loin EXPOSÉ
10h05–10h30	L'arbre généalogique de l'IA : comment les concepts s'articulent Construction d'une carte conceptuelle commune — IA, LLM, ingénierie de prompt, RAG, affinage, systèmes agentiques, agents, MCP. Ce que chaque concept peut et ne peut pas faire pour la statistique officielle, et la discipline de vocabulaire qui évite les malentendus coûteux. Cette demi-heure fixe le langage de toute la semaine. EXPOSÉ
10h45–11h45	Expériences des pays en IA et en usage des mégadonnées non traditionnelles Brèves présentations pays (8 minutes chacune, 6 diapositives maximum) sur ce qui a réellement été tenté sur place — pilotes lancés, partenariats de données signés, obstacles rencontrés, résultats publiés. Les pays sont invités à être francs sur ce qui n'a pas fonctionné ; c'est la moitié la plus utile de l'échange. PLÉNIÈRE
11h45–12h30	Synthèse : où en est le continent Discussion animée structurée autour de quatre questions tirées des présentations — quels cas d'usage reviennent, quels partenariats de données sont répliquables, quels obstacles sont partagés, et où la mutualisation serait payante. Les productions sont consignées sur un mur ouvert toute la semaine. Se termine par l'auto-évaluation initiale des compétences. DISCUSSION ANIMÉE

Heure	Séance
14h00–14h30	Infrastructure de l'IA : ce qu'exige réellement l'exploitation de l'IA dans un office statistique Fondamentaux et besoins — GPU et accélérateurs, mémoire et contexte, inférence contre entraînement, latence et débit. Nuage, hybride ou sur site ; souveraineté des données et contraintes de confidentialité des microdonnées d'un INS ; modélisation des coûts par cas d'usage ; modèles à poids ouverts contre propriétaires. À quoi ressemble une configuration d'entrée de gamme réaliste pour un INS africain, avec des ordres de grandeur indicatifs. EXPOSÉ
14h30–15h30	Atelier partie 1 — Génération augmentée par récupération (RAG) Construire un assistant RAG fonctionnel sur un corpus statistique (note de concept STG17, plan d'action, SHaSA II, documents méthodologiques nationaux) — découpage, plongements, base vectorielle, récupération, réponse ancrée. Le tester sur des questions à réponse connue et observer où la récupération échoue, et pourquoi. LABORATOIRE
15h30–16h45	Atelier partie 2 — Du RAG à l'agent Transformer le récupérateur construit avant la pause en outil, et l'envelopper dans un agent — outils et appel de fonctions, planification et itération, mémoire, gestion d'erreurs et points de contrôle humains. L'agent répond à une question, retrouve les chiffres à l'appui et rédige une courte note ; les participants examinent ensuite précisément où il doit rester supervisé. LABORATOIRE

Jour 2 · Ingénierie de prompt et usage optimisé des LLM

Mardi — Obtenir des modèles de langage un travail fiable, rapide et abordable

Heure	Séance
09h00–10h30	Parler aux machines : l'art de l'ingénierie de prompt Cadrage de la tâche, rôle et contexte, contraintes explicites, exemples few-shot, décomposition, sorties JSON structurées, garde-fous et itération systématique. Pourquoi les modèles hallucinent et comment la conception du prompt réduit le phénomène. Anti-patrons courants et comment les détecter dans vos propres prompts. EXPOSÉ ET LABORATOIRE
10h45–12h30	Atelier — Du document statistique au tableau de bord public Prendre une publication statistique nationale (PDF ou rapport), utiliser un LLM pour en extraire et structurer les données, vérifier l'extraction contre la source, générer un tableau de bord interactif et le publier en ligne sur GitHub Pages. Chaque participant repart avec une URL publique. L'étape de vérification n'est pas optionnelle — c'est elle qui rend le résultat publiable. LABORATOIRE
14h00–14h45	De bon à excellent : optimisation des prompts L'amélioration systématique plutôt que le tâtonnement — construire un jeu d'évaluation, mesurer la qualité des sorties, maîtriser la variance, gérer la longueur de contexte et le coût en tokens, la mise en cache, et arbitrer entre prompt, RAG et affinage. EXPOSÉ ET LABORATOIRE
14h45–15h30	Choisir son moteur : vitesse, coût et souveraineté — travailler avec Groq Comment la vitesse d'inférence change ce qui est faisable dans une chaîne statistique de production. Les participants exécutent le même prompt chez deux fournisseurs, dont Groq, et consignent latence, coût pour mille documents et qualité de sortie dans une feuille de comparaison partagée. Cette feuille devient un intrant réutilisable pour les achats de leur office. BENCHMARK
15h30–16h45	Atelier — Un modèle, plusieurs métiers : une boîte à outils LLM pour statisticiens Ateliers tournants sur des cas d'usage professionnels — écrire et déboguer du code ; rédiger rapports et notes méthodologiques ; produire des présentations ; générer graphiques et visuels ; travail sur l'image et l'identité visuelle, y compris la création de logos ; analyse documentaire et synthèses audio avec NotebookLM ; multimodalité avec Gemini. Chaque participant choisit deux ateliers pertinents pour son office et repart avec un livrable achevé de chacun. LABORATOIRE

Jour 3 · Au-delà de l'enquête : données non traditionnelles et technologies qui les traitent

Mercredi — Une nouvelle matière première pour la statistique officielle — et les moteurs qui la rendent exploitable à l'échelle

Heure	Séance
09h00–10h30	Sources de données non traditionnelles : le trésor caché Taxonomie des sources non traditionnelles — imagerie satellitaire, mesure participative, données de caisse et de transaction, moissonnage web, capteurs et IdO, données produites par les citoyens. Cadres de qualité et biais de couverture des sources non probabilistes ; modèles d'accès et de partenariat avec les détenteurs privés ; éthique et confidentialité. EXPOSÉ ET LABORATOIRE
10h45–12h30	Atelier — Données ouvertes Ookla Speedtest et WorldPop Ookla : tuiles de performance au zoom 16 en Mercator web (environ 611 m à l'équateur), trimestrielles depuis le T1 2019 ; champs clés (quadkey, avg_d_kbps, avg_lat_ms, tests, devices) ; licence CC BY-NC-SA 4.0 et ses conséquences pour la publication par un INS ; vérifier la couverture nationale avant de concevoir tout indicateur. WorldPop : rasters de population maillés servant à pondérer et normaliser. Les équipes joignent les tuiles aux frontières administratives et produisent un premier indicateur de connectivité pondéré par la population, par région. LABORATOIRE
14h00–14h30	Moteurs de passage à l'échelle : technologies big data pour les systèmes statistiques Fondamentaux — ingestion, stockage (lac de données et lakehouse), traitement distribué (par lots contre flux, Spark), indexation et recherche, orchestration, métadonnées et versionnement. Où chaque technologie mérite sa place dans un INS, et où un outil plus simple ferait l'affaire. La Plateforme mondiale des Nations unies et le Centre ONU pour les mégadonnées de Kigali comme infrastructures partagées. EXPOSÉ
14h45–15h30	Atelier partie 1 — Ookla à l'échelle avec Elasticsearch Indexer les tuiles Ookla dans un cluster Elasticsearch pré-provisionné ; comprendre le mapping et le type geo_shape ; exécuter les premières agrégations et requêtes géospatiales. LABORATOIRE
15h30–16h45	Atelier partie 2 — Exploration pilotée par la recherche Construire une exploration de la connectivité par région et par trimestre pilotée par la recherche ; comparer temps de requête et empreinte mémoire avec l'approche pandas du matin, et en tirer la conclusion pratique sur le moment où la complexité supplémentaire se justifie. LABORATOIRE

Jour 4 · L'Afrique après la nuit tombée : lire le développement dans les lumières nocturnes

Jeudi — Une journée entière sur les NTL — de la radiance brute à un indicateur infranational validé

Heure	Séance
09h00–09h30	Lumières nocturnes : ce que l'obscurité nous dit Concepts et utilité, délibérément brefs pour que la journée se passe dans les données — de DMSP-OLS (1992-2013) à VIIRS/DNB ; les produits NASA Black Marble (VNP46A2 journalier, A3 mensuel, A4 annuel) et la série VNL annuelle de l'EOG ; unités de radiance, résolution et disponibilité temporelle ; ce que les NTL approchent bien — activité économique, électrification, urbanisation, suivi de crise. Les artefacts connus ne sont ici que nommés ; on les rencontre concrètement en partie 2. EXPOSÉ
09h30–10h30	Atelier partie 1 — Collecter Accéder aux rasters NTL (NASA Earthdata, EOG ou Google Earth Engine) ; comprendre la structure des fichiers, les bandes et les indicateurs de qualité ; découper à l'emprise nationale et enregistrer un sous-ensemble de travail. LABORATOIRE

Heure	Séance
10h45–12h30	Atelier partie 2 — Explorer et comprendre Visualiser et interroger le raster avant de calculer dessus — distribution des valeurs de radiance, effet des masques de nuages et de qualité, variation d'un mois à l'autre. Les équipes traquent délibérément les artefacts nommés dans l'exposé du matin (halo lumineux autour des villes, saturation, torchères, saisonnalité, discontinuité de capteur, bruit de faible luminosité rural) et documentent lesquels sont présents dans leur propre pays. Se termine par un tour de comparaisons entre équipes. LABORATOIRE
14h00–15h30	Atelier partie 3 — Analyse Statistiques zonales par niveau administratif (somme de radiance, radiance moyenne, superficie éclairée) ; séries temporelles annuelles et mensuelles ; détection de changement entre deux périodes ; cartographie et visualisation des résultats. LABORATOIRE
15h30–16h30	Atelier partie 4 — Validation Corréler l'indicateur indirect NTL avec des statistiques infranationales officielles (PIB, population, taux d'électrification) et, le cas échéant, avec les indicateurs de connectivité du Jour 3. Décider, preuves à l'appui, si l'indicateur est utilisable pour la diffusion dans votre pays ou s'il reste un simple outil de diagnostic. Documenter explicitement les limites — cette déclaration fait partie du livrable. LABORATOIRE
16h30–16h45	Publication et préparation du Jour 5 Verser carnets, cartes et déclaration de limites sur GitHub ; assembler les trois productions de la semaine — tableau de bord, indicateurs de connectivité, analyse NTL — dans la présentation pays de 8 minutes pour vendredi. LABORATOIRE

Jour 5 · Ressources partagées, résultats des pays et voie à suivre

Vendredi (matin seulement) — Transformer une semaine de pratique en ressource continentale et en engagements au titre du Plan d'action

Heure	Séance
09h00–10h30	Aider les pays à publier leurs travaux Comment une équipe nationale transforme ce qu'elle a construit cette semaine en produit public durable — structure de dépôt et conventions de README, GitHub Pages, licences des données et du code, DOI et citation, métadonnées, versionnement et responsabilité de maintenance. Se conclut par l'offre d'appui continu du Secrétariat et la voie de soumission des travaux nationaux au catalogue de bonnes pratiques du STG17. LABORATOIRE
10h45–12h15	Présentations des pays Chaque équipe présente les travaux produits durant la semaine — tableau de bord, indicateurs de connectivité, analyse NTL — avec son dépôt GitHub et une déclaration honnête de ses limites. 8 minutes plus 2 pour les questions ; les équipes sont formées au niveau pays ou sous-régional afin que le créneau tienne. PLÉNIÈRE
12h15–12h30	Enseignements clés et voie à suivre Consolidation du mur resté ouvert toute la semaine, et accord sur les thèmes des webinaires de suivi. PLÉNIÈRE
12h30–12h45	Cérémonie de clôture Mots de clôture de la Banque africaine de développement et de l'UA STATAFRIC. Certificats et prochaines étapes au titre du Plan d'action STG17. CÉRÉMONIE

Détail complet, supports et carnets : <https://datainnov4africa-web.github.io/stg17-workshop/fr/>